



Processus de Poisson

Théorie, simulation et applications

Travail d'Étude et de Recherche
Master 1 Mathématiques

Koessivi Jean HONOU

Encadrant : **Philippe BONNEAU**

Motivation et problématique

Question générale

Comment modéliser des événements aléatoires qui arrivent dans le temps ?

Exemples classiques

- ▶ appels téléphoniques ;
- ▶ arrivées de clients ;
- ▶ requêtes informatiques ;
- ▶ files d'attente.

Applications du TER

- ▶ sessions de recharge électrique ;
- ▶ signalements NYC 311 ;
- ▶ incidents de trafic ;
- ▶ demandes de service.

Problématique

Dans quelle mesure le processus de Poisson permet-il de modéliser des arrivées réelles dans le temps ?


Objectifs et plan de l'exposé

Objectifs du travail : comprendre le modèle, le simuler, puis le tester sur deux jeux de données réels.

- 1 Fondements théoriques
- 2 Simulation numérique sous R et Python
- 3 Application aux sessions de recharge ACN-Data
- 4 Application aux signalements NYC 311
- 5 Limites du modèle homogène et extension non homogène

Théorie $\longrightarrow$ simulation $\longrightarrow$ données réelles $\longrightarrow$ limites du modèle

Du modèle discret au modèle continu



On découpe l'intervalle $[0, \tau]$ en petits intervalles de longueur δ . Sur chaque petit intervalle, on pose :

$$X_i = \begin{cases} 1, & \text{arrivée,} \\ 0, & \text{pas d'arrivée.} \end{cases} \quad \mathbb{P}(X_i = 1) = p.$$

Le nombre total d'arrivées sur $[0, \tau]$ est alors :

$$N_\tau = X_1 + \cdots + X_n, \quad n = \frac{\tau}{\delta}.$$

Objectif : obtenir un processus de comptage continu $N(t)$.

De la loi binomiale à la loi de Poisson

Le nombre d'arrivées suit d'abord une loi binomiale :

$$\mathbb{P}(N_\tau = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

On choisit :

$$p = \lambda\delta, \quad n = \frac{\tau}{\delta}, \quad np = \lambda\tau.$$

Lorsque $\delta \rightarrow 0$, on a :

$$n \rightarrow +\infty, \quad p \rightarrow 0, \quad np = \lambda\tau \text{ reste fixé.}$$

On obtient alors :

$$\mathbb{P}(N_\tau = k) \longrightarrow \frac{(\lambda\tau)^k}{k!} e^{-\lambda\tau}.$$

Conclusion :

$$N_\tau \sim \mathcal{P}(\lambda\tau).$$

Processus de Poisson homogène

Un processus $(N(t))_{t \geq 0}$ est un processus de Poisson homogène d'intensité $\lambda > 0$ si :

1. $N(0) = 0$;
2. les accroissements disjoints sont indépendants ;
3. pour tout $0 \leq s < t$,

$$N(t) - N(s) \sim \mathcal{P}(\lambda(t - s)).$$

En particulier :

$$N(t) \sim \mathcal{P}(\lambda t), \quad \mathbb{P}(N(t) = k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}.$$

Propriété clé	Utilisation dans les données
$\mathbb{E}[N(t)] = \text{Var}(N(t)) = \lambda t$	détecter la surdispersion
$T_1 \sim \text{Exp}(\lambda)$	analyser les temps inter-arrivées

Simulation : construction du processus



On simule un processus de Poisson homogène pour vérifier les propriétés théoriques avant l'étude des données réelles.

Étape	Construction
Temps inter-arrivées	$T_i \stackrel{i.i.d.}{\sim} \text{Exp}(\lambda)$
Instants d'arrivée	$S_n = T_1 + \cdots + T_n$
Compteur	$N(t) = \max\{n \geq 0 : S_n \leq t\}$
Paramètres	$\lambda = 5, \quad \tau = 10, \quad M = 10000$
Référence théorique	$\mathbb{E}[N(\tau)] = \text{Var}(N(\tau)) = \lambda\tau = 50$

Les trajectoires simulées sont en escalier : le compteur reste constant entre deux arrivées et augmente lors d'un événement.

Simulation : validation statistique

Distribution de $N(\tau)$: simulation et loi théorique



Quantité	R	Python
Moyenne simulée	50.002	49.9128
Variance simulée	49.891	50.2194
Indice de dispersion	0.9978	1.0061

Conclusion : les simulations sont cohérentes avec le modèle homogène.

ACN-Data : source et données finales

Source et choix

ACN-Data est un jeu public de sessions de recharge de véhicules électriques, mis à disposition par Caltech :

`ev.caltech.edu/dataset.`

Site retenu : office_01, parking Parking_Lot_01, 8 bornes.

Filtrage

- ▶ base initiale : 1 474 sessions ;
- ▶ jours ouvrés ;
- ▶ exclusion de la période COVID ;
- ▶ base finale : 1 218 sessions.

session_start	date	hour	jour
2019-03-25 16 :24 :42	2019-03-25	16	Monday
2019-03-25 17 :19 :26	2019-03-25	17	Monday
2019-03-25 21 :27 :32	2019-03-25	21	Monday
2019-03-26 18 :33 :56	2019-03-26	18	Tuesday

La colonne `session_start` donne l'instant d'arrivée ; `date` permet de construire les comptes journaliers.

ACN-Data : des horodatages aux comptes journaliers

Une arrivée correspond au début d'une session :

$$Y_k = \text{session_start}_k.$$


On regroupe les arrivées par date :

$$X_j = \text{nombre de sessions commencées le jour } j = N(j+1) - N(j).$$

Sous le modèle homogène :

$$X_j \sim \mathcal{P}(\lambda).$$

Série temporelle des comptes journaliers



Taux moyen estimé

$$\hat{\lambda} = \bar{X} = 5,4619$$

sessions par jour

ACN-Data : tests du modèle homogène

Pour une loi de Poisson homogène :


$$\mathbb{E}[X_j] = \text{Var}(X_j) = \lambda, \quad I_d = \frac{\widehat{\text{Var}}(X_j)}{\bar{X}} \simeq 1.$$

Critère	Valeur	Interprétation
Moyenne $\bar{X}$	5,4619	taux moyen journalier
Variance $\widehat{\text{Var}}(X_j)$	8,5648	supérieure à la moyenne
Indice I_d	1,5681	surdispersion
χ^2_{obs}	36,1493	ddl = 8
p-valeur	$1,65 \times 10^{-5}$	$< 0,001$

Décision : rejet du modèle homogène.

ACN-Data : bilan

Distribution des comptes journaliers et loi de Poisson ajustée



Point observé

Comptes journaliers

Surdispersion

Test du chi-deux

Interprétation

construction d'un processus de comptage
variabilité supérieure au modèle homogène
rejet statistique du taux constant

Le modèle homogène sert de référence, mais ACN-Data montre déjà une structure temporelle dans les arrivées.

NYC 311 : source et sous-flux retenu

Source

NYC 311 recense les demandes de service adressées à la ville de New York. Le jeu de données est public : `data.cityofnewyork.us`.

Périmètre final

- ▶ type : Traffic Signal Condition;
- ▶ lieu : Bronx;
- ▶ période : 01/01/2020 – 29/02/2020 ;
- ▶ volume final : 664 signalements ;
- ▶ horizon : 1 438 heures.

Type de demande		Total	Moy.	I_d
Street Light Condition		5 899	7,71	29,40
Water System		4 026	5,26	5,17
Traffic	Signal	3 202	4,19	3,96
Condition				


Restriction au Bronx : $I_d = 1,4033$ sur janvier 2020.

NYC 311 : comptes horaires et structure temporelle


Une arrivée correspond à la création d'un signalement :

$$Y_k = \text{created_date}_k, \quad X_h = \text{nombre de signalements pendant l'heure } h = N(h+1) - N(h).$$

Série temporelle des comptes horaires



Distribution horaire des signalements



$$\hat{\lambda} = \frac{664}{1438} = 0,4618 \quad \text{signalement par heure.}$$

La distribution horaire montre une activité très faible la nuit et plus forte en journée.

NYC 311 : tests du modèle homogène

Pour une loi de Poisson homogène :

$$\mathbb{E}[X_h] = \text{Var}(X_h) = \lambda, \quad I_d = \frac{\widehat{\text{Var}}(X_h)}{\bar{X}} \simeq 1.$$

Critère	Valeur	Interprétation
Moyenne $\bar{X}$	0,4618	taux moyen faible
Variance $\widehat{\text{Var}}(X_h)$	0,6328	supérieure à la moyenne
Indice I_d	1,3704	surdispersion
χ^2_{obs}	57,58	ddl = 2
p-valeur	< 0,001	rejet de H_0

Décision : rejet du modèle homogène.

Pourquoi introduire un modèle non homogène ?

Les simulations ont confirmé le comportement du processus de Poisson homogène. Mais sur les deux jeux de données réelles, le modèle à taux constant est rejeté.

Données	Résultat homogène	Structure observée
ACN-Data	$I_d = 1,5681, p \approx 1,65 \times 10^{-5}$	activité différente selon les jours et montée progressive du site
NYC 311	$I_d = 1,3704, p < 0,001$	activité faible la nuit et plus forte en journée

Le problème vient surtout de l'hypothèse :

$$\lambda(t) = \lambda.$$

Idée : remplacer le taux constant par une intensité qui dépend du temps.

Processus de Poisson non homogène

Dans le modèle homogène, le taux d'arrivée est constant :

$$\lambda(t) = \lambda.$$

Dans le modèle non homogène, l'intensité devient une fonction du temps :

$$\lambda(t) \geq 0.$$

Pour tout intervalle $[a, b]$, le nombre d'arrivées vérifie :

$$N(b) - N(a) \sim \mathcal{P}(\Lambda(a, b)), \quad \Lambda(a, b) = \int_a^b \lambda(u) du.$$

Homogène	Non homogène
un seul taux λ	une intensité $\lambda(t)$
$N(t) \sim \mathcal{P}(\lambda t)$	$N(t) \sim \mathcal{P}\left(\int_0^t \lambda(u) du\right)$

Principe : conserver la structure de Poisson, mais adapter le paramètre au rythme observé.

Choix de l'intensité variable

On ne choisit pas $\lambda(t)$ au hasard : le choix vient des structures observées dans les données.

Données	Structure dominante	Choix
ACN-Data	différences selon les jours ouvrés	$\lambda(t) = \lambda_{\text{jour}}$
NYC 311	forte variation selon l'heure	$\lambda(t) = \lambda_{\text{heure}}$

Objectif : voir si une intensité variable réduit la surdispersion et améliore les tests.

Extension sur ACN-Data

Pour ACN-Data, on utilise un taux dépendant du jour :

$$\lambda(t) = \lambda_{\text{jour}}.$$

$$\hat{\lambda}_d = \frac{\sum_{\text{jours } j \in d} X_j}{\text{card}\{j : \text{le jour } j \text{ est de type } d\}}, \quad X_j = \text{nombre de sessions commencées le jour } j.$$

Jour d	lun.	mar.	mer.	jeu.	ven.
$\hat{\lambda}_d$	5,80	4,36	5,00	5,84	6,26

Critère	Homogène	Non homogène
Moyenne globale	5,4619	5,4619
Variance empirique / attendue	8,5648	$\approx 6,04$
Indice de dispersion	1,5681	1,1062
Statistique du chi-deux	36,15	29,32
p-valeur	$1,65 \times 10^{-5}$	0,000573
Décision	rejet	rejet encore présent

Bilan : la dispersion diminue nettement, mais le test reste rejeté

Extension sur NYC 311

Pour NYC 311, on utilise un taux dépendant de l'heure :

$$\lambda(t) = \lambda_{\text{heure}}.$$

$$\hat{\lambda}_h = \frac{\sum_{\text{jours } j} X_{j,h}}{\text{card}\{j : \text{l'heure } h \text{ est observée le jour } j\}}, \quad X_{j,h} = \text{nombre de signalements le jour } j \text{ à l'heure } h.$$

Heure h	0	1	2	...	8	9	10	...	22	23
$\hat{\lambda}_h$	0,13	0,18	0,08	...	0,88	1,32	1,00	...	0,34	0,17

Critère	Homogène	Non homogène
Moyenne globale	0,4618	$E[\lambda_h] = 0,4615$
Variance empirique / attendue	0,6328	0,5648
Indice de dispersion	1,3704	1,2238
Statistique du chi-deux	57,58	9,13
p-valeur	< 0,001	0,0579
Décision	rejet	non-rejet au seuil 5%

Conclusion : le modèle non homogène n'est plus rejeté au seuil 5%.

Conclusion générale

Réponse à la problématique

Le processus de Poisson est un bon point de départ pour modéliser des arrivées aléatoires : il donne un cadre simple, simulable et statistiquement testable.

Étape	Ce que le TER a montré
Théorie	passage Bernoulli $\rightarrow$ Poisson, propriétés de comptage
Simulation	cohérence avec $\mathbb{E}[N(t)] = \text{Var}(N(t))$
ACN-Data	rejet du modèle homogène, mais structure temporelle détectée
NYC 311	rejet du modèle homogène, forte structure horaire
Extension	amélioration avec une intensité variable $\lambda(t)$

Conclusion : le modèle homogène est utile comme référence, mais les données réelles nécessitent souvent une intensité variable.

Perspectives : prévision de charge électrique, systèmes urbains, files d'attente, modèles non homogènes plus fins.