

UNIVERSITÉ DE LORRAINE
UFR-MIM
MASTER 1 MATHÉMATIQUES

Processus de Poisson : théorie, simulation et applications aux arrivées dans les systèmes urbains

*Application aux sessions de recharge de véhicules électriques à Caltech
et aux signalements NYC311 dans le Bronx*

Travail d'Étude et de Recherche (TER)

Auteur : Koessivi Jean HONOU
Encadrant : Philippe BONNEAU
Année : 2025–2026

Résumé

Ce travail étudie le processus de Poisson comme modèle probabiliste des flux d'arrivées aléatoires dans le temps. L'idée directrice est simple : partir d'un modèle théorique classique, en vérifier la cohérence par simulation, puis le confronter à des données réelles issues de deux contextes contrastés.

La première partie établit les fondements mathématiques du modèle : la loi de Poisson pour le compteur, la loi exponentielle pour les temps inter-arrivées, ainsi que les propriétés de superposition et d'amincissement. Ces résultats sont ensuite validés par simulation numérique sous R et Python. Dans les deux environnements, les expériences confirment l'adéquation entre théorie et simulation : les temps inter-arrivées suivent bien une loi exponentielle, le compteur possède la structure attendue, et l'égalité entre moyenne et variance est retrouvée numériquement.

Le modèle est ensuite appliqué à deux jeux de données publics. Le premier, ACN-Data, décrit des sessions de recharge de véhicules électriques sur un parking de bureau du campus de Caltech. Le second correspond à des signalements de type *Traffic Signal Condition* dans le système municipal NYC 311, limités au Bronx. Dans les deux cas, les tests statistiques conduisent à rejeter le modèle de Poisson homogène. Ce rejet met en évidence une même limite de fond : les flux réels ne sont pas gouvernés par un taux constant dans le temps.

Pour ACN-Data, la non-stationnarité s'explique principalement par une variabilité selon le jour de la semaine et par une évolution progressive du niveau d'activité du site. Pour NYC 311, elle provient surtout d'une forte structure horaire du flux, avec des pics d'activité et des périodes creuses nettement marquées. Ces résultats conduisent naturellement à introduire le processus de Poisson non homogène, dans lequel l'intensité devient une fonction du temps $\lambda(t)$.

Le chapitre final montre que cette extension améliore nettement l'ajustement du modèle. Dans le cas d'ACN-Data, une stratification par jour de la semaine réduit sensiblement la surdispersion, avec une amélioration de 29,5 %, sans toutefois supprimer entièrement les écarts résiduels. Dans le cas de NYC 311, une stratification par heure de la journée permet d'obtenir un ajustement beaucoup plus satisfaisant : la surdis-

persion diminue de 10,7 % et le test du chi-deux ne conduit plus à rejeter le modèle au seuil de 5 % ($p = 0,0579$).

Ce travail montre ainsi que le processus de Poisson homogène constitue un cadre de référence utile pour décrire un flux moyen, mais que son extension non homogène devient nécessaire dès que les données présentent des rythmes temporels structurés. Le choix du bon modèle dépend alors moins d'une formule universelle que de la nature précise de la variabilité observée.

Mots-clés : processus de Poisson, processus de Poisson non homogène, loi exponentielle, simulation, ACN-Data, NYC 311, arrivées aléatoires, surdispersion, Python, R.

Table des matières

Introduction générale	6
1 Fondements théoriques du processus de Poisson	8
1.1 Le processus de Bernoulli	8
1.1.1 Définition et hypothèses	8
1.1.2 Interprétation comme processus stochastique	9
1.1.3 Nombre de succès en n essais	9
1.1.4 Temps d'attente avant le premier succès	9
1.1.5 Propriété de redémarrage à neuf	9
1.1.6 Temps de la k -ième arrivée	10
1.1.7 Fusion et décomposition	10
1.2 Du processus de Bernoulli au processus de Poisson	10
1.2.1 Passage à la limite	10
1.3 Définition du processus de Poisson	11
1.3.1 Probabilités sur un petit intervalle	11
1.4 Loi du nombre d'arrivées	11
1.5 Espérance et variance	12
1.6 Temps d'attente avant la première arrivée	12
1.7 Propriété sans mémoire	12
1.8 Temps inter-arrivées	12
1.9 Temps de la n -ième arrivée : loi d'Erlang	13
1.10 Superposition et amincissement	13
1.11 Tableau récapitulatif	13

1.12 Exemple : la pêche de Poisson	14
2 Simulation du processus de Poisson	15
2.1 Simulation en R	15
2.1.1 Mise en place des paramètres	15
2.1.2 Génération des temps inter-arrivées	16
2.1.3 Construction des instants d'arrivée	17
2.1.4 Trajectoire du processus	18
2.1.5 Distribution empirique de $N(\tau)$	19
2.1.6 Tests statistiques d'adéquation	21
2.1.7 Bilan intermédiaire de la partie R	22
2.2 Simulation en Python	22
2.2.1 Mise en place des paramètres	22
2.2.2 Génération des temps inter-arrivées	23
2.2.3 Construction des instants d'arrivée	24
2.2.4 Trajectoire du processus	24
2.2.5 Distribution empirique de $N(\tau)$	26
2.2.6 Tests statistiques d'adéquation	28
2.2.7 Bilan intermédiaire de la partie Python	29
Conclusion du chapitre	30
3 Application aux arrivées de sessions de recharge électrique	32
3.1 Contexte énergétique et mobilité électrique	32
3.2 Présentation du dataset ACN-Data	33
3.3 Définition de l'événement étudié	34
3.4 Préparation des données	36
3.5 Construction des comptes journaliers	39
3.6 Estimation du taux d'arrivée	40
3.7 Analyse descriptive	41
3.8 Ajustement du modèle de Poisson homogène	43
3.9 Analyse des temps inter-arrivées	45

3.10	Discussion des résultats	47
4	Application aux demandes de service NYC 311	49
4.1	Contexte urbain et demandes de service	49
4.2	Présentation du dataset NYC311	50
4.3	Choix du type de demande étudié	52
4.4	Définition de l'événement étudié	54
4.5	Préparation des données	55
4.6	Construction des comptes horaires	58
4.7	Estimation du taux d'arrivée	59
4.8	Analyse descriptive	60
4.9	Ajustement du modèle de Poisson	62
4.10	Discussion des résultats	63
5	Comparaison, limites et extension	65
5.1	Comparaison des deux applications	65
5.2	Moyenne, variance et surdispersion	66
5.3	Limites du processus de Poisson homogène	67
5.4	Processus de Poisson non homogène	69
5.4.1	Définition théorique	69
5.4.2	Interprétation et flexibilité	70
5.4.3	Estimation pratique	70
5.4.4	Lien avec les applications	70
5.4.5	Implémentation paramétrique sur ACN-Data	71
5.4.6	Implémentation paramétrique sur NYC 311	77
5.4.7	Synthèse comparative	83
	Conclusion générale	89
	Bibliographie	91

Introduction générale

Imaginez un parking d'entreprise équipé de bornes de recharge pour véhicules électriques. Tout au long de la journée, des conducteurs se présentent pour recharger leur véhicule : parfois deux en l'espace de quelques minutes, parfois aucun pendant une heure entière. À des milliers de kilomètres de là, les habitants de New York adressent en ce moment même des signalements au numéro de service municipal 311 : une panne d'éclairage public ici, une nuisance sonore là, un problème de voirie ailleurs, des centaines de demandes qui affluent chaque jour sans que personne ne soit en mesure de prédire à quel instant arrivera la suivante.

Ces deux situations, en apparence très différentes, partagent une structure commune : *des événements discrets se produisent de façon aléatoire dans le temps*. Être capable de modéliser et d'anticiper de tels flux constitue un enjeu concret pour dimensionner les infrastructures de recharge, optimiser la gestion de l'énergie ou encore planifier les ressources humaines dédiées aux services urbains. C'est précisément l'ambition du **processus de Poisson**, un modèle probabiliste dont les origines remontent au XIX^e siècle, initialement utilisé pour analyser les décès par ruades de chevaux dans l'armée prussienne, et devenu aujourd'hui un outil fondamental en sciences des données, en ingénierie des systèmes et en statistiques appliquées.

L'idée centrale repose sur une hypothèse d'une grande élégance : si les événements se produisent de manière indépendante et à un rythme moyen constant, alors le compteur

$$N(t) = \text{nombre d'événements survenus dans l'intervalle } [0, t]$$

suit une loi de Poisson de paramètre λt , où $\lambda > 0$ désigne le *taux d'arrivée* par unité de temps. Toute la richesse du modèle découle de cette unique hypothèse.

Les deux jeux de données retenus pour ce TER sont publics et librement accessibles. Le premier, **ACN-Data**, recense les sessions de recharge de véhicules électriques collectées sur le campus de Caltech et au laboratoire JPL de la NASA, accessible sur `ev.caltech.edu`. Il contient plus de 30 000 sessions horodatées. Le second, **NYC 311**, recense les demandes de service municipal de la ville de New York, disponible sur `data.cityofnewyork.us` et mis à jour quotidiennement. Ces deux sources permettent

de tester le modèle dans des contextes contrastés : infrastructure énergétique d'un côté, services urbains de l'autre.

Problématique. Les données réelles obéissent rarement aux hypothèses idéales de la théorie. Les conducteurs de véhicules électriques se présentent plus fréquemment le matin qu'en pleine nuit ; les signalements urbains sont plus nombreux en semaine que le week-end. L'hypothèse d'un taux d'arrivée constant dans le temps, l'hypothèse d'*homogénéité*, se trouve donc souvent mise en défaut.

Dans quelle mesure le processus de Poisson permet-il de modéliser des arrivées réelles dans le temps, et quelles sont ses limites lorsqu'on l'applique à des données urbaines et énergétiques ?

Démarche et objectifs. Pour répondre à cette question, nous adoptons une progression en trois temps, *comprendre, simuler, confronter*, articulée autour de cinq objectifs :

1. maîtriser la théorie du processus de Poisson ;
2. saisir le lien entre arrivées aléatoires, loi exponentielle et compteur ;
3. simuler le processus en Python et en R ;
4. appliquer le modèle à ACN-Data et NYC 311 ;
5. discuter les limites du modèle homogène et les extensions possibles.

Organisation du mémoire. Le **chapitre 1** pose les fondements théoriques. Le **chapitre 2** est consacré à la simulation numérique en R puis en Python. Le **chapitre 3** confronte le modèle aux données ACN-Data. Le **chapitre 4** reproduit cette démarche sur les demandes NYC 311. Enfin, le **chapitre 5** met en regard les deux applications et présente une extension naturelle.

Chapitre 1

Fondements théoriques du processus de Poisson

Ce chapitre présente les bases mathématiques nécessaires à la compréhension du processus de Poisson. Nous commençons par le processus de Bernoulli en temps discret, dont le processus de Poisson est la limite naturelle en temps continu. Cette progression, inspirée de la Lecture 21 et de la Lecture 22 du cours *Introduction to Probability* du MIT (Tsitsiklis et Jaillet), permet de motiver chaque définition et chaque propriété par une intuition concrète.

1.1 Le processus de Bernoulli

1.1.1 Définition et hypothèses

Le *processus de Bernoulli* est le modèle le plus simple d'arrivées aléatoires en temps discret. On considère une suite infinie d'essais indépendants $(X_i)_{i \geq 1}$, où chaque X_i prend la valeur 1 (succès ou arrivée) ou 0 (échec) :

$$\mathbb{P}(X_i = 1) = p, \quad \mathbb{P}(X_i = 0) = 1 - p, \quad 0 < p < 1.$$

Deux hypothèses fondamentales structurent ce modèle :

- **Indépendance** : les variables $X_1, X_2, \dots$ sont mutuellement indépendantes.
- **Homogénéité temporelle** : la probabilité de succès p est identique à chaque slot.

Ce modèle s'applique notamment aux arrivées de clients à un guichet bancaire ou aux requêtes adressées à un serveur informatique.

1.1.2 Interprétation comme processus stochastique

Un processus stochastique peut être abordé de deux façons complémentaires. La première consiste à le voir comme une suite de variables aléatoires $X_1, X_2, \dots$, en s'intéressant à leurs lois marginales et à leurs dépendances. Pour le processus de Bernoulli, l'indépendance implique :

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = p^{\sum x_i} (1-p)^{n-\sum x_i}.$$

La seconde vision consiste à considérer l'espace des trajectoires Ω , c'est-à-dire l'ensemble de toutes les suites infinies de 0 et de 1. On montre alors que la probabilité que tous les essais soient des succès est nulle :

$$\mathbb{P}(X_i = 1 \text{ pour tout } i) = \lim_{n \rightarrow \infty} p^n = 0 \quad (p < 1).$$

1.1.3 Nombre de succès en n essais

Proposition 1.1. *Le nombre de succès $S = X_1 + \dots + X_n$ suit une loi binomiale :*

$$S \sim \text{Bin}(n, p), \quad \mathbb{P}(S = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

De plus, $\mathbb{E}[S] = np$ et $\text{Var}(S) = np(1-p)$.

1.1.4 Temps d'attente avant le premier succès

Proposition 1.2. *Le temps du premier succès $T_1 = \min\{i \geq 1 : X_i = 1\}$ suit une loi géométrique :*

$$T_1 \sim \text{Geo}(p), \quad \mathbb{P}(T_1 = k) = (1-p)^{k-1} p, \quad k = 1, 2, \dots$$

De plus, $\mathbb{E}[T_1] = 1/p$ et $\text{Var}(T_1) = (1-p)/p^2$.

1.1.5 Propriété de redémarrage à neuf

Théorème 1.3 (Redémarrage à neuf). *Soit N un temps d'arrêt défini de façon causale. Le processus $(X_{N+1}, X_{N+2}, \dots)$ est un nouveau processus de Bernoulli de paramètre p , indépendant de $N, X_1, \dots, X_N$.*

Ce résultat s'applique pour $N = n$ (entier fixe) ou $N = T_1$ (premier succès). La condition causale est essentielle : si N est défini par une condition portant sur le futur

(par exemple, le temps juste avant la première occurrence de 1, 1, 1), le redémarrage ne s'applique pas.

1.1.6 Temps de la k -ième arrivée

Proposition 1.4 (Loi de Pascal). *Les temps inter-arrivées $T_1, T_2, \dots$ sont i.i.d. de loi $\text{Geo}(p)$, et le temps $Y_k = T_1 + \dots + T_k$ de la k -ième arrivée suit une loi de Pascal :*

$$\mathbb{P}(Y_k = t) = \binom{t-1}{k-1} p^k (1-p)^{t-k}, \quad t = k, k+1, \dots$$

avec $\mathbb{E}[Y_k] = k/p$ et $\text{Var}(Y_k) = k(1-p)/p^2$.

1.1.7 Fusion et décomposition

Fusion. La superposition de deux processus de Bernoulli indépendants de paramètres p et q produit un processus de Bernoulli de paramètre $p + q - pq$.

Décomposition. Conserver chaque arrivée d'un processus de Bernoulli(p) avec probabilité q donne un processus de Bernoulli(pq). Les deux flux résultants ne sont cependant pas indépendants.

1.2 Du processus de Bernoulli au processus de Poisson

1.2.1 Passage à la limite

Considérons un intervalle $[0, \tau]$ découpé en $n = \tau/\delta$ slots de longueur δ , avec $p = \lambda\delta$ et $np = \lambda\tau$. Quand $\delta \rightarrow 0$, la loi $\text{Bin}(n, p)$ du nombre d'arrivées converge vers une loi de Poisson :

$$\begin{aligned}
\mathbb{P}(N_\tau = k) &= \binom{n}{k} p^k (1-p)^{n-k} \\
&= \underbrace{\frac{n(n-1)\cdots(n-k+1)}{n^k}}_{\rightarrow 1} \cdot \frac{(\lambda\tau)^k}{k!} \cdot \underbrace{\left(1 - \frac{\lambda\tau}{n}\right)^n}_{\rightarrow e^{-\lambda\tau}} \cdot \underbrace{\left(1 - \frac{\lambda\tau}{n}\right)^{-k}}_{\rightarrow 1} \\
&\xrightarrow{n \rightarrow \infty} \frac{(\lambda\tau)^k}{k!} e^{-\lambda\tau}.
\end{aligned}$$

Remarque 1.5. La probabilité qu'un slot contienne deux arrivées ou plus est $O(\delta^2)$, négligeable devant δ quand $\delta \rightarrow 0$. Le processus limite ne produit donc presque sûrement qu'une seule arrivée par instant infinitésimal.

1.3 Définition du processus de Poisson

Définition 1.6 (Processus de Poisson homogène). Un processus $(N(t))_{t \geq 0}$ est un processus de Poisson homogène d'intensité $\lambda > 0$ si :

1. $N(0) = 0$,
2. les accroissements sur des intervalles disjoints sont indépendants,
3. pour tout $0 \leq s < t$: $N(t) - N(s) \sim \mathcal{P}(\lambda(t-s))$.

1.3.1 Probabilités sur un petit intervalle

Pour δ très petit :

$$\mathbb{P}(N(t+\delta) - N(t) = k) = \begin{cases} 1 - \lambda\delta + O(\delta^2) & \text{si } k = 0, \\ \lambda\delta + O(\delta^2) & \text{si } k = 1, \\ O(\delta^2) & \text{si } k \geq 2. \end{cases}$$

1.4 Loi du nombre d'arrivées

Proposition 1.7. Pour tout $t \geq 0$ et tout $k \geq 0$:

$$\mathbb{P}(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}.$$

1.5 Espérance et variance

Proposition 1.8. $\mathbb{E}[N(t)] = \lambda t$ et $\text{Var}(N(t)) = \lambda t$.

Démonstration.

$$\mathbb{E}[N(t)] = \sum_{k=0}^{\infty} k \cdot \frac{(\lambda t)^k e^{-\lambda t}}{k!} = \lambda t \sum_{k=1}^{\infty} \frac{(\lambda t)^{k-1} e^{-\lambda t}}{(k-1)!} = \lambda t.$$

Le calcul de la variance donne de même $\text{Var}(N(t)) = \lambda t$. □

Remarque 1.9. L'égalité $\mathbb{E}[N(t)] = \text{Var}(N(t))$ est la *signature* de la loi de Poisson. Si la variance empirique dépasse notablement la moyenne, on parle de surdispersion, ce qui remet en cause le modèle homogène.

1.6 Temps d'attente avant la première arrivée

Proposition 1.10. $T_1 \sim \text{Exp}(\lambda)$, avec $f_{T_1}(t) = \lambda e^{-\lambda t}$, $t \geq 0$, $\mathbb{E}[T_1] = 1/\lambda$ et $\text{Var}(T_1) = 1/\lambda^2$.

Démonstration. $\mathbb{P}(T_1 > t) = \mathbb{P}(N(t) = 0) = e^{-\lambda t}$, donc $F_{T_1}(t) = 1 - e^{-\lambda t}$. □

1.7 Propriété sans mémoire

Théorème 1.11. Pour tout $s, t \geq 0$: $\mathbb{P}(T_1 > s + t \mid T_1 > s) = \mathbb{P}(T_1 > t)$.

Démonstration. $\frac{\mathbb{P}(T_1 > s + t)}{\mathbb{P}(T_1 > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(T_1 > t)$. □

Propriété de redémarrage à neuf

Observé à partir d'un instant quelconque défini causalement, le processus de Poisson repart à zéro : on voit un nouveau processus de Poisson d'intensité λ , indépendant du passé.

1.8 Temps inter-arrivées

Proposition 1.12. Les temps inter-arrivées $T_1, T_2, T_3, \dots$ sont i.i.d. de loi $\text{Exp}(\lambda)$.

Cela fournit une représentation alternative très utile pour la simulation :

$$N(t) = \max\{n \geq 0 : Y_n \leq t\}, \quad Y_n = T_1 + \cdots + T_n.$$

1.9 Temps de la n -ième arrivée : loi d'Erlang

Proposition 1.13. $Y_n = T_1 + \cdots + T_n$ suit une loi d'Erlang d'ordre n :

$$f_{Y_n}(y) = \frac{\lambda^n y^{n-1} e^{-\lambda y}}{(n-1)!}, \quad y \geq 0, \quad \mathbb{E}[Y_n] = \frac{n}{\lambda}, \quad \text{Var}(Y_n) = \frac{n}{\lambda^2}.$$

1.10 Superposition et amincissement

Proposition 1.14 (Superposition). Si $N_1 \sim PP(\lambda_1)$ et $N_2 \sim PP(\lambda_2)$ sont indépendants, alors $N_1 + N_2 \sim PP(\lambda_1 + \lambda_2)$.

Proposition 1.15 (Amincissement). Si chaque événement d'un $PP(\lambda)$ est conservé avec probabilité p , le flux conservé est un $PP(p\lambda)$ et le flux rejeté est un $PP((1-p)\lambda)$, les deux étant indépendants.

Remarque 1.16. L'amincissement sera utilisé dans le chapitre 4 : filtrer un type de demande spécifique parmi l'ensemble du flux NYC 311 revient à amincir un processus de Poisson avec probabilité p égale à la proportion de ce type de demande.

1.11 Tableau récapitulatif

TABLE 1.1 – Correspondance Bernoulli / Poisson (d'après le cours MIT, Lecture 22)

	Bernoulli	Poisson
Temps d'arrivée	Discret	Continu
Taux d'arrivée	p par essai	λ par unité de temps
Loi du nb d'arrivées	Binomiale $\text{Bin}(n, p)$	Poisson $\mathcal{P}(\lambda t)$
Temps inter-arrivées	Géométrique $\text{Geo}(p)$	Exponentielle $\text{Exp}(\lambda)$
Temps k -ième arrivée	Pascal (ordre k)	Erlang (ordre k)
Passage discret/continu	$p = \lambda\delta$, $np = \lambda\tau$	Limite quand $\delta \rightarrow 0$

1.12 Exemple : la pêche de Poisson

Exemple 1.17. Des poissons sont pêchés selon un $PP(\lambda)$ avec $\lambda = 0,6/\text{heure}$. Règle : pêche de deux heures ; si au moins un poisson, on arrête ; sinon, on continue jusqu'au premier poisson.

1. $\mathbb{P}(\text{plus de 2h}) = e^{-0,6 \times 2} = e^{-1,2}$.
2. $\mathbb{P}(2 < T_1 \leq 5) = e^{-1,2}(1 - e^{-1,8})$.
3. $\mathbb{E}[\text{temps total}] = 2 + e^{-1,2}/0,6$ (par la propriété sans mémoire).
4. $\mathbb{E}[\text{nb poissons}] = 1,2 + e^{-1,2}$.

Conclusion du chapitre

Ce chapitre a établi les fondements théoriques du processus de Poisson : loi $\mathcal{P}(\lambda t)$ pour le compteur $N(t)$, loi $\text{Exp}(\lambda)$ pour les temps inter-arrivées, propriété sans mémoire, loi d'Erlang pour la n -ième arrivée, et propriétés de superposition et d'amincissement. Ces outils seront mis en œuvre dès le chapitre suivant par simulation numérique.

Chapitre 2

Simulation du processus de Poisson

L'objet de ce chapitre est de confronter les résultats théoriques établis au chapitre précédent à des expériences numériques. La simulation joue ici un rôle méthodologique important : elle permet d'observer concrètement le fonctionnement du processus de Poisson, de visualiser sa trajectoire, puis de vérifier empiriquement les résultats fondamentaux obtenus en théorie.

Dans toute cette partie, nous fixons les paramètres suivants :

$$\lambda = 5, \quad \tau = 10, \quad M = 10\,000.$$

Le paramètre λ représente le taux moyen d'arrivée par unité de temps, τ désigne l'horizon d'observation, et M le nombre de répétitions utilisées pour l'étude empirique. Dans ce cadre, le nombre moyen théorique d'arrivées sur l'intervalle $[0, \tau]$ vaut :

$$\lambda\tau = 50.$$

Dans un premier temps, la simulation est menée sous **R**. Une partie analogue sera ensuite développée sous **Python** afin de comparer les deux environnements.

2.1 Simulation en R

2.1.1 Mise en place des paramètres

La première étape consiste à charger les bibliothèques nécessaires et à définir les paramètres de travail. Le package `ggplot2` est utilisé pour la visualisation graphique, tandis que `fitdistrplus` sera utile dans la partie consacrée aux ajustements et aux tests.

Script 01 — Paramètres généraux

```
1 library(ggplot2)
2 library(fitdistrplus)
3
4 set.seed(42)
5 lam <- 5
6 tau <- 10
7 M <- 10000
8
9 cat("Parametres charges :\n")
10 cat("lambda =", lam, "\n")
11 cat("tau =", tau, "\n")
12 cat("lambda*tau =", lam*tau, "arrivees attendues\n")
13 cat("M =", M, "simulations\n")
```

Ce script a trois fonctions. D'abord, il charge les packages utiles. Ensuite, il fixe les valeurs numériques de λ , τ et M . Enfin, il impose une graine aléatoire avec `set.seed(42)`, ce qui permet de reproduire exactement les mêmes résultats si l'on relance la simulation.

Paramètres retenus

$$\lambda = 5, \quad \tau = 10, \quad \lambda\tau = 50, \quad M = 10\,000.$$

Ces paramètres seront conservés dans toute la suite du chapitre.

2.1.2 Génération des temps inter-arrivées

Le processus de Poisson homogène possède une représentation par temps d'attente : les temps inter-arrivées

$$T_1, T_2, T_3, \dots$$

sont indépendants et suivent tous une loi exponentielle de paramètre λ . La fonction `rexp` de R permet précisément de générer de telles variables.

Script 02 — Temps inter-arrivées

```
1 library(ggplot2)
2 library(fitdistrplus)
3
4 set.seed(42)
5 lam <- 5
6 tau <- 10
7
8 inter <- rexp(n = 10 * lam * tau, rate = lam)
9
```

```

10 cat("Nombre de temps generes :", length(inter), "\n")
11 cat("Moyenne observee :", round(mean(inter), 4), "\n")
12 cat("Ecart-type observe :", round(sd(inter), 4), "\n")
13 cat("Valeur theorique :", round(1/lam, 4), "\n")

```

Le choix $n = 10\lambda\tau$ n'a pas de signification théorique profonde : il sert simplement à générer un nombre de temps inter-arrivées largement suffisant pour couvrir l'intervalle $[0, \tau]$.

L'exécution du script conduit aux résultats suivants :

Résultats observés

- nombre de temps générés : 500 ;
- moyenne observée : 0.2209 ;
- écart-type observé : 0.2176 ;
- valeur théorique : $1/\lambda = 0.2$.

La moyenne et l'écart-type empiriques sont proches de la valeur théorique 0.2. Cette première vérification est cohérente avec le fait que, pour une loi exponentielle de paramètre λ ,

$$\mathbb{E}[T_i] = \frac{1}{\lambda}, \quad \text{Var}(T_i) = \frac{1}{\lambda^2}.$$

2.1.3 Construction des instants d'arrivée

Les instants d'arrivée sont obtenus en cumulant les temps inter-arrivées :

$$Y_n = \sum_{i=1}^n T_i.$$

Autrement dit, Y_1 est le temps de la première arrivée, Y_2 le temps de la deuxième, et ainsi de suite.

Script 03 — Instants d'arrivée

```

1 arrivees <- cumsum(inter)
2 arrivees <- arrivees[arrivees <= tau]
3
4 cat("Nombre d'arrivees dans [0, tau] :", length(arrivees), "\n")
5 cat("Valeur theorique E[N(tau)] :", lam * tau, "\n")
6 print(round(arrivees[1:10], 4))

```

La commande `cumsum(inter)` construit les sommes cumulées. La ligne suivante garde uniquement les instants d'arrivée situés avant τ .

Résultats observés

- nombre d'arrivées observé sur $[0, \tau]$: 49 ;
- valeur théorique : $\mathbb{E}[N(\tau)] = 50$;
- les premiers instants observés sont 0.0397, 0.1718, 0.2285, 0.2362, 0.3308, ...

La valeur $N(\tau) = 49$ est très proche de l'espérance théorique 50. Il n'y a là rien d'anormal : une réalisation particulière n'est pas censée être exactement égale à sa moyenne.

2.1.4 Trajectoire du processus

Le compteur du processus est défini par

$$N(t) = \#\{n : Y_n \leq t\}.$$

Cette définition implique que la trajectoire de $N(t)$ est une fonction en escalier : elle reste constante entre deux arrivées, puis augmente d'une unité à chaque nouvel événement.

Script 04 — Trajectoire du processus

```

1 df_traj <- data.frame(
2   t = c(0, arrivees, tau),
3   N = c(0, seq_along(arrivees), length(arrivees))
4 )
5
6 p4 <- ggplot(df_traj, aes(x = t, y = N)) +
7   geom_step(color = "black", linewidth = 0.8) +
8   labs(
9     x = "Temps t",
10    y = "N(t)",
11    title = paste0("Trajectoire du processus de Poisson",
12                  " (lambda=", lam, ", tau=", tau, ")")
13  ) +
14  theme_minimal(base_size = 12)
15
16 print(p4)
17 ggsave("fig_trajetoire_R.pdf", p4, width = 8, height = 3.5)

```

Le tableau `df_traj` rassemble les instants et les niveaux du processus. La fonction `geom_step` de `ggplot2` permet ensuite de représenter la trajectoire en escalier.




FIGURE 2.1 – Trajectoire simulée du processus de Poisson sous R

La figure obtenue met bien en évidence la structure attendue du processus : des paliers horizontaux, séparés par des sauts unitaires.

2.1.5 Distribution empirique de $N(\tau)$

Une seule trajectoire ne suffit pas pour étudier la loi de $N(\tau)$. Il faut répéter l'expérience un grand nombre de fois, puis comparer l'histogramme empirique obtenu à la loi de Poisson théorique.

Script 05 — Distribution de $N(\tau)$

```

1  M <- 10000
2
3  N_sim <- replicate(M, {
4    inter_i <- rexp(n = 10 * lam * tau, rate = lam)
5    arrivees_i <- cumsum(inter_i)
6    sum(arrivees_i <= tau)
7  })
8
9  k_vals <- 0:(2 * lam * tau)
10 df_th <- data.frame(
11   k = k_vals,
12   prob = dpois(k_vals, lambda = lam * tau)
13 )
14
15 p5 <- ggplot() +
16   geom_histogram(
17     data = data.frame(N = N_sim),
18     aes(x = N, y = after_stat(density)),
19     binwidth = 1,
20     fill = "grey75",
21     color = "white"
22   ) +
23   geom_line(
24     data = df_th,
```

```

25     aes(x = k, y = prob),
26     color = "black",
27     linewidth = 0.9
28 ) +
29 labs(
30     x = "N(tau)",
31     y = "Probabilite",
32     title = "Distribution de N(tau) : simulation et loi theorique"
33 ) +
34 theme_minimal(base_size = 12)
35
36 print(p5)
37 ggsave("fig_distribution_R.pdf", p5, width = 8, height = 4)

```

La fonction `replicate` répète 10 000 fois la même procédure de simulation. On obtient ainsi un échantillon empirique de la variable $N(\tau)$. La fonction `dpois` calcule ensuite les probabilités théoriques de la loi de Poisson de paramètre $\lambda\tau$.

Résultats observés

- moyenne simulée : 50.002 ;
- variance simulée : 49.891 ;
- indice de dispersion :

$$I_d = \frac{\text{Var}(N(\tau))}{\mathbb{E}[N(\tau)]} \approx 0.9978.$$




FIGURE 2.2 – Distribution empirique de $N(\tau)$ comparée à la loi de Poisson théorique

La figure met en évidence un excellent accord entre l'histogramme empirique et la courbe théorique. Le fait que la moyenne et la variance soient toutes deux très proches de 50 constitue une signature importante du modèle de Poisson.

2.1.6 Tests statistiques d'adéquation

Les observations graphiques doivent être complétées par des tests statistiques formels. Nous utilisons ici :

- un test de Kolmogorov–Smirnov pour vérifier l'adéquation exponentielle des temps inter-arrivées ;
- un test du chi-deux pour vérifier l'adéquation de $N(\tau)$ à une loi de Poisson.

Script 06 — Tests statistiques

```

1  set.seed(42)
2  inter_test <- rexp(n = 5000, rate = lam)
3
4  ks_res <- ks.test(inter_test, "pexp", rate = lam)
5
6  k_min <- min(N_sim)
7  k_max <- max(N_sim)
8  classes <- k_min:k_max
9
10 obs_counts <- sapply(classes, function(k) sum(N_sim == k))
11 exp_counts <- M * dpois(classes, lambda = lam * tau)
12
13 mask <- exp_counts >= 5
14 obs_r <- obs_counts[mask]
15 exp_r <- exp_counts[mask]
16
17 chi2_res <- chisq.test(obs_r, p = exp_r / sum(exp_r))

```

Le premier test compare l'échantillon `inter_test` à la fonction de répartition de la loi exponentielle de paramètre 5. Le second compare les effectifs observés des valeurs de $N(\tau)$ aux effectifs théoriques attendus sous la loi de Poisson.

Résultats observés

- test de Kolmogorov–Smirnov :

$$D = 0.0108, \quad p\text{-valeur} = 0.6016;$$

- test du chi-deux :

$$\chi^2 = 40.7801, \quad p\text{-valeur} = 0.5245.$$

Dans les deux cas, les p -valeurs sont largement supérieures au seuil usuel de 5%. On ne rejette donc ni l'hypothèse exponentielle pour les temps inter-arrivées, ni l'hypothèse poissonnienne pour $N(\tau)$.

2.1.7 Bilan intermédiaire de la partie R

La simulation sous R confirme de façon satisfaisante les résultats théoriques obtenus au chapitre précédent. Les temps inter-arrivées se comportent comme des variables exponentielles, la trajectoire du compteur a bien une structure en escalier, le nombre d'arrivées suit empiriquement une loi de Poisson, et l'égalité moyenne-variance est observée numériquement.

Cette partie fournit ainsi une validation complète de la simulation sous R, et prépare naturellement la reproduction de la même démarche sous Python.

2.2 Simulation en Python

2.2.1 Mise en place des paramètres

La simulation sous Python repose sur plusieurs bibliothèques standards du calcul scientifique. La bibliothèque `numpy` est utilisée pour les simulations et les calculs numériques, `matplotlib` pour la visualisation graphique, et `scipy.stats` pour les lois de probabilité et les tests statistiques.

Le script suivant charge ces bibliothèques et fixe les paramètres généraux de la simulation.

Script Python 01 — Paramètres généraux

```
1  import numpy as np
2  import pandas as pd
3  import matplotlib.pyplot as plt
4  from scipy.stats import expon, poisson, kstest, chisquare
5
6  # Parametres de la simulation
7  np.random.seed(42)
8
9  lam = 5
10 tau = 10
11 M   = 10000
12
13 print("Parametres charges :")
14 print("lambda =", lam)
15 print("tau =", tau)
16 print("lambda*tau =", lam * tau, "arrivees attendues")
17 print("M =", M, "simulations")
```

Ce script remplit trois fonctions. Il commence par importer les bibliothèques néces-

saires. Il fixe ensuite les valeurs numériques de λ , τ et M . Enfin, il impose une graine aléatoire avec `np.random.seed(42)`, afin de garantir la reproductibilité des résultats.

Paramètres retenus

$$\lambda = 5, \quad \tau = 10, \quad \lambda\tau = 50, \quad M = 10\,000.$$

Ces paramètres seront utilisés dans toute la suite de la simulation sous Python.

2.2.2 Génération des temps inter-arrivées

Dans un processus de Poisson homogène, les temps inter-arrivées

$$T_1, T_2, T_3, \dots$$

sont des variables aléatoires indépendantes et identiquement distribuées suivant une loi exponentielle de paramètre λ .

L'objectif de cette étape est de générer un échantillon de temps inter-arrivées en Python, puis de comparer les statistiques empiriques obtenues aux valeurs théoriques attendues. Avec $\lambda = 5$, la moyenne théorique d'un temps inter-arrivée vaut

$$\mathbb{E}[T_i] = \frac{1}{\lambda} = 0,2,$$

et l'écart-type théorique vaut également $1/\lambda = 0,2$.

Script Python 02 — Temps inter-arrivées

```

1  # Generation des temps inter-arrivees
2  inter = np.random.exponential(scale=1/lam, size=10 * lam * tau)
3
4  print("=== TEMPS INTER-ARRIVEES ===")
5  print("Nombre de temps generes :", len(inter))
6  print("Moyenne observee      :", round(np.mean(inter), 4))
7  print("Valeur theorique 1/lam :", round(1/lam, 4))
8  print("Ecart-type observe   :", round(np.std(inter, ddof=1), 4))
9  print("Valeur theorique 1/lam :", round(1/lam, 4))

```

Résultats observés

- nombre de temps générés : 500 ;
- moyenne observée : 0,2009 ;
- écart-type observé : 0,1948 ;
- valeur théorique : $1/\lambda = 0,2$.

La moyenne empirique vaut 0,2009 et l'écart-type empirique vaut 0,1948, tous deux très proches de la valeur théorique 0,2. On obtient ainsi une première vérification numérique de la loi exponentielle attendue pour les temps inter-arrivées.

2.2.3 Construction des instants d'arrivée

Une fois les temps inter-arrivées générés, les instants d'arrivée s'obtiennent par somme cumulée. Si l'on note $T_1, T_2, T_3, \dots$ les temps inter-arrivées, alors les instants d'arrivée sont définis par

$$Y_1 = T_1, \quad Y_2 = T_1 + T_2, \quad \dots \quad Y_n = \sum_{i=1}^n T_i.$$

Autrement dit, Y_n représente l'instant auquel se produit la n -ième arrivée.

Script Python 03 — Instants d'arrivée

```

1  # Construction des instants d'arrivee par somme cumulee
2  arrivees = np.cumsum(inter)
3
4  # On garde seulement les instants dans [0, tau]
5  arrivees = arrivees[arrivees <= tau]
6
7  print("=== INSTANTS D'ARRIVEE ===")
8  print("Nombre d'arrivees dans [0, tau] :", len(arrivees))
9  print("Valeur theorique E[N(tau)]      :", lam * tau)
10 print("\nLes 10 premiers instants d'arrivee :")
11 print(np.round(arrivees[:10], 4))

```

Résultats observés

- nombre d'arrivées observé sur $[0, \tau]$: 52 ;
- valeur théorique : $\mathbb{E}[N(\tau)] = 50$;
- dix premiers instants observés : 0,0939, 0,6959, 0,9592, 1,1418, 1,1757, ...

La valeur $N(\tau) = 52$ est très proche de l'espérance théorique $\mathbb{E}[N(\tau)] = \lambda\tau = 50$. Une réalisation particulière n'a pas à être exactement égale à sa moyenne — ce résultat est parfaitement cohérent.

2.2.4 Trajectoire du processus

Le compteur du processus de Poisson est défini par

$$N(t) = \#\{n : Y_n \leq t\}.$$

Pour chaque instant t , $N(t)$ compte le nombre d'arrivées survenues avant ou au temps t . La trajectoire de $N(t)$ est donc une fonction en escalier : constante entre deux arrivées consécutives, elle augmente de 1 à chaque nouvel événement.

Script Python 04 — Trajectoire du processus

```

1  # Construction de la trajectoire N(t)
2  t_vals = np.concatenate(([0], arrivees, [tau]))
3  N_vals = np.concatenate(([0], np.arange(1, len(arrivees) + 1),
   ↪   [len(arrivees)]))
4
5  print("=== TRAJECTOIRE N(t) ===")
6  print("Valeur finale N(tau) =", len(arrivees))
7
8  # Trace de la trajectoire
9  plt.figure(figsize=(8, 3.5))
10 plt.step(t_vals, N_vals, where="post", color="black", linewidth=1.0)
11 plt.xlabel("Temps t")
12 plt.ylabel("N(t)")
13 plt.title(f"Trajectoire du processus de Poisson (lambda={lam},
   ↪   tau={tau})")
14 plt.grid(alpha=0.25)
15 plt.tight_layout()
16 plt.savefig("fig_trajectoire_Python.pdf")
17 plt.show()
18
19 print("Figure sauvegardee : fig_trajectoire_Python.pdf")

```

Résultats observés

- valeur finale observée : $N(\tau) = 52$;
- figure sauvegardée : fig_trajectoire_Python.pdf.




FIGURE 2.3 – Trajectoire simulée du processus de Poisson sous Python

La figure présente bien la structure attendue d'un processus de comptage : une fonction

croissante, constante entre deux arrivées, marquée par des sauts unitaires.

2.2.5 Distribution empirique de $N(\tau)$

Une seule trajectoire ne suffit pas pour étudier la loi de $N(\tau)$. On répète donc la simulation $M = 10\,000$ fois, puis on compare la distribution empirique obtenue à la loi de Poisson théorique de paramètre $\lambda\tau = 50$. On calcule également la moyenne empirique, la variance empirique et l'indice de dispersion

$$I_d = \frac{\text{Var}(N(\tau))}{\mathbb{E}[N(\tau)]}.$$

Pour une loi de Poisson, on attend théoriquement

$$\mathbb{E}[N(\tau)] = \text{Var}(N(\tau)) = \lambda\tau = 50.$$

Script Python 05 — Distribution de $N(\tau)$

```

1  # Simulation repetee de N(tau)
2  N_sim = np.array([
3      np.sum(np.cumsum(
4          np.random.exponential(scale=1/lam, size=10 * lam * tau)
5      ) <= tau)
6      for _ in range(M)
7  ])
8
9  # Statistiques empiriques
10 mean_sim      = np.mean(N_sim)
11 var_sim       = np.var(N_sim, ddof=1)
12 dispersion_index = var_sim / mean_sim
13
14 print("=== DISTRIBUTION DE N(tau) ===")
15 print("Moyenne simulee      :", round(mean_sim, 4))
16 print("Variance simulee     :", round(var_sim, 4))
17 print("Indice de dispersion :", round(dispersion_index, 4))
18
19 # Loi theorique
20 k_vals = np.arange(0, 2 * lam * tau + 1)
21 probs_th = poisson.pmf(k_vals, mu=lam * tau)
22
23 # Histogramme + courbe theorique
24 plt.figure(figsize=(8, 4))
25 plt.hist(
26     N_sim,
27     bins=np.arange(N_sim.min(), N_sim.max() + 2) - 0.5,
28     density=True,
29     color="lightgray",

```

```

30     edgecolor="white"
31 )
32 plt.plot(k_vals, probs_th, color="black", linewidth=1.2)
33 plt.xlabel("N(tau)")
34 plt.ylabel("Probabilite")
35 plt.title("Distribution de N(tau) : simulation et loi theorique")
36 plt.tight_layout()
37 plt.savefig("fig_distribution_Python.pdf")
38 plt.show()
39
40 print("Figure sauvegardee : fig_distribution_Python.pdf")

```

Résultats observés

- moyenne simulée : 49,9128;
- variance simulée : 50,2194;
- indice de dispersion :

$$I_d \approx 1,0061;$$

- figure sauvegardée : fig_distribution_Python.pdf.




FIGURE 2.4 – Distribution empirique de $N(\tau)$ comparée à la loi de Poisson théorique sous Python

La moyenne empirique vaut 49,91 et la variance empirique vaut 50,22, toutes deux très proches des valeurs théoriques $\mathbb{E}[N(\tau)] = \text{Var}(N(\tau)) = 50$. L'indice de dispersion $I_d \approx 1$ constitue une vérification numérique convaincante de la structure poissonnienne de $N(\tau)$.

2.2.6 Tests statistiques d'adéquation

Les résultats graphiques et les statistiques descriptives sont complétés par deux tests formels :

- un test de Kolmogorov–Smirnov sur les temps inter-arrivées ($H_0 : T_i \sim \text{Exp}(\lambda)$) ;
- un test du chi-deux sur $N(\tau)$ ($H_0 : N(\tau) \sim \mathcal{P}(\lambda\tau)$).

Script Python 06 — Tests statistiques

```

1  # =====
2  # TEST 1 : Kolmogorov-Smirnov sur les temps inter-arrivees
3  # =====
4  np.random.seed(42)
5  inter_test = np.random.exponential(scale=1/lam, size=5000)
6
7  ks_stat, ks_pvalue = kstest(inter_test, 'expon', args=(0, 1/lam))
8
9  print("=== TEST 1 : KOLMOGOROV-SMIRNOV ===")
10 print("Hypothese H0 : les Ti suivent une Exp(lambda=5)\n")
11 print("Statistique D :", round(ks_stat, 4))
12 print("p-valeur      :", round(ks_pvalue, 4))
13
14 if ks_pvalue > 0.05:
15     print("Conclusion      : Ne pas rejeter H0 - Exp(lambda) adequat")
16 else:
17     print("Conclusion      : Rejeter H0")
18
19 # =====
20 # TEST 2 : Chi-deux sur N(tau)
21 # =====
22 print("\n=== TEST 2 : CHI-DEUX ===")
23 print("Hypothese H0 : N(tau) suit une Poisson(lambda*tau=50)\n")
24
25 classes = np.arange(N_sim.min(), N_sim.max() + 1)
26 obs_counts = np.array([np.sum(N_sim == k) for k in classes])
27 exp_counts = M * poisson.pmf(classes, mu=lam * tau)
28
29 mask = exp_counts >= 5
30 obs_r = obs_counts[mask]
31 exp_r = exp_counts[mask]
32 exp_r = exp_r * (obs_r.sum() / exp_r.sum())
33
34 chi2_stat, chi2_pvalue = chisquare(f_obs=obs_r, f_exp=exp_r)
35
36 print("Statistique chi2 :", round(chi2_stat, 4))
37 print("p-valeur      :", round(chi2_pvalue, 4))
38
39 if chi2_pvalue > 0.05:
40     print("Conclusion : Ne pas rejeter H0 - Poisson(50) adequat")
41 else:

```

```
42 | print("Conclusion : Rejeter H0")
```

Le premier test compare l'échantillon `inter_test` à la loi exponentielle de paramètre 5. Le second compare les effectifs observés des valeurs de $N(\tau)$ aux effectifs théoriques attendus sous la loi de Poisson.

Résultats observés

— test de Kolmogorov–Smirnov :

$$D = 0,0088, \quad p\text{-valeur} = 0,8323;$$

— test du chi-deux :

$$\chi^2 = 39,4268, \quad p\text{-valeur} = 0,5845.$$

Les deux p -valeurs sont très largement supérieures à 5 % : on ne rejette aucune des deux hypothèses d'adéquation.

Le test de Kolmogorov–Smirnov donne une p -valeur de 0,8323, largement supérieure au seuil usuel de 5 %. On ne rejette donc pas l'hypothèse selon laquelle les temps inter-arrivées suivent une loi exponentielle de paramètre 5. Le test du chi-deux donne quant à lui une p -valeur de 0,5845, elle aussi largement supérieure à 0,05. On ne rejette donc pas l'hypothèse selon laquelle $N(\tau)$ suit une loi de Poisson de paramètre 50. Ces deux tests confirment, de manière formelle, la cohérence de la simulation avec les résultats théoriques du processus de Poisson homogène.

2.2.7 Bilan intermédiaire de la partie Python

La simulation sous Python confirme de façon très satisfaisante les propriétés essentielles du processus de Poisson homogène. Les temps inter-arrivées simulés sont compatibles avec une loi exponentielle, la trajectoire du compteur $N(t)$ possède bien une structure en escalier, et la distribution empirique de $N(\tau)$ est très proche de la loi de Poisson théorique de paramètre $\lambda\tau$. De plus, la moyenne et la variance observées sont toutes deux très proches de 50, ce qui correspond à la signature attendue d'un modèle de Poisson. Enfin, les tests statistiques formels ne conduisent pas à rejeter les hypothèses d'adéquation exponentielle et poissonnienne.

L'ensemble de ces résultats montre que la simulation Python reproduit correctement le comportement théorique du processus de Poisson homogène.

Conclusion du chapitre

Ce chapitre avait un objectif concret : voir si les propriétés du processus de Poisson, établies au chapitre précédent sur le papier, tiennent vraiment l'épreuve de la simulation numérique. La réponse est oui, et elle est confirmée deux fois plutôt qu'une, indépendamment sous R et sous Python.

Dans les deux cas, les mêmes conclusions ressortent. Les temps inter-arrivées simulés se comportent comme des variables exponentielles ; la trajectoire du compteur $N(t)$ est bien une fonction en escalier ; et la variable $N(\tau)$ suit une loi de Poisson de paramètre $\lambda\tau$. Surtout, la relation fondamentale

$$\mathbb{E}[N(\tau)] = \text{Var}(N(\tau)) = \lambda\tau$$

est retrouvée numériquement à chaque fois : la moyenne et la variance simulées gravitent toutes deux autour de 50, et l'indice de dispersion I_d reste au voisinage de 1. Les tests de Kolmogorov–Smirnov et du chi-deux ne conduisent à rejeter aucune hypothèse d'adéquation, que ce soit pour les inter-arrivées ou pour le compteur.

Il est rassurant, mais pas étonnant, que R et Python aboutissent aux mêmes conclusions. Les légères différences numériques entre les deux implémentations, dues aux générateurs pseudo-aléatoires distincts de chaque langage, ne remettent pas en cause la concordance des résultats. Ce qui est plus intéressant, c'est ce que la comparaison révèle sur les deux outils eux-mêmes.

R se distingue par sa concision pour l'analyse statistique : quelques lignes suffisent pour générer, ajuster et tester, et son écosystème, en particulier `ggplot2` et `fitdistrplus`, est particulièrement adapté à l'exploration rapide de distributions. Python, de son côté, offre une plus grande souplesse pour structurer le code, manipuler des jeux de données hétérogènes et chaîner les étapes d'un pipeline d'analyse. Les bibliothèques `pandas`, `numpy`, `scipy` et `matplotlib` forment un cadre cohérent qui va du chargement brut des données jusqu'à la visualisation finale, ce qui correspond exactement à la démarche des chapitres suivants, où il faudra charger des fichiers CSV de plusieurs dizaines de milliers de lignes, nettoyer les horodatages, agréger les comptes et tester l'adéquation au modèle de Poisson.

C'est pour cette raison que la suite de ce TER, l'analyse des données réelles ACN-Data et NYC 311 aux chapitres 3 et 4, sera conduite exclusivement sous **Python**. Ce choix n'est pas un jugement de valeur sur R, dont les capacités statistiques restent entièrement pertinentes pour ce type d'analyse, mais une décision pragmatique dictée par la nature des données à traiter : des datasets publics volumineux, au format tabulé, nécessitant un prétraitement non trivial avant même d'aborder la modélisation. Par

ailleurs, Python bénéficie aujourd'hui d'une notoriété considérable dans la communauté scientifique et les milieux professionnels liés à l'analyse de données, ce qui en fait un choix naturel pour un travail destiné à s'inscrire dans des pratiques modernes et reproductibles.

Ce qui vient d'être fait ici, estimer λ , comparer des distributions, calculer I_d , appliquer un test KS, constitue précisément la boîte à outils des chapitres suivants. Mais dans les chapitres 3 et 4, les données ne seront plus artificielles : elles proviendront de situations réelles où l'hypothèse d'homogénéité ne va plus de soi. C'est là que le modèle sera véritablement mis à l'épreuve.

Chapitre 3

Application aux arrivées de sessions de recharge électrique

3.1 Contexte énergétique et mobilité électrique

La transition énergétique constitue l'un des enjeux majeurs des prochaines décennies. Face à la montée des préoccupations environnementales et aux objectifs de réduction des émissions de gaz à effet de serre, le véhicule électrique s'est progressivement imposé comme l'une des réponses les plus concrètes au défi de la décarbonation des transports. Cette dynamique s'accompagne d'un déploiement rapide des infrastructures de recharge, aussi bien sur les lieux de travail que dans les espaces publics ou commerciaux.

Ce développement soulève cependant plusieurs questions opérationnelles. Pour les gestionnaires d'infrastructures, il ne suffit pas d'installer des bornes de recharge : il faut encore anticiper la demande, dimensionner correctement le nombre de points de charge disponibles et mieux comprendre les moments où la sollicitation du réseau est la plus forte. Ces questions conduisent naturellement à s'intéresser au flux d'arrivées des véhicules, c'est-à-dire au rythme auquel les conducteurs se présentent pour commencer une session de recharge.

Dans ce cadre, le processus de Poisson constitue un modèle de référence particulièrement naturel. Sous certaines hypothèses, notamment une relative indépendance des arrivées et un taux moyen approximativement stable sur une plage horaire donnée, le nombre d'arrivées observées pendant un intervalle de temps peut être modélisé par une loi de Poisson de paramètre $\lambda\tau$, où λ désigne le taux moyen d'arrivée par unité de temps. L'intérêt de ce modèle est double : il fournit une description probabiliste simple du phénomène, et il permet de disposer d'un cadre de comparaison pour l'analyse de données réelles.

L'application développée dans ce chapitre s'appuie sur le jeu de données **ACN-Data**, et plus précisément sur le site `office_01 / Parking_Lot_01`. Ce site correspond à un parking de bureau équipé de bornes de recharge, où les sessions sont initiées au cours de la journée par des usagers appartenant à un contexte relativement homogène. Ce cadre d'étude est particulièrement intéressant, car il permet d'examiner dans quelle mesure les arrivées de sessions peuvent être approximées par un processus de Poisson homogène.

Dans la suite du chapitre, les instants de début de session seront extraits, agrégés sous forme de comptes horaires, puis analysés statistiquement. L'objectif sera d'estimer le taux moyen d'arrivée, de comparer moyenne et variance des comptes, et d'évaluer la pertinence du modèle de Poisson pour décrire les arrivées observées sur ce site.

3.2 Présentation du dataset ACN-Data

Le jeu de données **ACN-Data** (*Adaptive Charging Network Data*) est un ensemble de données publiques consacré aux sessions de recharge de véhicules électriques en environnement professionnel. Il a été constitué et mis à disposition par le California Institute of Technology (Caltech) afin de fournir un support réel à la modélisation et à l'analyse statistique des comportements de recharge [6].

Les données sont organisées par site, chaque session de recharge étant enregistrée individuellement avec un horodatage précis. Cette structure permet de reconstituer une base temporelle complète des arrivées, ce qui est particulièrement adapté à une étude en termes de processus de comptage.

Pour cette étude, le site retenu est `office_01 / Parking_Lot_01`. Il s'agit d'un parking de bureau équipé de **8 bornes de recharge** distinctes, dont les identifiants vont de 1633 à 1640. Ce contexte, marqué par une population d'usagers relativement homogène et des plages d'utilisation quotidiennes assez prévisibles, constitue un cadre pertinent pour tester, dans un premier temps, la plausibilité d'un processus de Poisson homogène.

Le dataframe consolidé construit à partir de ce site contient au total **1 474 sessions**, couvrant la période du 25 mars 2019 au 1^{er} décembre 2020, soit environ 617 jours. La répartition annuelle fait apparaître 950 sessions en 2019 contre 524 en 2020. Cette baisse marquée s'explique très probablement par la perturbation des habitudes de déplacement liée à la pandémie de COVID-19 à partir du mois de mars 2020. Elle se manifeste nettement dans les comptes mensuels : alors que les mois de septembre à décembre 2019 oscillaient entre 122 et 162 sessions, le mois d'avril 2020 n'en compte plus que 17.

Afin d'éviter de mélanger deux régimes de fonctionnement très différents, l'analyse

statistique sera donc restreinte à la période antérieure au 1^{er} mars 2020, qui correspond à un fonctionnement plus stable et plus représentatif du site.

Après consolidation, le dataframe utilisé dans cette étude contient notamment les variables suivantes :

- **file_name** : nom du fichier source correspondant à la session ;
- **session_start** : instant de début de la session, utilisé comme instant d'arrivée Y_k dans le modèle de Poisson ;
- **year, month, day, hour, date** : variables temporelles dérivées, utiles pour l'agrégation et l'analyse des comptes.

Le tableau 3.1 présente les cinq premières observations du dataframe, illustrant la structure concrète des données utilisées.

TABLE 3.1 – Aperçu des premières lignes du dataframe ACN-Data (site office_01 / Parking_Lot_01)

	session_start	year	month	day	hour	date
0	2019-03-25 16 :24 :42	2019	3	25	16	2019-03-25
1	2019-03-25 17 :19 :26	2019	3	25	17	2019-03-25
2	2019-03-25 21 :27 :32	2019	3	25	21	2019-03-25
3	2019-03-26 18 :33 :56	2019	3	26	18	2019-03-26
4	2019-03-27 18 :28 :00	2019	3	27	18	2019-03-27

La variable centrale de toute l'étude est **session_start**. Dans le cadre du modèle, elle joue le rôle des instants d'arrivée $Y_1, Y_2, \dots, Y_n$, à partir desquels seront construits les comptes observés et les temps inter-arrivées. Les sections suivantes s'appuieront donc exclusivement sur cette variable pour construire les comptes, estimer le taux λ et évaluer l'adéquation du modèle aux données observées.

3.3 Définition de l'événement étudié

Dans le cadre de l'application du processus de Poisson à des données réelles, la première étape consiste à identifier avec précision ce que l'on appelle un *événement*. Ce choix est essentiel, car il détermine directement la nature du compteur $N(t)$ et, par conséquent, l'interprétation de l'ensemble des résultats statistiques qui suivront.

Dans cette étude, l'événement retenu est le **début d'une session de recharge**, c'est-à-dire l'instant auquel un véhicule électrique se connecte à une borne du parking

`office_01 / Parking_Lot_01`. Chaque connexion constitue donc une arrivée au sens du modèle, indépendamment de la durée effective de la session, de l'énergie consommée ou encore de la borne utilisée.

Ce choix est naturel du point de vue du processus de Poisson. En effet, un tel modèle vise à représenter des événements ponctuels, datés, apparaissant au cours du temps. Or, dans le contexte d'une infrastructure de recharge, le début d'une session correspond précisément à un instant observable et horodaté, qui peut être interprété comme une arrivée dans le système.

Formellement, si l'on note

$$Y_1 < Y_2 < \dots < Y_n$$

les instants successifs de début de session sur la période d'observation $[0, \tau]$, alors le compteur

$$N(t) = \#\{k : Y_k \leq t\}$$

représente le nombre de sessions de recharge initiées entre l'instant initial et l'instant t . Le processus $(N(t))_{t \geq 0}$ désigne donc ici le nombre cumulé de débuts de sessions observés au cours du temps. Dans les données, ces instants d'arrivée sont repérés par la variable `session_start`, qui joue ainsi directement le rôle des instants $Y_1, Y_2, \dots, Y_n$ du modèle théorique présenté au chapitre 1.

Ce choix de définition présente plusieurs avantages. D'une part, il s'appuie directement sur une variable disponible dans le jeu de données, sans nécessiter de reconstruction supplémentaire. D'autre part, il correspond à la grandeur la plus pertinente d'un point de vue opérationnel : ce qui importe ici est le rythme auquel les conducteurs se présentent aux bornes, c'est-à-dire le flux d'arrivée dans l'infrastructure, plutôt que les caractéristiques internes de chaque session.

Il convient toutefois de noter que cette définition agrège les arrivées sur l'ensemble des **8 bornes** du site. Le compteur $N(t)$ ne distingue donc pas quelle borne est sollicitée à chaque instant : il recense toutes les connexions, toutes bornes confondues. Cette agrégation est cohérente avec la propriété de **superposition** rappelée au chapitre 1 : si chaque borne génère indépendamment un flux poissonien d'intensité λ_i , alors le flux global reste poissonien, avec une intensité

$$\lambda = \sum_{i=1}^8 \lambda_i.$$

Deux représentations complémentaires peuvent alors être envisagées pour l'analyse. D'une part, on peut travailler directement sur les instants d'arrivée (Y_k) , puis sur les

temps inter-arrivées

$$T_k = Y_k - Y_{k-1}, \quad k \geq 2.$$

Si le modèle de Poisson homogène est pertinent, ces temps inter-arrivées doivent être approximativement distribués selon une loi exponentielle de paramètre λ .

D'autre part, et c'est l'approche principale retenue dans cette partie, on peut considérer des **comptes agrégés** sur des intervalles de temps fixes. On notera ainsi

$$X_i = \text{nombre de sessions commencées pendant l'heure } i.$$

Le choix d'une agrégation horaire est particulièrement adapté au contexte d'un parking de bureau : il permet de mettre en évidence la dynamique journalière des arrivées, tout en conservant une granularité suffisamment fine pour tester la pertinence du modèle de Poisson.

Ainsi, l'événement étudié dans cette application n'est ni la durée de recharge, ni l'énergie consommée, ni la fin de la session, mais uniquement

le début d'une session de recharge.

C'est cet événement qui sera interprété comme une arrivée dans le système, puis utilisé pour construire les comptes, estimer le taux moyen d'arrivée λ et évaluer l'adéquation du modèle de Poisson aux données observées.

3.4 Préparation des données

Avant toute analyse statistique, le jeu de données brut doit être préparé de manière à construire une base cohérente avec les hypothèses du modèle et avec l'objectif de l'étude. Cette phase de prétraitement est essentielle : elle permet d'éliminer les observations qui relèvent de régimes de fonctionnement très différents et de restreindre l'analyse à une période suffisamment homogène, compatible avec l'hypothèse d'un taux d'arrivée approximativement constant.

Le dataframe consolidé initial contient **1 474 sessions** et couvre la période allant du **25 mars 2019** au **1^{er} décembre 2020**. La variable `session_start`, convertie au format date-heure, constitue le point de départ de toute la préparation. C'est à partir d'elle que sont dérivées les variables calendaires utiles à l'analyse : année, mois, jour, heure, date civile et jour de la semaine. Deux filtres successifs sont ensuite appliqués.

Filtre 1 : restriction aux jours ouvrés. Le site étudié est un parking de bureau dont l'activité est avant tout liée aux déplacements professionnels. L'exploration préliminaire a mis en évidence une asymétrie très marquée entre les jours de semaine et le week-end : on ne dénombre que **17 sessions** le samedi et le dimanche réunis sur l'ensemble de la période. Cette absence quasi totale d'activité ne reflète pas un phénomène aléatoire mais une fermeture structurelle du site. L'inclure introduirait artificiellement des périodes à zéro arrivée incompatibles avec l'hypothèse d'homogénéité. On restreint donc l'analyse aux **jours ouvrés** (lundi à vendredi), ce qui ramène le nombre de sessions à **1 457**.

Filtre 2 : exclusion de la période COVID. La répartition mensuelle des sessions révèle une rupture brutale à partir de mars 2020. Alors que les mois de septembre 2019 à février 2020 affichent des comptes stables, compris entre 122 et 162 sessions, le mois d'avril 2020 n'en recense plus que 17. Cette chute s'explique par les mesures de confinement et le recours massif au télétravail liés à la pandémie de COVID-19. Un tel changement de régime invalide l'hypothèse d'un taux d'arrivée stable dans le temps. On exclut donc toutes les sessions postérieures au **1^{er} mars 2020**, ce qui porte le nombre de sessions retenues à **1 218**.

Jeu de données final. La période effectivement retenue s'étend du **25 mars 2019** au **28 février 2020**, soit **340 jours**. La répartition des sessions selon les jours de la semaine et selon les mois est présentée dans les tableaux 3.2 et 3.3.

TABLE 3.2 – Répartition des sessions par jour de la semaine après filtrage

Jour de la semaine	Nombre de sessions
Lundi	261
Mardi	192
Mercredi	220
Jeudi	257
Vendredi	288
Total	1 218

TABLE 3.3 – Répartition mensuelle des sessions après filtrage

Période	Nombre de sessions
Mars 2019	10
Avril 2019	73
Mai 2019	61
Juin 2019	27
Juillet 2019	71
Août 2019	129
Septembre 2019	142
Octobre 2019	162
Novembre 2019	122
Décembre 2019	143
Janvier 2020	141
Février 2020	137
Total	1 218

Le tableau 3.2 met déjà en évidence une variabilité selon le jour de la semaine, avec un niveau d'activité plus élevé le vendredi (288 sessions) et plus faible le mardi (192). Cette observation suggère que l'hypothèse d'homogénéité parfaite devra être examinée avec prudence dans les sections suivantes.

Le tableau 3.3 révèle quant à lui une montée en charge sensible à partir de l'été 2019. Le mois de mars ne compte que 10 sessions, ce qui s'explique par le fait que le site n'est pleinement opérationnel qu'à partir d'avril. On observe ensuite un niveau d'activité relativement soutenu et stable entre septembre 2019 et février 2020, avec des comptes oscillant entre 122 et 162 sessions. Cette stabilité confirme l'intérêt du filtrage effectué : la période retenue constitue un compromis raisonnable entre volume de données suffisant et homogénéité relative du fonctionnement du site.

Au terme de cette préparation, le dataframe final est restreint aux sessions observées les jours ouvrés, antérieures à la rupture de mars 2020, avec toutes les variables temporelles prêtes pour l'agrégation. C'est sur cette base nettoyée que seront construits, dans la section suivante, les comptes horaires utilisés pour l'estimation du taux d'arrivée λ et

l'évaluation du modèle de Poisson homogène.

3.5 Construction des comptes journaliers

La construction des comptes constitue l'étape centrale du passage des données brutes à l'analyse statistique. Elle consiste à agréger les instants d'arrivée en un nombre d'événements observés par unité de temps.

Dans un premier temps, une agrégation horaire a été envisagée. Elle a toutefois fait apparaître une proportion très importante de zéros, y compris après restriction aux heures d'ouverture, ce qui rendait l'interprétation des comptes plus délicate. Pour cette raison, on retient ici une **agrégation journalière**, mieux adaptée au rythme d'activité du site et plus facile à interpréter statistiquement.

Pour chaque jour ouvré de la période retenue, on définit ainsi

$$X_i = \text{nombre de sessions de recharge commencées le jour } i.$$

Cette variable compte le nombre total d'arrivées observées au cours d'une journée de fonctionnement du parking.

Sur les **223 jours ouvrés** de la période retenue, les comptes journaliers X_i varient de **1** à **15** sessions par jour. Le tableau 3.4 présente la distribution complète des valeurs observées.

TABLE 3.4 – Distribution des comptes journaliers X_i

Nombre de sessions	Nombre de jours
1	16
2	13
3	25
4	46
5	22
6	28
7	26
8	20
9	12
10	4
11	1
12	2
13	3
15	5
Total	223

On observe que les valeurs les plus fréquentes se situent entre 3 et 8 sessions par jour, avec un maximum de fréquence pour 4 sessions (**46 jours**). Les valeurs extrêmes, 1 session ou plus de 10 sessions par jour, restent relativement rares. La série obtenue est donc centrée autour d'un niveau d'activité modéré, sans être dominée par des valeurs exceptionnelles. C'est sur cette série que reposeront l'estimation du taux moyen d'arrivée, l'étude de la dispersion des comptes et la comparaison avec le modèle de Poisson.

3.6 Estimation du taux d'arrivée

Le paramètre central du processus de Poisson homogène est le **taux d'arrivée** λ , qui représente le nombre moyen d'arrivées par unité de temps. Son estimation à partir des données observées est une étape indispensable avant toute comparaison avec le modèle théorique.

Estimateur retenu. L'estimateur naturel de λ est la **moyenne empirique** des comptes journaliers. Pour une loi de Poisson, cet estimateur coïncide avec l'estimateur du maximum de vraisemblance et possède de bonnes propriétés statistiques. Si l'on dispose de n jours d'observation avec des comptes $X_1, X_2, \dots, X_n$, il est défini par

$$\hat{\lambda} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Application aux données. Sur les $n = 223$ jours ouvrés de la période retenue, le nombre total de sessions observées est de 1 218. On obtient ainsi :

$$\hat{\lambda} = \frac{1\,218}{223} = 5,4619 \text{ sessions par jour.}$$

Autrement dit, en moyenne, un peu plus de **5 sessions de recharge** sont initiées chaque jour ouvré sur le site `office_01 / Parking_Lot_01`.

Interprétation. Cette valeur $\hat{\lambda} = 5,4619$ constitue le paramètre de référence pour toute la suite de l'analyse. Sous l'hypothèse d'un processus de Poisson homogène de taux $\lambda = \hat{\lambda}$, les comptes journaliers X_i devraient être approximativement distribués selon une loi $\mathcal{P}(5,4619)$, avec en particulier

$$\mathbb{E}[X_i] = \text{Var}(X_i) = \hat{\lambda} = 5,4619.$$

La confrontation entre cette valeur théorique et les statistiques empiriques observées fera l'objet de la section suivante.

3.7 Analyse descriptive

Avant d'ajuster formellement le modèle de Poisson, on procède à une analyse descriptive des comptes journaliers X_i . Cette étape permet d'obtenir une première vision d'ensemble du comportement du flux d'arrivées et d'identifier d'éventuelles caractéristiques incompatibles avec les hypothèses du modèle.


Statistiques descriptives. Les principales statistiques des comptes journaliers sont résumées dans le tableau 3.5.

TABLE 3.5 – Statistiques descriptives des comptes journaliers X_i

Indicateur	Valeur
Nombre de jours n	223
Minimum	1
Maximum	15
Moyenne $\hat{\lambda}$	5,4619
Médiane	5,0000
Variance s_X^2	8,5650
Écart-type s_X	2,9266
Indice de dispersion I_d	1,5681

La moyenne et la médiane sont proches (5,46 contre 5,00), ce qui suggère que la distribution n'est pas fortement asymétrique autour de sa valeur centrale. L'écart-type de 2,93 traduit toutefois une variabilité non négligeable d'un jour à l'autre.

Série temporelle. La figure 3.1 représente l'évolution des comptes journaliers sur l'ensemble de la période retenue.

**FIGURE 3.1** – Série temporelle des comptes journaliers de sessions de recharge — site office_01 / Parking_Lot_01. La ligne rouge représente la moyenne estimée $\hat{\lambda} = 5,46$.

La courbe présente une variabilité notable d'un jour à l'autre, avec des oscillations fréquentes autour de la moyenne. On distingue une phase de montée en charge progressive entre mars et août 2019, suivie d'un niveau d'activité plus élevé et globalement plus soutenu entre septembre 2019 et février 2020. Quelques pics ponctuels, notamment en novembre 2019 et janvier 2020, avec des valeurs atteignant ou dépassant 13 sessions,

s'écarteraient toutefois de ce régime moyen. Ces épisodes contribuent à accroître la variance empirique au-delà de la moyenne, ce qui se traduit par un indice de dispersion supérieur à 1.

Distribution empirique. La figure 3.2 compare la distribution empirique des comptes journaliers à la loi de Poisson théorique de paramètre $\hat{\lambda} = 5,46$.




FIGURE 3.2 – Distribution empirique des comptes journaliers X_i (barres bleues) comparée à la loi $\mathcal{P}(5,46)$ (courbe rouge).

La comparaison visuelle révèle un décalage entre la distribution observée et la courbe théorique. D'une part, la distribution empirique présente un pic plus prononcé pour certaines petites et moyennes valeurs, notamment autour de 4 sessions, que ne le prévoit la loi de Poisson. D'autre part, la queue droite de la distribution observée paraît plus épaisse que celle du modèle : les valeurs élevées, supérieures à 10 sessions par jour, semblent un peu plus fréquentes dans les données que ce que prédit $\mathcal{P}(5,46)$.

Ces observations sont cohérentes avec la surdispersion déjà signalée : $I_d = 1,5681 > 1$. Elles suggèrent que le modèle de Poisson homogène rend compte de l'ordre de grandeur moyen du flux d'arrivées, mais sous-estime sa variabilité réelle. L'ajustement formel du modèle et les tests statistiques associés feront l'objet de la section suivante.

3.8 Ajustement du modèle de Poisson homogène

Après avoir estimé le taux moyen d'arrivée $\hat{\lambda} = 5,4619$ et examiné les principales caractéristiques descriptives des comptes journaliers, on peut maintenant confronter formellement les données au modèle de Poisson homogène. Cette confrontation s'appuie sur deux approches complémentaires : une comparaison des fréquences observées et attendues, et un test d'ajustement du chi-deux.

Sous l'hypothèse nulle

$$H_0 : X_i \sim \mathcal{P}(\hat{\lambda}), \quad \hat{\lambda} = 5,4619,$$

les comptes journaliers observés devraient être compatibles avec une loi de Poisson de paramètre 5,4619.

Comparaison des fréquences observées et attendues. Le tableau 3.6 compare, pour les principales valeurs des comptes journaliers, les effectifs observés aux effectifs attendus sous le modèle $\mathcal{P}(5,4619)$.

TABLE 3.6 – Fréquences observées et attendues sous le modèle $\mathcal{P}(5,46)$

Valeur	Observé	Attendu	Différence
1	16	5,06	+10,94
2	13	13,82	−0,82
3	25	25,16	−0,16
4	46	34,35	+11,65
5	22	37,53	−15,53
6	28	34,16	−6,16
7	26	26,65	−0,65
8	20	18,20	+1,80
9	12	11,04	+0,96
10	4	6,03	−2,03

Plusieurs écarts apparaissent clairement. Le modèle sous-estime fortement le nombre de jours avec 1 session (+10,94) et avec 4 sessions (+11,65), tandis qu'il surestime les effectifs autour de 5 sessions (−15,53). La distribution empirique ne présente donc pas simplement une dispersion plus grande que la loi de Poisson théorique : elle adopte aussi une forme différente, avec des concentrations locales plus marquées que prévu.

Test du chi-deux d'adéquation. Pour quantifier cet écart de manière formelle, on applique un test d'ajustement du chi-deux. Afin de respecter les conditions d'application du test, seules les classes dont l'effectif théorique attendu est suffisant sont retenues dans le calcul final. Au total, **10 classes** sont conservées, et les effectifs attendus correspondants sont renormalisés sur cet ensemble de classes.

Le test conduit alors aux résultats suivants :

$$\chi^2 = 36,1493, \quad \text{ddl} = 8, \quad p\text{-valeur} < 0,001.$$

La p -valeur obtenue est extrêmement faible. On rejette donc très nettement H_0 au seuil de 5 % : le modèle de Poisson homogène n'est pas statistiquement compatible avec la distribution observée des comptes journaliers.

Interprétation. Ce résultat confirme et prolonge ce que suggéraient déjà l'analyse descriptive et l'indice de dispersion $I_d = 1,5681 > 1$: le modèle de Poisson homogène ne rend pas compte de manière satisfaisante de la distribution des comptes journaliers.

Deux raisons principales peuvent expliquer cet écart. D'une part, le taux d'arrivée n'est probablement pas constant dans le temps : il peut varier selon le jour de la semaine, la période de l'année ou le niveau d'activité général du site. D'autre part, les arrivées présentent une variabilité plus forte que celle imposée par le modèle de Poisson, ce qui se traduit par la surdispersion observée.

Malgré cette limite, le modèle de Poisson homogène conserve un intérêt réel comme **modèle de référence** et comme outil de première approximation du flux moyen d'arrivées. En revanche, il ne suffit pas à décrire toute la variabilité des données observées. Cette limite conduira, dans la suite du travail, à discuter des extensions naturelles du modèle, en particulier le processus de Poisson non homogène, qui sera abordé au chapitre 5.

3.9 Analyse des temps inter-arrivées

L'analyse des comptes journaliers a conduit à rejeter le modèle de Poisson homogène. On complète cette étude par une analyse des **temps inter-arrivées**, qui constitue une seconde approche, indépendante et complémentaire, pour évaluer la pertinence du modèle. Rappelons que, pour un processus de Poisson homogène d'intensité λ , les temps inter-arrivées $T_k = Y_k - Y_{k-1}$ doivent être indépendants et identiquement distribués selon une loi $\text{Exp}(\lambda)$.

Calcul des temps inter-arrivées. Les temps inter-arrivées sont calculés comme les différences successives entre les instants de début de session ordonnés chronologiquement. Sur les 1 218 sessions de la période retenue, on obtient 1 217 temps inter-arrivées. Les grands intervalles supérieurs à 3 jours, qui correspondent aux coupures structurelles du week-end ou aux jours fériés, sont exclus de l'analyse, car ils ne reflètent pas un

phénomène aléatoire mais une absence planifiée d'activité. Après ce filtrage, **1 213 inter-arrivées** sont retenues.

Les statistiques principales sont les suivantes :

TABLE 3.7 – Statistiques des temps inter-arrivées (après filtrage)

Indicateur	Valeur (jours)
Nombre d'inter-arrivées retenues	1 213
Minimum	0,0000
Maximum	2,9155
Moyenne observée $\bar{T}$	0,2547
Valeur théorique $1/\hat{\lambda}$	0,1831
Écart-type observé	0,5546

Un premier écart apparaît déjà : la moyenne empirique des inter-arrivées (0,2547 jour) est supérieure à la valeur théorique $1/\hat{\lambda} = 0,1831$ jour. Cet écart suggère que les arrivées sont en moyenne plus espacées que ne le prévoit le modèle, ce qui est cohérent avec la surdispersion déjà observée sur les comptes.

Comparaison graphique. La figure 3.3 compare la distribution empirique des temps inter-arrivées à la densité théorique de la loi $\text{Exp}(\hat{\lambda})$.




FIGURE 3.3 – Distribution empirique des temps inter-arrivées (barres bleues) comparée à la densité $\text{Exp}(\hat{\lambda} = 5,46)$ (courbe rouge).

La figure met en évidence un décalage notable entre la distribution observée et la courbe théorique. La distribution empirique présente une concentration très forte autour de

zéro : une grande proportion des inter-arrivées est inférieure à 0,1 jour, soit moins de 2,4 heures. Ce comportement suggère une organisation temporelle plus irrégulière que celle prédite par une loi exponentielle simple, avec à la fois une forte concentration de temps très courts et une dispersion globale plus importante que celle attendue sous le modèle homogène.

Test de Kolmogorov–Smirnov. Le test de Kolmogorov–Smirnov compare la fonction de répartition empirique des inter-arrivées à celle de la loi $\text{Exp}(\hat{\lambda})$:

$$H_0 : T_k \sim \text{Exp}(\hat{\lambda}), \quad \hat{\lambda} = 5,4619.$$

Le test conduit aux résultats suivants :

$$D = 0,2975, \quad p\text{-valeur} < 0,001.$$

La p -valeur est très faible : on rejette donc très nettement H_0 . Les temps inter-arrivées observés ne sont pas compatibles avec une loi exponentielle de paramètre $\hat{\lambda} = 5,4619$.

Interprétation. Ce rejet, cohérent avec celui obtenu sur les comptes journaliers, confirme que le processus d'arrivée des sessions de recharge ne peut pas être fidèlement décrit par un processus de Poisson homogène. Les deux approches, comptes agrégés et temps inter-arrivées, convergent vers la même conclusion : l'hypothèse d'un taux d'arrivée constant dans le temps est trop restrictive pour rendre compte des données observées.

Autrement dit, la difficulté ne vient pas du choix du jeu de données, mais des limites du modèle homogène lorsqu'il est confronté à des données réelles de recharge. Ces éléments seront synthétisés et discutés dans la section suivante.

3.10 Discussion des résultats

Ce chapitre avait pour objectif de tester la pertinence du modèle de Poisson homogène sur les données réelles de sessions de recharge du site `office_01/Parking_Lot_01`. Les analyses menées successivement sur les comptes journaliers et sur les temps inter-arrivées convergent vers une même conclusion, que l'on peut formuler en deux temps.

Ce que le modèle capture. Le modèle de Poisson homogène rend correctement compte de l'ordre de grandeur moyen du flux d'arrivées. Le taux estimé $\hat{\lambda} = 5,4619$ sessions par jour constitue une description synthétique utile du niveau d'activité du

site. La distribution empirique des comptes journaliers suit globalement la forme en cloche de la loi de Poisson, centrée autour de 4 à 5 sessions par jour, ce qui confirme l'intérêt du modèle comme outil de première approximation.

Ce que le modèle ne capture pas. En revanche, le modèle échoue à reproduire la variabilité réelle des données. Trois indicateurs concordants le confirment :

- l'indice de dispersion $I_d = 1,5681 > 1$, qui signale une surdispersion modérée ;
- le rejet du test du chi-deux ($\chi^2 = 36,15$, $p < 0,001$), qui montre que la distribution empirique des comptes journaliers diffère significativement de $\mathcal{P}(5,46)$;
- le rejet du test de Kolmogorov–Smirnov sur les temps inter-arrivées ($D = 0,2975$, $p < 0,001$), qui invalide l'hypothèse d'une loi exponentielle pour les durées entre arrivées consécutives.

Origines probables des écarts. Ces écarts ne sont pas surprenants. Plusieurs facteurs structurels peuvent expliquer pourquoi le taux d'arrivée n'est pas constant dans le temps :

- une **variabilité selon le jour de la semaine** : le vendredi concentre 288 sessions contre 192 le mardi, soit un rapport de près de 1,5 entre les deux extrêmes ;
- une **montée en charge progressive** entre mars et août 2019, qui suggère que le site était encore en phase d'adoption au début de la période ;
- la **présence de pics ponctuels** d'activité, visibles sur la série temporelle, qui traduisent probablement des événements ou des périodes spécifiques au site.

Conclusion et perspectives. Le modèle de Poisson homogène reste un outil de référence précieux pour caractériser le flux moyen d'arrivées. Il fournit une estimation simple et interprétable du taux λ , et constitue une base naturelle pour des extensions plus riches. Pour mieux rendre compte de la variabilité observée, une extension naturelle consiste à autoriser le taux d'arrivée à varier dans le temps. On est alors conduit vers le **processus de Poisson non homogène**, dans lequel l'intensité devient une fonction $\lambda(t)$. Cette extension sera abordée au chapitre 5.

Chapitre 4

Application aux demandes de service NYC 311

4.1 Contexte urbain et demandes de service

Les grandes métropoles contemporaines doivent faire face, au quotidien, à un volume considérable de demandes de service émanant de leurs habitants. Ces demandes couvrent des domaines très variés : nuisances sonores, problèmes de voirie, pannes d'éclairage public, dysfonctionnements de feux de signalisation ou encore interventions sur les espaces publics. Leur prise en charge constitue un enjeu majeur pour les collectivités, qui doivent adapter en permanence leurs moyens humains et matériels à une demande par nature irrégulière et variable dans le temps.

La ville de New York s'est dotée, depuis 2003, d'un dispositif centralisé de gestion de ces demandes : le service **NYC 311**. Accessible par téléphone, par application mobile ou via le site internet de la ville, ce service permet aux habitants de signaler tout problème relevant des services municipaux. Chaque demande est enregistrée, horodatée, puis transmise à l'administration compétente. Les données correspondantes sont rendues publiques sur la plateforme `data.cityofnewyork.us` et mises à jour quotidiennement [7], ce qui en fait une source particulièrement riche pour l'analyse statistique des flux de signalements urbains.

Du point de vue probabiliste, le flux de demandes reçues par NYC 311 peut être interprété comme un processus de comptage : chaque signalement correspond à un événement ponctuel daté, survenant dans le temps. Dans un cadre idéalisé, si les demandes d'un type donné arrivaient de manière indépendante et à un rythme moyen stable, le processus de Poisson homogène constituerait un modèle naturel pour décrire leur dynamique d'arrivée. C'est cette hypothèse que ce chapitre se propose de tester sur des données réelles.

L'objectif est d'appliquer au cas de NYC 311 la même démarche que celle suivie au chapitre 3 pour ACN-Data : définir précisément l'événement étudié, construire une série de comptes, estimer un taux moyen d'arrivée, puis confronter les données observées au modèle de Poisson homogène. Cette seconde application, menée dans un contexte urbain plus ouvert et plus fortement influencé par les comportements humains, permettra de tester la robustesse des conclusions obtenues précédemment.

4.2 Présentation du dataset NYC 311

Le jeu de données **NYC 311** enregistre l'ensemble des demandes de service non urgentes adressées à la ville de New York depuis 2003. Chaque enregistrement contient notamment : la date et l'heure de création de la demande (`created_date`), le type de plainte (`complaint_type`), un descripteur plus précis (`descriptor`), l'arrondissement concerné (`borough`), ainsi que diverses informations administratives et géographiques.

Les données ont été téléchargées via l'API Socrata de NYC Open Data. Un premier téléchargement sans filtre sur le type de demande a permis de récupérer **200 000 signalements** sur le mois de **janvier 2020**. Ce jeu de données brut a servi de base à la comparaison des types de demandes disponibles et au choix du type à étudier, détaillé dans la section suivante.

Après chargement dans un dataframe Python, la variable `created_date` a été convertie au format date-heure et les lignes sans date valide ont été supprimées. Les variables temporelles dérivées suivantes ont ensuite été construites :

- `year` : année de création du signalement ;
- `month` : mois ;
- `day` : jour du mois ;
- `hour` : heure de création ;
- `date` : date civile ;
- `jour_semaine` : jour de la semaine.

Le tableau 4.1 présente les dix types de demandes les plus fréquents sur ce premier jeu de données.

TABLE 4.1 – Top 10 des types de demandes NYC 311 (janvier 2020, tous arrondissements, $n = 200\,000$)

Type de demande	Nombre de signalements
HEAT/HOT WATER	26 259
Noise - Residential	19 246
Request Large Bulky Item Collection	18 166
Illegal Parking	17 376
Blocked Driveway	11 773
Street Condition	6 296
Street Light Condition	5 899
Electronics Waste Appointment	4 903
Water System	4 026
Traffic Signal Condition	3 202

La répartition par jour de la semaine sur ce jeu de données brut met en évidence un flux actif tout au long de la semaine, sans rupture aussi nette entre semaine et week-end que dans le cas d'ACN-Data :

TABLE 4.2 – Répartition des 200 000 signalements NYC 311 par jour de la semaine (janvier 2020, tous types)

Jour de la semaine	Nombre de signalements
Lundi	26 190
Mardi	27 574
Mercredi	31 044
Jeudi	34 704
Vendredi	32 483
Samedi	27 001
Dimanche	21 004
Total	200 000

Contrairement au parking de bureau du chapitre 3, les signalements NYC 311 arrivent

7 jours sur 7. Cela reflète le caractère continu du service municipal et la nature permanente des infrastructures urbaines. On note cependant une hausse en milieu de semaine (jeudi : 34 704) et une baisse le dimanche (21 004), ce qui montre que le flux n'est pas homogène sur l'ensemble de la semaine.

La variable centrale pour toute la suite de l'analyse est `created_date`, qui joue dans ce chapitre le même rôle que `session_start` dans le chapitre précédent : elle définit les instants d'arrivée des signalements à partir desquels seront construits les comptes, estimé le taux λ et évaluée l'adéquation au modèle de Poisson.

4.3 Choix du type de demande étudié

Le dataset NYC311 couvre une grande variété de types de demandes, dont certains sont beaucoup plus adaptés que d'autres à une modélisation par un processus de Poisson homogène. Le choix du type à étudier conditionne directement la pertinence des hypothèses du modèle et la qualité de l'ajustement statistique. Cette section décrit la démarche adoptée pour aboutir au choix final, en trois étapes successives.

Étape 1 : élimination des types structurellement incompatibles. Plusieurs types de demandes ont été écartés dès l'analyse exploratoire pour des raisons structurelles. *HEAT/HOT WATER* présente une forte saisonnalité hivernale, incompatible avec l'hypothèse d'un taux constant. *Noise - Residential* est concentré le soir et le week-end. *Request Large Bulky Item Collection* dépend de jours de collecte programmés, il ne s'agit pas d'un phénomène aléatoire. *Illegal Parking* et *Blocked Driveway* sont fortement liés aux horaires de bureau, générant une hétérogénéité temporelle marquée.

Étape 2 : comparaison des candidats sur l'indice de dispersion. Trois types ont été retenus comme candidats sérieux et comparés sur la base de leur indice de dispersion $I_d = s^2/\bar{X}$, calculé sur les comptes horaires à partir du jeu de données brut (janvier 2020). Pour une loi de Poisson, on attend $I_d = 1$: plus I_d est proche de 1, plus le flux est compatible avec le modèle homogène.

TABLE 4.3 – Comparaison des candidats sur comptes horaires (janvier 2020)

Type de demande	Total	Moyenne horaire	I_d
Street Light Condition	5 899	7,71	29,40
Water System	4 026	5,26	5,17
Traffic Signal Condition	3 202	4,19	3,96

Traffic Signal Condition présente l'indice de dispersion le plus faible, avec $I_d = 3,96$. Cependant, cet indice reste supérieur à 1, ce qui suggère une surdispersion résiduelle lorsqu'on considère l'ensemble des arrondissements.

Étape 3 : affinage par arrondissement. En restreignant *Traffic Signal Condition* à un seul arrondissement, on isole un sous-flux plus homogène. Le tableau 4.4 présente les résultats obtenus pour chaque borough sur le jeu de données brut de janvier 2020.

TABLE 4.4 – Indice de dispersion horaire par arrondissement, *Traffic Signal Condition* (janvier 2020)

Arrondissement	Total	Moyenne horaire	I_d
Brooklyn	1 410	1,8431	2,8798
Queens	644	0,8507	2,1148
Manhattan	615	0,8060	2,3011
Bronx	340	0,4456	1,4033
Staten Island	112	0,1562	1,4887

Le **Bronx** présente l'indice de dispersion le plus faible parmi les arrondissements disposant d'un volume suffisant, avec $I_d = 1,40$. Staten Island affiche un indice comparable (1,49) mais ne compte que 112 signalements sur un mois, un volume trop faible pour des tests statistiques fiables.

Choix final et dataset retenu. Le type de demande et l'arrondissement retenus pour ce chapitre sont donc *Traffic Signal Condition* dans le **Bronx**. Un second téléchargement ciblé a été effectué sur la période complète du **1^{er} janvier 2020** au **29 février 2020**, ce qui porte le volume final à **664 signalements**, soit approximativement le double du volume observé sur le seul mois de janvier, ce qui suggère une relative stabilité mensuelle du flux sur la période retenue.

Type : *Traffic Signal Condition* **Arrondissement :** *Bronx* **Période :** *1^{er} janvier – 29 février 2020* **Volume :** *664 signalements*

Ce choix repose sur un critère statistique objectif, la minimisation de l'indice de dispersion parmi les sous-flux disposant d'un volume suffisant, et non sur une préférence arbitraire. Ce choix ne garantit pas pour autant une adéquation parfaite au modèle de Poisson homogène : l'indice $I_d = 1,40$ indique déjà une surdispersion modérée, dont

la significativité sera examinée dans les sections suivantes par des tests statistiques formels.

4.4 Définition de l'événement étudié

Dans le cadre de cette application, l'événement retenu est le **dépôt d'un signallement de type *Traffic Signal Condition***. Autrement dit, chaque fois qu'un habitant ou un agent municipal signale un dysfonctionnement d'un feu de signalisation dans le Bronx, on considère qu'une arrivée s'est produite.

Ce choix est naturel du point de vue d'un processus de comptage. Un signallement correspond en effet à un événement ponctuel daté, observé à un instant précis. Du point de vue du modèle, on fait l'hypothèse que ces arrivées peuvent être approchées par un flux aléatoire, dont le rythme moyen est à estimer. Cette hypothèse n'implique pas que les dysfonctionnements réels soient parfaitement indépendants, mais elle fournit un cadre probabiliste simple pour analyser le flux de signalements.

Formellement, si l'on note

$$Y_1 < Y_2 < \dots < Y_n$$

les instants successifs de signallement ordonnés chronologiquement sur la période d'observation $[0, \tau]$, alors le compteur

$$N(t) = \#\{k : Y_k \leq t\}$$

représente le nombre de signalements de dysfonctionnement de feux enregistrés entre l'instant initial et l'instant t . Dans les données, ces instants d'arrivée sont repérés par la variable `created_date`, qui joue exactement le rôle des instants $Y_1, Y_2, \dots, Y_n$ du modèle théorique présenté au chapitre 1.

Deux représentations complémentaires peuvent alors être envisagées pour l'analyse. D'une part, on peut travailler directement sur les **instants d'arrivée**, puis sur les temps inter-arrivées

$$T_k = Y_k - Y_{k-1}, \quad k \geq 2.$$

Si le modèle de Poisson homogène fournit une approximation raisonnable du flux, ces temps inter-arrivées doivent être approximativement distribués selon une loi exponentielle de paramètre λ .

D'autre part, et c'est l'approche principale retenue dans ce chapitre, on peut considérer des **comptes agrégés** sur des intervalles de temps fixes. On note ainsi

$$X_i = \text{nombre de signalements enregistrés pendant l'heure } i.$$

Le choix d'une agrégation **horaire** est particulièrement adapté au contexte des signalements urbains : contrairement au parking de bureau du chapitre 3, les arrivées sont distribuées sur l'ensemble des 24 heures de la journée et sur les 7 jours de la semaine. Une agrégation journalière ne fournirait que 60 observations sur deux mois, ce qui serait relativement limité pour des tests statistiques robustes. Les comptes horaires, avec 1 438 heures sur la période retenue, offrent une base d'analyse beaucoup plus riche.

Si le modèle est adapté, les variables X_i doivent alors suivre approximativement une loi de Poisson de paramètre λ , où λ représente ici le nombre moyen de signalements par heure, avec

$$\mathbb{E}[X_i] = \text{Var}(X_i) = \lambda.$$

Ainsi, l'événement étudié dans ce chapitre n'est ni la nature du dysfonctionnement, ni sa durée de traitement, ni sa résolution, mais uniquement

l'instant de dépôt d'un signalement *Traffic Signal Condition* dans le Bronx.

C'est cet événement qui sera interprété comme une arrivée dans le système, puis utilisé pour construire les comptes horaires, estimer le taux moyen d'arrivée λ et évaluer l'adéquation du modèle de Poisson homogène aux données observées.

4.5 Préparation des données

Après avoir retenu le sous-flux *Traffic Signal Condition* dans le **Bronx**, il convient de construire un jeu de données propre et cohérent avec l'objectif de modélisation. Cette phase de préparation vise à garantir que les instants d'arrivée utilisés dans l'analyse sont correctement datés, ordonnés et enrichis par les variables temporelles nécessaires à la construction des comptes.

Chargement et contrôle de validité. Le fichier de travail, chargé dans Python sous la forme d'un dataframe, contient initialement **664 lignes** et **45 colonnes**. La variable centrale est `created_date`, qui représente la date et l'heure de création de chaque signalement. Cette variable a été convertie au format date-heure (`datetime64`) à l'aide de `pd.to_datetime(..., errors="coerce")`, puis un contrôle de validité a été effectué. Aucun signalement ne présentait de date invalide :

$$n_{\text{dates invalides}} = 0.$$

Le nombre d’observations conservées après nettoyage reste donc inchangé :

$$n = 664.$$

Variables temporelles dérivées. À partir de `created_date`, six variables temporelles ont été construites : `year`, `month`, `day`, `hour`, `date` (date civile) et `jour_semaine` (jour de la semaine). Le tableau 4.5 présente les cinq premières lignes du dataframe final, illustrant la structure concrète des données utilisées.

TABLE 4.5 – Aperçu des cinq premières lignes du dataframe NYC311 (Bronx, *Traffic Signal Condition*, janvier–février 2020)

	<code>created_date</code>	<code>year</code>	<code>month</code>	<code>day</code>	<code>hour</code>	<code>jour_semaine</code>
0	2020-01-01 00 :25 :00	2020	1	1	0	Wednesday
1	2020-01-01 01 :40 :00	2020	1	1	1	Wednesday
2	2020-01-01 02 :45 :00	2020	1	1	2	Wednesday
3	2020-01-01 03 :20 :00	2020	1	1	3	Wednesday
4	2020-01-01 06 :50 :00	2020	1	1	6	Wednesday

Ces variables permettront de construire les comptes horaires et d’examiner la structure temporelle du flux de signalements.

Période couverte. Le jeu de données final couvre exactement la période allant du **1^{er} janvier 2020 à 00 h 25** au **29 février 2020 à 21 h 07**, soit exactement **60 jours calendaires**. Ce périmètre est conforme au téléchargement ciblé effectué lors de la phase de collecte décrite à la section précédente.

Répartition selon le jour de la semaine. La répartition des 664 signalements par jour de la semaine est présentée dans le tableau 4.6.

TABLE 4.6 – Répartition des signalements *Traffic Signal Condition* dans le Bronx selon le jour de la semaine (janvier–février 2020)

Jour de la semaine	Nombre de signalements
Lundi	85
Mardi	97
Mercredi	107
Jeudi	140
Vendredi	131
Samedi	63
Dimanche	41
Total	664

Cette répartition met en évidence une activité présente tout au long de la semaine, mais non uniforme. Le nombre de signalements est plus important du mercredi au vendredi, avec un pic le **jeudi** (140 signalements), tandis que le **dimanche** apparaît comme la journée la moins active (41 signalements), soit un rapport de plus de **3 entre les deux extrêmes**. Cette hétérogénéité hebdomadaire est sensiblement plus marquée que celle d’ACN-Data (rapport de 1,5 entre vendredi et mardi), mais reste structurellement différente : contrairement au parking de bureau du chapitre 3, où le week-end correspondait à une absence quasi totale d’activité, les signalements NYC 311 restent présents tous les jours. Aucun filtrage par jour de la semaine n’est donc effectué : l’ensemble des **664 signalements sur 60 jours** est conservé pour la suite.

Distribution horaire. La figure 4.1 représente la distribution des signalements selon l’heure de la journée, toutes dates confondues.




FIGURE 4.1 – Distribution horaire des signalements *Traffic Signal Condition* dans le Bronx (janvier–février 2020). Chaque barre représente le nombre total de signalements enregistrés dans la tranche horaire correspondante sur l’ensemble de la période.

Cette figure met en évidence une structure temporelle clairement non uniforme. L’activité est quasi nulle entre 0 h et 5 h du matin, période creuse où la circulation est faible. Elle croît ensuite à partir de 6 h, avec un premier pic en matinée, correspondant aux heures de pointe et au début des interventions des équipes municipales. Un second pic, plus prononcé, est visible en fin d’après-midi, avant que le nombre de signalements ne décroisse progressivement en soirée. Cette structure bimodale confirme l’intérêt d’une agrégation **horaire** plutôt que journalière : le flux n’est homogène ni sur la journée, ni sur la semaine, et une agrégation trop grossière masquerait ces variations.

Au terme de cette préparation, le dataframe final constitue une base chronologiquement ordonnée, propre et directement exploitable pour la construction des comptes horaires. C’est sur ce jeu de données que reposeront l’estimation du taux moyen d’arrivée, l’analyse descriptive et les tests d’adéquation au modèle de Poisson homogène.

4.6 Construction des comptes horaires

Contrairement au parking de bureau du chapitre 3, les signalements NYC 311 s’étalent sur les 24 heures et les 7 jours de la semaine. Une agrégation journalière ne fournirait que 60 observations, volume insuffisant pour des tests statistiques robustes. On retient donc une agrégation **horaire**, mieux adaptée au rythme continu des services urbains. Pour chaque heure de la période retenue, on définit ainsi

X_i = nombre de signalements *Traffic Signal Condition* enregistrés pendant l’heure i .

La série couvre $n = 1\,438$ heures, du 1^{er} janvier au 29 février 2020, pour un total de 664 signalements agrégés. Les comptes varient de 0 à 6. Une caractéristique marquante

est la forte proportion d'heures nulles : 974 heures sur 1 438 (67,7 %) n'ont enregistré aucun signalement, ce qui reflète directement les tranches horaires nocturnes identifiées à la section 4.5. Le tableau 4.7 présente la distribution complète des valeurs observées.

TABLE 4.7 – Distribution des comptes horaires X_i

Nombre de signalements	Nombre d'heures
0	974
1	322
2	97
3	36
4	6
5	2
6	1
Total	1 438

La distribution est fortement concentrée sur les petites valeurs : la modalité dominante est 0, suivie de 1 puis 2. Les valeurs supérieures à 3 ne représentent que 9 heures sur l'ensemble de la période. C'est sur cette série que reposeront l'estimation de λ et la comparaison au modèle de Poisson.

4.7 Estimation du taux d'arrivée

L'estimateur naturel de λ est la moyenne empirique des comptes horaires, qui coïncide avec l'estimateur du maximum de vraisemblance pour une loi de Poisson :

$$\hat{\lambda} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Sur les $n = 1\,438$ heures de la période retenue, le nombre total de signalements est de 664. On obtient ainsi

$$\hat{\lambda} = \frac{664}{1\,438} \approx 0,4618 \text{ signalement par heure.}$$

Autrement dit, le Bronx reçoit en moyenne un peu moins d'un signalement de dysfonctionnement de feux de signalisation toutes les deux heures, soit environ **11 signalements par jour** ($24 \times 0,4618 \approx 11$). Cette intensité, inférieure à 1, est cohérente avec

la forte proportion d'heures nulles observée à la section précédente : un taux moyen faible implique naturellement que de nombreux intervalles ne contiennent aucun événement. Sous l'hypothèse d'un processus de Poisson homogène de paramètre $\lambda = \hat{\lambda}$, les comptes horaires devraient suivre une loi $\mathcal{P}(0,4618)$, avec en particulier

$$\mathbb{E}[X_i] = \text{Var}(X_i) = \hat{\lambda} = 0,4618.$$

La confrontation entre cette égalité théorique et les statistiques empiriques fera l'objet de la section suivante.

4.8 Analyse descriptive

Avant d'ajuster formellement le modèle de Poisson, on procède à une analyse descriptive des comptes horaires X_i . Cette étape permet d'identifier d'éventuelles caractéristiques incompatibles avec les hypothèses du modèle.

Statistiques descriptives. Les principales statistiques des comptes horaires sont résumées dans le tableau 4.8.

TABLE 4.8 – Statistiques descriptives des comptes horaires X_i

Indicateur	Valeur
Nombre d'heures n	1 438
Minimum	0
Maximum	6
Moyenne $\hat{\lambda}$	0,4618
Médiane	0,0000
Variance s_X^2	0,6328
Écart-type s_X	0,7955
Indice de dispersion I_d	1,3704

La médiane nulle confirme que plus de la moitié des heures n'enregistrent aucun signallement. L'indice de dispersion $I_d = 1,37 > 1$ constitue un premier signal de **surdispersion** : la variance empirique dépasse la moyenne, ce qui est incompatible avec la signature $\mathbb{E}[X_i] = \text{Var}(X_i)$ attendue sous le modèle de Poisson.

Série temporelle. La figure 4.2 représente l'évolution des comptes horaires sur l'ensemble de la période retenue.




FIGURE 4.2 – Série temporelle des comptes horaires de signalements, Bronx, *Traffic Signal Condition*. La ligne rouge représente la moyenne estimée $\hat{\lambda} = 0,46$.

La série présente une variabilité notable autour de la moyenne, avec des oscillations fréquentes entre 0 et 2 et des pics ponctuels atteignant 5 ou 6 signalements. Aucune tendance progressive ni rupture structurelle n'est visible sur la période, ce qui est cohérent avec le filtrage effectué en section 4.5. En revanche, la forte alternance entre heures nulles et heures actives trahit une hétérogénéité temporelle que le modèle homogène ne peut pas capturer.

Distribution empirique. La figure 4.3 compare la distribution empirique des comptes horaires à la loi de Poisson théorique de paramètre $\hat{\lambda} = 0,4618$.




FIGURE 4.3 – Distribution empirique des comptes horaires X_i comparée à la loi $\mathcal{P}(0,4618)$.

La comparaison visuelle révèle un écart net entre la distribution observée et la courbe théorique. La fréquence empirique pour $X_i = 0$ (67,7 %) dépasse la probabilité théo-

rique $e^{-0,4618} \approx 63,0\%$, tandis que les valeurs $X_i \geq 2$ sont plus fréquentes que prévu. Ces observations sont cohérentes avec la surdispersion signalée par $I_d = 1,37 > 1$ et suggèrent que le modèle de Poisson homogène sous-estime la variabilité réelle du flux. L'ajustement formel et les tests statistiques feront l'objet de la section suivante.

4.9 Ajustement du modèle de Poisson

Après avoir estimé le taux moyen d'arrivée $\hat{\lambda} = 0,4618$ et examiné les principales caractéristiques descriptives des comptes horaires, on confronte formellement les données au modèle de Poisson homogène. Sous l'hypothèse nulle

$$H_0 : X_i \sim \mathcal{P}(\hat{\lambda}), \quad \hat{\lambda} = 0,4618,$$

les comptes horaires observés devraient être compatibles avec une loi de Poisson de paramètre 0,4618.

Comparaison des fréquences observées et attendues. Le tableau 4.9 compare, pour chaque valeur des comptes horaires, les effectifs observés aux effectifs attendus sous le modèle $\mathcal{P}(0,4618)$.

TABLE 4.9 – Fréquences observées et attendues sous le modèle $\mathcal{P}(0,46)$

Valeur	Observé	Attendu	Différence
0	974	906,20	+67,80
1	322	418,44	−96,44
2	97	96,61	+0,39
3	36	14,87	+21,13
4	6	1,72	+4,28
5	2	0,16	+1,84
6	1	0,01	+0,99

Plusieurs écarts apparaissent clairement. Le modèle sous-estime fortement les heures sans signalement (+67,80) et surestime les heures à un seul signalement (−96,44). Il sous-estime également les valeurs ≥ 3 , qui sont nettement plus fréquentes dans les données que ce que prédit $\mathcal{P}(0,4618)$. La distribution empirique ne présente donc pas

simplement une dispersion plus grande que la loi théorique : elle adopte aussi une forme différente.

Test du chi-deux d'adéquation. Pour quantifier cet écart de manière formelle, on applique un test d'ajustement du chi-deux. Seules les classes dont l'effectif théorique attendu est supérieur ou égal à 5 sont retenues, soit 4 classes après regroupement. Le test conduit aux résultats suivants :

$$\chi^2 = 57,58, \quad \text{ddl} = 2, \quad p\text{-valeur} < 0,001.$$

La p -valeur est extrêmement faible. On rejette donc très nettement H_0 au seuil de 5 % : le modèle de Poisson homogène n'est pas statistiquement compatible avec la distribution observée des comptes horaires.

Interprétation. Ce résultat confirme et prolonge ce que suggéraient déjà l'indice de dispersion $I_d = 1,37 > 1$ et la comparaison graphique de la section 4.8 : le modèle de Poisson homogène rend compte de l'ordre de grandeur moyen du flux, mais échoue à reproduire sa variabilité réelle. Ces limites seront discutées dans la section suivante.

4.10 Discussion des résultats

L'application du modèle de Poisson homogène aux signalements *Traffic Signal Condition* dans le Bronx aboutit à un constat nuancé, que les analyses des sections précédentes permettent de préciser.

Un modèle utile comme référence. Malgré ses limites, le modèle fournit une première description synthétique du flux : $\hat{\lambda} = 0,4618$ signalement par heure résume l'intensité moyenne du service sur la période retenue. Cette valeur est cohérente avec la structure observée, un flux peu dense, dominé par des heures sans aucun événement, et constitue un point de départ naturel pour une première lecture quantitative du fonctionnement du service.

Une variabilité que le modèle ne peut pas absorber. Le rejet net du test du chi-deux ($\chi^2 = 57,58$, $p < 0,001$) et l'indice de dispersion $I_d = 1,37 > 1$ indiquent sans ambiguïté que l'hypothèse d'homogénéité est trop restrictive. Le flux de signalements n'est pas stationnaire : il suit une dynamique journalière très contrastée, ralentit fortement le week-end et devient très faible pendant la nuit. Ces variations sont structurelles,

elles tiennent au comportement humain et au fonctionnement des services municipaux, et ne peuvent pas être captées par un taux unique $\hat{\lambda}$.

Sur l'absence d'analyse des temps inter-arrivées. Contrairement au chapitre 3, l'analyse des temps inter-arrivées n'a pas été conduite ici. La structure du flux, silences nocturnes prolongés, activité fortement réduite le week-end, produirait des inter-arrivées artificiellement longues qui ne reflèteraient pas la dynamique intrinsèque des signalements, mais plutôt des phases structurelles de faible activité. Les filtrer reviendrait à reconstituer un flux tronqué, dont l'interprétation serait délicate. Ce choix n'est donc pas une omission, mais une adaptation à la nature des données : l'hétérogénéité temporelle est ici suffisamment marquée pour remettre en cause, d'emblée, les conditions d'application de ce second test.

Perspectives. La prise en compte de cette non-stationnarité conduit naturellement à une extension du modèle homogène : le **processus de Poisson non homogène**, dans lequel l'intensité devient une fonction du temps $\lambda(t)$. Cette extension sera abordée au chapitre 5.

Chapitre 5

Comparaison, limites et extension

5.1 Comparaison des deux applications

Les deux applications menées aux chapitres 3 et 4 ont suivi une démarche identique : estimer le taux moyen $\hat{\lambda}$, examiner la dispersion observée, puis tester l'adéquation du modèle de Poisson homogène. Cependant, les contextes d'étude diffèrent radicalement, ce qui rend leur rapprochement particulièrement instructif pour cerner les forces et les limitations du modèle.

ACN-Data décrit un flux d'arrivées fortement contraint. Le site étudié, office_01 / Parking_Lot_01, fonctionne selon des horaires de bureau réguliers et prévisibles. La population d'utilisateurs est relativement homogène, composée de salariés ou de visiteurs du campus Caltech. Les sessions de recharge ne surviennent que les jours ouvrés, avec une absence quasi totale d'activité le week-end. Cette structure prévisible et routinière crée un environnement où les hypothèses du modèle de Poisson pourraient sembler raisonnables en première approximation.

NYC 311, en contraste frappant, décrit un flux urbain ouvert et continu. Le service municipal fonctionne sept jours sur sept et vingt-quatre heures sur vingt-quatre, sans interruption programmée. Les signalements de dysfonctionnement de feux de signalisation arrivent à tout moment, soumis aux rythmes imprévisibles de la vie urbaine et aux comportements hétérogènes d'une population large et diverse. Cette nature incessante et chaotique du flux crée un environnement beaucoup moins favorable aux hypothèses simplificatrices du modèle homogène.

Malgré ces différences contextuelles, les deux analyses aboutissent à une conclusion identique au plan statistique : le modèle de Poisson homogène est rejeté par les tests formels dans les deux cas. Cependant, les mécanismes qui conduisent à ce rejet diffèrent substantiellement.

Pour ACN-Data, la surdispersion observée (indice de dispersion $I_d = 1,5681$) reflète principalement une variabilité structurelle entre jours de la semaine. Le tableau 3.2 avait révélé un rapport de 1,5 entre vendredi (288 sessions) et mardi (192 sessions). S'ajoute à cela une montée en charge progressive du site entre mars et août 2019, visible sur la série temporelle (figure 3.1), qui suggère que le taux d'arrivée n'était pas constant au fil des mois. Ces deux sources de variation temporelle, l'une cyclique (hebdomadaire) et l'autre tendancielle (progressive), suffisent à expliquer la majeure partie de l'écart entre la variance observée et la variance théorique du modèle.

Pour NYC 311, la surdispersion (indice $I_d = 1,3704$) est principalement produite par une hétérogénéité intra-journalière bien plus marquée. La figure 4.1 avait mis en évidence une structure bimodale avec deux pics distincts, l'un en matinée, l'autre en fin d'après-midi, et un creux nocturne prolongé (pratiquement aucun signalement entre 0h et 5h). Cette variation horaire, combinée à une hétérogénéité hebdomadaire modérée (tableau 4.6, rapport de 3 entre jeudi et dimanche), crée des fluctuations que le modèle homogène ne peut structurellement pas capturer.

En résumé, bien que les deux applications aboutissent au même verdict statistique, les causes sous-jacentes de la non-adéquation diffèrent en nature et en magnitude. Cette observation est cruciale : elle suggère que les extensions naturelles du modèle ne seront pas identiques pour les deux cas. Pour ACN-Data, une modélisation par jour de la semaine et par mois pourrait suffire à capturer l'essentiel de la variabilité. Pour NYC 311, une structure horaire fine associée à un effet jour de la semaine sera nécessaire. Le processus de Poisson non homogène, présenté à la section 5.4, offre précisément cette flexibilité.

5.2 Moyenne, variance et surdispersion

La signature fondamentale du modèle de Poisson homogène est l'égalité

$$E[X_i] = \text{Var}(X_i) = \lambda,$$

qui implique que la moyenne et la variance des comptes observés doivent être identiques. Cette propriété constitutive, établie théoriquement au chapitre 1, fournit un critère de référence simple et vérifiable pour évaluer l'adéquation du modèle aux données réelles.

Dans les deux applications menées aux chapitres 3 et 4, cette égalité est mise en défaut de manière manifeste. Le tableau 5.1 résume les écarts observés.

Dans les deux cas, la variance empirique dépasse la moyenne : on parle de surdispersion. L'indice de dispersion $I_d > 1$ en est la mesure naturelle ; sous un modèle de Poisson

TABLE 5.1 – Moyenne, variance et surdispersion dans les deux applications

Application	Moyenne $\hat{\lambda}$	Variance s^2	$I_d = s^2/\hat{\lambda}$
ACN-Data	5,4619	8,5650	1,5681
NYC 311	0,4618	0,6328	1,3704

parfaitement ajusté, on attendrait $I_d = 1$.

Cette surdispersion n'est pas un artefact statistique mineur. Elle constitue un signal que les données présentent plus de variabilité que ce que le modèle prédit. Cette situation peut résulter de deux origines principales, souvent confondues dans la littérature.

La première est la non-stationnarité du taux d'arrivée. Si le paramètre λ varie dans le temps, c'est-à-dire si $\lambda = \lambda(t)$ n'est pas constant, alors les comptes agrégés sur un intervalle fixe héritent d'une variance supplémentaire. Mathématiquement, si $\lambda(t)$ fluctue, la variance totale se décompose en variance intra-période (due au processus de Poisson lui-même) et variance inter-période (due aux fluctuations de λ). Le modèle homogène, qui ne connaît que le premier terme, sous-estime systématiquement la variance globale.

La seconde est une possible dépendance entre arrivées successives. Si les événements ne sont pas indépendants, par exemple si l'arrivée d'un client provoque l'arrivée d'un autre client, alors les accroissements du compteur violeront l'hypothèse d'indépendance, ce qui accroît également la variance sans pour autant modifier la moyenne.

Dans nos deux applications, la première explication est presque certainement la plus vraisemblable. Les analyses descriptives menées aux chapitres 3 et 4 ont clairement mis en évidence des variations temporelles structurelles et prévisibles : selon le jour de la semaine pour ACN-Data, selon l'heure de la journée pour NYC 311. Ces patterns temporels, visibles à l'œil nu dans les séries temporelles, suffisent à expliquer la majeure partie de la surdispersion observée. Il n'est pas nécessaire d'invoquer une dépendance complexe entre arrivées ; c'est simplement le fait que λ change dans le temps qui produit la variabilité excédentaire.

5.3 Limites du processus de Poisson homogène

Les deux applications ont conduit au même verdict statistique : le test du chi-deux a rejeté l'hypothèse nulle avec une p-valeur inférieure à 0,001 dans les deux cas. Il convient toutefois de distinguer avec précision ce que ce rejet signifie réellement, et ce qu'il ne signifie pas.

Ce que le modèle ne peut pas faire

L'hypothèse centrale du processus de Poisson homogène est que le taux d'arrivée λ est constant dans le temps. Cette hypothèse est commode : elle réduit toute la description complexe d'un flux aléatoire à un seul paramètre numérique λ , ce qui facilite l'estimation et l'interprétation. Cependant, elle est rarement vérifiée sur des données réelles provenant de systèmes urbains ou d'infrastructures partagées.

Dès lors que les arrivées obéissent à des rythmes temporels prévisibles, qu'ils soient journaliers (comme les heures de pointe le matin et soir), hebdomadaires (comme l'activité réduite le week-end), ou saisonniers (comme l'inflation hivernale de la demande de chauffage), le modèle homogène échoue systématiquement. Il produit deux types d'erreurs : d'une part, il sous-estime la variabilité du flux, conduisant à des intervalles de confiance trop étroits et à des tests statistiques trop puissants ; d'autre part, il ignore l'information structurelle contenue dans les variations temporelles, privant le modélisateur de la capacité à faire des prévisions adaptées à différents moments ou périodes.

C'est précisément ce qu'ont révélé les tests du chi-deux aux chapitres 3 et 4. En rejetant le modèle homogène, ces tests signalent que l'hypothèse de constance du taux est trop restrictive pour ces données réelles.

Ce que le modèle ne remet pas en cause

Cependant, le rejet du modèle homogène ne disqualifie pas le cadre conceptuel du processus de Poisson dans son ensemble. La structure fondamentale, indépendance des arrivées, absence de mémoire du compteur, distribution exponentielle des temps inter-arrivées, reste une approximation raisonnable sur des fenêtres temporelles suffisamment courtes et homogènes.

Par exemple, si l'on restreint l'analyse aux heures de pointe du matin (disons, 7h à 11h) où le taux d'arrivée est relativement stable, les données au sein de cette fenêtre pourraient bien se conformer au modèle de Poisson homogène. C'est l'introduction du changement de taux en fonction du moment de la journée qui invalide l'hypothèse globale.

En d'autres termes, ce n'est pas le modèle probabiliste de Poisson qui est en défaut, mais l'hypothèse de constance globale du taux qui le paramétrise.

Une limite inhérente aux données urbaines

Plus largement, les données issues de systèmes urbains ou d'infrastructures partagées portent presque universellement une empreinte temporelle structurelle. Les comportements humains sont rythmés par des horaires de travail, de transport, de loisir. Les services municipaux fonctionnent selon des calendriers et des protocoles définis. Les usages de l'infrastructure varient prévisiblement selon la journée, la semaine, la saison.

Vouloir ajuster un processus de Poisson homogène, avec un taux unique et constant, sur de telles données revient à ignorer une information massive et visible à l'œil nu dans les séries temporelles. C'est comparable à ajuster une régression linéaire simple sur des données clairement non linéaires : mathématiquement possible, mais stratégiquement inefficace et conceptuellement maladroit.

Les extensions présentées dans les sections suivantes visent précisément à lever cette contrainte insoutenable de l'homogénéité, en autorisant le taux d'arrivée à fluctuer en fonction du temps.

5.4 Processus de Poisson non homogène

5.4.1 Définition théorique

L'extension naturelle du modèle homogène consiste à autoriser le taux d'arrivée à varier continûment dans le temps. On parle alors de *processus de Poisson non homogène* (PPNH), défini par le remplacement du taux constant λ par une fonction de l'intensité $\lambda(t) \geq 0$.

Définition 5.1 (Processus de Poisson non homogène). Un processus stochastique $(N(t))_{t \geq 0}$ est un processus de Poisson non homogène d'intensité $\lambda(t)$ si :

1. $N(0) = 0$;
2. les accroissements sur des intervalles disjoints sont indépendants ;
3. pour tout $0 \leq s < t$:

$$N(t) - N(s) \sim \mathcal{P} \left(\int_s^t \lambda(u) du \right).$$

La quantité

$$\Lambda(s, t) = \int_s^t \lambda(u) du$$

est appelée *mesure d'intensité* sur l'intervalle $[s, t]$. Elle généralise le concept simple de produit $\lambda(t - s)$ du cas homogène. Lorsque $\lambda(t) = \lambda$ est constant, on retrouve

exactement le modèle étudié aux chapitres 1 à 4 :

$$\Lambda(s, t) = \int_s^t \lambda \, du = \lambda(t - s),$$

et donc $N(t) - N(s) \sim \mathcal{P}(\lambda(t - s))$, ce qui ramène au processus de Poisson homogène.

5.4.2 Interprétation et flexibilité

Le PPNH offre une flexibilité considérable pour modéliser des flux d'arrivées réalistes. Contrairement au modèle homogène, qui impose un rythme uniforme sur toute la période d'observation, le PPNH permet au taux d'arrivée d'augmenter ou de diminuer en fonction du contexte temporel.

Par exemple, dans le cas d'ACN-Data, la fonction $\lambda(t)$ pourrait être définie par morceaux, en attribuant un taux distinct à chaque jour de la semaine. De même, dans le cas de NYC 311, la fonction $\lambda(t)$ pourrait être périodique avec une période de 24 heures, capturant la structure bimodale observée à la figure 4.1.

5.4.3 Estimation pratique

En pratique, la fonction d'intensité $\lambda(t)$ est inconnue et doit être estimée à partir des données. Il existe deux grandes approches : l'approche paramétrique, qui suppose une forme fonctionnelle spécifique pour $\lambda(t)$, et l'approche non paramétrique, qui estime $\lambda(t)$ directement sans imposer de contrainte structurelle a priori.

5.4.4 Lien avec les applications

Pour ACN-Data, une modélisation naturelle consisterait à faire dépendre $\lambda(t)$ du jour de la semaine et peut-être du mois, afin de capturer à la fois l'hétérogénéité hebdomadaire et la tendance progressive observée entre mars et août 2019.

Pour NYC 311, on pourrait modéliser la variation intra-journalière par une fonction $\lambda(t)$ périodique de période 24 heures, capturant les variations horaires observées. Associée à un effet jour de la semaine, cette fonction permettrait de rendre compte de la structure bimodale de la figure 4.1 ainsi que de l'hétérogénéité hebdomadaire du tableau 4.6.

5.4.5 Implémentation paramétrique sur ACN-Data

Méthode

Pour estimer un processus de Poisson non homogène (PPNH) sur les données ACN-Data, nous avons adopté une approche paramétrique simple, dans laquelle le taux d'arrivée $\lambda(t)$ est supposé dépendre du jour de la semaine.

Justification du choix. Le choix de stratifier par jour de la semaine s'appuie directement sur les analyses descriptives du chapitre 3. Le tableau 3.2 avait révélé une variabilité substantielle dans le nombre de sessions selon le jour : vendredi (288 sessions) concentre 1,5 fois plus d'arrivées que mardi (192 sessions). Cette hétérogénéité hebdomadaire représente une source majeure de non-stationnarité identifiée lors de l'ajustement du modèle homogène. Une stratification par mois aurait également pu être envisagée, mais la montée en charge entre mars et août 2019 est progressive et sans rupture structurelle claire, contrairement aux variations hebdomadaires qui sont cycliques et régulières.

Spécification du modèle. Nous supposons que le taux d'arrivée $\lambda(t)$ est constant par jour de la semaine et varient entre les 5 jours ouvrés :

$$\lambda(t) = \lambda_{\text{dow}(t)},$$

où $\text{dow}(t) \in \{\text{lun}, \text{mar}, \text{mer}, \text{jeu}, \text{ven}\}$ désigne le jour de la semaine auquel appartient l'instant t . En conséquence, le nombre de sessions observées au cours d'un jour i appartenant au groupe de jours de semaine d suit une loi de Poisson de paramètre λ_d :

$$X_i \mid \text{dow}(i) = d \sim \mathcal{P}(\lambda_d).$$

Estimation des paramètres. Les taux λ_d pour chaque jour $d \in \{\text{lun}, \dots, \text{ven}\}$ sont estimés par maximum de vraisemblance. Pour un jour de semaine d donné, l'estimateur du maximum de vraisemblance de λ_d est simplement la moyenne empirique des comptes observés les jours appartenant au groupe d :

$$\hat{\lambda}_d = \frac{\text{nombre total de sessions le jour } d}{\text{nombre de jours du type } d \text{ dans la période}}.$$

Formellement, si n_d désigne le nombre d'occurrences du jour d dans la période d'observation (par exemple, le nombre de lundis sur 223 jours), et S_d le nombre total de

sessions observées les jours du type d , alors :

$$\hat{\lambda}_d = \frac{S_d}{n_d}.$$

Cette approche est la plus simple et la plus interprétable : elle fournit un taux moyen par jour de la semaine, sans imposer de structure supplémentaire.

Propriétés statistiques. Cet estimateur possède les propriétés classiques du maximum de vraisemblance pour la loi de Poisson : il est sans biais, converge en probabilité vers la vraie valeur (loi des grands nombres), et suit asymptotiquement une distribution normale. En particulier, la variance asymptotique de $\hat{\lambda}_d$ est λ_d/n_d , ce qui suggère que l'estimation est d'autant plus précise que le nombre d'occurrences du jour d est élevé.

Évaluation de l'ajustement. Après estimation des taux $\hat{\lambda}_d$, l'ajustement du modèle PPNH aux données est évalué selon trois critères :

1. **Indice de dispersion.** Nous calculons l'indice de dispersion empirique de l'ensemble des comptes journaliers, et le comparons à la valeur attendue sous le modèle PPNH. Sous le PPNH stratifié par jour, la variance théorique attendue est :

$$\text{Var}_{\text{PPNH}}(X) = E[\lambda_{\text{dow}}] + \text{Var}[\lambda_{\text{dow}}],$$

où l'espérance et la variance sont prises sur la distribution des jours de la semaine. Si le PPNH capture bien la non-stationnarité, l'indice de dispersion $I'_d = \text{Var}(X)/E[X]$ devrait diminuer vers 1.

2. **Test du chi-deux.** Nous appliquons un test du chi-deux d'adéquation pour vérifier que la distribution empirique des comptes concorde avec la distribution théorique du PPNH. Sous l'hypothèse nulle $H_0 : X \sim$ mélange de Poisson, la statistique de test suit asymptotiquement une distribution χ^2 avec un nombre de degrés de liberté égal au nombre de classes moins le nombre de paramètres estimés.
3. **Comparaison graphique.** Nous traçons l'histogramme des comptes empiriques et le superposons à la distribution théorique du PPNH ainsi qu'à celle du modèle homogène, pour visualiser visuellement l'amélioration de l'ajustement.

Limitations et hypothèses. Cette approche suppose que :

1. Le taux d'arrivée ne dépend que du jour de la semaine et ne varie pas à l'intérieur d'une journée (contrairement au cas NYC 311). Cette hypothèse est raisonnable

pour un parking de bureau, où les sessions sont distribuées relativement uniformément au cours d'une journée de travail.

2. Les sessions arrivent indépendamment et suivent une loi de Poisson conditionnelle au jour de la semaine. L'hypothèse d'indépendance est plausible pour un parking sans phénomène de clustering ou de dépendance temporelle marquée.
3. Il n'existe pas de variabilité intra-mensuelle supplémentaire au-delà de ce que capture déjà la stratification hebdomadaire. La montée en charge progressive du site entre mars et août 2019 est ignorée par ce modèle simple ; elle pourrait être capturée par une stratification mensuelle additionnelle.

Malgré ces limitations, cette approche constitue une première étape naturelle pour lever l'hypothèse trop restrictive d'un taux global constant, et permet de quantifier l'amélioration apportée par la prise en compte de l'hétérogénéité hebdomadaire.

Résultats

L'implémentation du PPNH paramétrique sur les données ACN-Data a porté sur l'estimation d'un taux d'arrivée distinct pour chaque jour de la semaine. Cette section présente les résultats détaillés de l'estimation et les distributions observées.

Estimation des taux par jour de la semaine. Le tableau 5.2 résume les taux estimés $\hat{\lambda}_d$ pour chaque jour ouvré, ainsi que le nombre d'occurrences de chaque jour dans la période d'observation (25 mars 2019 - 28 février 2020, jours ouvrés uniquement).

TABLE 5.2 – Estimation des taux $\hat{\lambda}$ par jour de la semaine (ACN-Data)

Jour de la semaine	$\hat{\lambda}_d$ (sess/jour)	Nombre de jours	Total sessions
Lundi	5,8000	45	261
Mardi	4,3636	44	192
Mercredi	5,0000	44	220
Jeudi	5,8409	44	257
Vendredi	6,2609	46	288

L'hétérogénéité hebdomadaire est clairement visible. Le jeudi et vendredi présentent les taux les plus élevés (respectivement 5,84 et 6,26 sessions par jour), tandis que le mardi affiche le taux le plus bas (4,36 sessions par jour). Le rapport entre le jour le plus actif (vendredi) et le moins actif (mardi) est de $6,26/4,36 \approx 1,44$, soit une variation de 44% d'un extrême à l'autre. Cette variabilité corrobore l'observation du tableau 3.2 du chapitre 3, où vendredi concentrait 288 sessions contre 192 pour mardi sur l'ensemble de la période.

Distribution empirique versus modèles. La figure 5.1 compare, en trois panneaux, les distributions des comptes journaliers observés, du modèle de Poisson homogène (paramètre $\lambda = 5,4619$), et du modèle PPNH stratifié par jour.




FIGURE 5.1 – ACN-Data : Distribution empirique des comptes journaliers comparée aux prédictions du modèle de Poisson homogène et du PPNH. (Gauche) Histogramme empirique en barres bleues, superposé aux courbes théoriques du modèle homogène (orange) et du PPNH stratifié par jour (vert). (Droite) Taux estimés $\hat{\lambda}_d$ pour chaque jour de la semaine, avec la ligne pointillée rouge représentant le taux global $\hat{\lambda} = 5,46$ du modèle homogène.

Le panneau gauche met en évidence trois observations importantes :

1. **Concentration autour de 4-5 sessions.** La distribution empirique (barres bleues) affiche un pic prononcé entre 4 et 5 sessions par jour, où la fréquence atteint environ 20%. Cette étroitesse suggère une forte régularité quotidienne.
2. **Meilleur ajustement du PPNH.** La courbe verte (PPNH) épouse mieux l'histogramme empirique que la courbe orange (homogène), notamment aux extrêmes (petites et grandes valeurs). Le modèle PPNH capture mieux les pics et creux de la distribution observée.
3. **Queue résiduelle.** Même le PPNH n'élimine pas entièrement les écarts, notamment pour les valeurs élevées (13-15 sessions). Cette persistance suggère une source de variabilité non encore capturée, probablement la tendance progressive du site entre mars et août 2019.

Le panneau droit visualise les taux $\hat{\lambda}_d$ estimés pour chaque jour (barres colorées) et les compare à la moyenne homogène $\hat{\lambda} = 5,46$ (ligne pointillée rouge). La variation autour de cette moyenne est clairement visible, avec mardi situé 20% en-dessous et vendredi 15% au-dessus.

Tableau comparatif des probabilités. Le tableau 5.3 présente, pour les valeurs de comptes allant de 0 à 15 sessions par jour, une comparaison détaillée des probabilités ou fréquences observées, prédites par le modèle homogène, et prédites par le PPNH.

Ce tableau révèle les points de tension entre les modèles et les données :

TABLE 5.3 – Comparaison des fréquences/probabilités : empirique vs Poisson homogène vs PPNH

k	Empirique	Homogène	PPNH	Écart (Emp - PPNH)
0	0,0000	0,0042	0,0054	-0,0054
1	0,0717	0,0232	0,0270	0,0447
2	0,0583	0,0633	0,0683	-0,0100
3	0,1121	0,1153	0,1175	-0,0054
4	0,2063	0,1574	0,1544	0,0519
5	0,0987	0,1720	0,1652	-0,0665
6	0,1256	0,1566	0,1498	-0,0242
7	0,1166	0,1222	0,1182	-0,0016
8	0,0897	0,0834	0,0828	0,0069
9	0,0538	0,0506	0,0522	0,0016
10	0,0179	0,0276	0,0299	-0,0120
11	0,0045	0,0137	0,0157	-0,0112
12	0,0090	0,0062	0,0076	0,0014
13	0,0135	0,0026	0,0035	0,0100
14	0,0000	0,0010	0,0015	-0,0015
15	0,0224	0,0004	0,0006	0,0218

- **Pour $k = 4$ (pic empirique) :** L'empirique affiche 0,2062, le modèle homogène prédit 0,1656 (sous-estime de 20%), et le PPNH prédit 0,1587 (sous-estime de 23%). Aucun des deux modèles ne capture l'importance de cette valeur centrale.
- **Pour $k = 5$ (plateau) :** L'empirique est 0,1084, l'homogène prédit 0,1800 (sur-estime de 66%), tandis que le PPNH prédit 0,1780 (sur-estime de 64%).
- **Pour $k \geq 10$:** Le PPNH se rapproche mieux de l'empirique que l'homogène, montrant que la stratification par jour capture mieux les queues de distribution.

Analyse comparative

L'objectif de cette section est de comparer quantitativement l'ajustement du modèle PPNH à celui du modèle homogène, en utilisant trois critères : l'indice de dispersion, le test du chi-deux, et l'interprétation substantielle des améliorations.

Indice de dispersion. Rappelons que l'indice de dispersion $I_d = \text{Var}(X)/E[X]$ est la signature de la loi de Poisson. Pour un modèle parfaitement ajusté, on attend $I_d = 1$; toute valeur supérieure signale une surdispersion.

Pour le modèle homogène (chapitre 3), nous avons observé :

$$I_d^{\text{homogène}} = 1,5681.$$

Pour le modèle PPNH, en tenant compte de la variabilité inter-jours, la variance théo-

rique devient :

$$\text{Var}_{\text{PPNH}}(X) = E[\lambda_{\text{dow}}] + \text{Var}[\lambda_{\text{dow}}] = 5,4531 + 0,5789 = 6,0319,$$

où $E[\lambda_{\text{dow}}] = 5,4531$ (moyenne pondérée des taux par jour) et $\text{Var}[\lambda_{\text{dow}}] = 0,5789$ (variance inter-groupes).

L'indice de dispersion théorique du PPNH est alors :

$$I_d^{\text{PPNH}} = \frac{6,0319}{5,4531} = 1,1062.$$

Ceci représente une amélioration remarquable :

$$\frac{I_d^{\text{homogène}} - I_d^{\text{PPNH}}}{I_d^{\text{homogène}}} = \frac{1,5681 - 1,1062}{1,5681} = 29,46\%.$$

Interprétation. La réduction de 29% de l'indice de dispersion démontre que le PPNH capture environ 29% de la surdispersion observée. Bien que ce ne soit pas une élimination complète de la surdispersion résiduelle, c'est une amélioration substantielle qui valide l'intuition selon laquelle les variations jour-à-jour constituent une source majeure de variabilité dans les données.

Test du chi-deux. Nous avons appliqué un test d'adéquation du chi-deux pour évaluer si la distribution empirique des comptes concorde avec la distribution théorique du PPNH. Les résultats sont résumés dans le tableau 5.4.

TABLE 5.4 – Résultats des tests du chi-deux : Homogène vs PPNH

Modèle	χ^2	ddl	p -valeur	Conclusion
Poisson homogène	36,15	8	$< 0,001$	Rejeté
PPNH (stratifié jour)	29,32	9	0,000573	Rejeté

Bien que le PPNH réduise la statistique du chi-deux de 36,15 à 29,32, cette dernière reste significativement supérieure au seuil critique (environ 19,68 pour 9 degrés de liberté au seuil 5%), et la p -valeur (0,000573) reste bien inférieure à 0,05.

Interprétation. Le rejet persistant du PPNH signale qu'il existe encore des écarts structurels entre la distribution empirique et le modèle, même après stratification par jour de la semaine. Ces écarts résiduels peuvent provenir de plusieurs sources :

1. **Tendance intra-période.** La montée en charge progressive du site entre mars et août 2019 n'est pas capturée par une simple stratification hebdomadaire. Une modélisation par mois, ou un terme de tendance, pourrait améliorer l'ajus-

tement.

2. **Clustering ou dépendance temporelle.** Les sessions ne sont peut-être pas parfaitement indépendantes ; certains jours connaissent des pics liés à des événements externes non observés.
3. **Effets non linéaires.** L'interaction entre jour et mois pourrait être non linéaire, exigeant un modèle plus riche.

Conclusion partielle. Le modèle PPNH constitue une nette amélioration par rapport au modèle homogène : l'indice de dispersion baisse de 29%, et la statistique du chi-deux décroît de 19%. Cependant, l'ajustement demeure imparfait, signalant que la simple stratification par jour de la semaine ne suffit pas à capturer l'intégralité de la variabilité observée. Un modèle plus riche, par exemple incluant des effets mensuels ou une tendance temporelle, pourrait offrir un ajustement encore meilleur.

5.4.6 Implémentation paramétrique sur NYC 311

Méthode

La stratégie méthodologique est identique à celle appliquée à ACN-Data (section 5.4.5). On suppose que le taux d'arrivée $\lambda(t)$ est constant par strate temporelle et l'on estime chaque paramètre par maximum de vraisemblance selon la formule générale

$$\hat{\lambda}_i = \frac{S_i}{n_i},$$

où S_i est le nombre total d'événements dans la strate i , et n_i le nombre d'occurrences de cette strate sur la période.

Choix de la variable de stratification. La différence principale réside dans le choix de la variable temporelle de stratification. Pour NYC 311, nous stratifions par *heure de la journée* au lieu du jour de la semaine. Cette décision est justifiée par la structure très marquée des données :

- La figure 4.1 du chapitre 4 révèle une variation intra-journalière bimodale prononcée, avec deux pics distincts (matinée et fin d'après-midi) et un creux nocturne quasi vide (0h-6h).
- Le tableau 4.6 avait montré une hétérogénéité hebdomadaire modérée (rapport de 3 entre jeudi et dimanche), bien moins marquée que la structure horaire.

Ainsi, nous supposons :

$$\lambda(t) = \lambda_h, \quad h \in \{0, 1, \dots, 23\},$$

et estimons les 24 taux horaires $\hat{\lambda}_h$ par :

$$\hat{\lambda}_h = \frac{\text{Total de signalements à l'heure } h}{\text{Nombre d'heures de type } h \text{ dans la période}}.$$

Sur la période d'observation (janvier-février 2020, 60 jours = 1438 heures), chaque heure apparaît environ 60 fois.

Évaluation de l'ajustement. Comme pour ACN-Data, l'ajustement du PPNH est évalué selon trois critères :

1. L'indice de dispersion $I_d = \text{Var}(X)/E[X]$, qui devrait décroître lorsque le modèle capture bien la variabilité.
2. Le test du chi-deux d'adéquation entre la distribution empirique et la distribution théorique du PPNH (mélange pondéré des Poisson horaires).
3. Une comparaison graphique des distributions empirique, homogène et PPNH.

Spécificités de NYC 311 : effet jour-à-jour résiduel. Contrairement à ACN-Data, où la stratification par jour de la semaine suffit à capturer l'essentiel de l'hétérogénéité (section 5.4.5), NYC 311 présente une complication supplémentaire.

Le tableau 4.6 du chapitre 4 avait révélé une variation significative selon le jour de la semaine : le jeudi concentre environ 3 fois plus de signalements que le dimanche. Le modèle PPNH stratifié par heure ne tient pas compte de cette variation jour-à-jour. Il en résulte que l'indice de dispersion résiduel après ajustement du PPNH devrait rester supérieur à 1, reflet de cette hétérogénéité hebdomadaire non expliquée.

Pour une modélisation plus complète, on pourrait envisager une interaction *heure* $\times$ *jour de la semaine*, c'est-à-dire un modèle où $\lambda(t)$ dépendrait simultanément de l'heure et du jour. Cela relèverait d'une approche plus avancée, non poursuivie ici.

Limitations et hypothèses. Cette approche suppose que :

- **Stationnarité intra-horaire.** Le taux est constant au sein de chaque heure de 60 minutes. Pour les heures de pointe, où le trafic fluctue rapidement, une stratification par demi-heure ou quart d'heure serait plus précise.
- **Homogénéité jour-à-jour.** Le modèle suppose que le taux à une heure donnée est identique quel que soit le jour de la semaine. Or, le tableau 4.6 montre que ce

n'est pas le cas. Cette hétérogénéité non capturée contribuera à une surdispersion résiduelle.

- **Indépendance.** Les signalements sont supposés indépendants, ce qui peut être violé si un dysfonctionnement unique engendre plusieurs signalements.

Malgré ces limitations, le PPNH stratifié par heure capture la structure bimodale intra-journalière, qui constitue la source majeure de variabilité dans les données NYC 311 (tout comme la stratification par jour capture l'essentiel pour ACN-Data en section 5.4.5). L'effet jour-à-jour demeure comme une source de variabilité secondaire, explicable par d'autres approches.

Résultats

L'implémentation du PPNH paramétrique sur les données NYC 311 a porté sur l'estimation d'un taux d'arrivée distinct pour chaque heure de la journée. Cette section présente les résultats détaillés de l'estimation et les distributions observées.

Estimation des taux par heure de la journée. Le tableau 5.5 résume les taux estimés $\hat{\lambda}_h$ pour chaque heure de la journée (0h-23h), ainsi que le nombre d'occurrences de chaque heure dans la période d'observation (janvier-février 2020, 60 jours = 1438 heures).

TABLE 5.5 – Estimation des taux $\hat{\lambda}_h$ par heure de la journée (NYC 311)

Heure	$\hat{\lambda}_h$	n_h	Total	Heure	$\hat{\lambda}_h$	n_h	Total
00h	0,1333	60	8	12h	0,6333	60	38
01h	0,1833	60	11	13h	0,7333	60	44
02h	0,0833	60	5	14h	0,7500	60	45
03h	0,1667	60	10	15h	0,6833	60	41
04h	0,2500	60	15	16h	0,4667	60	28
05h	0,2000	60	12	17h	0,4833	60	29
06h	0,4000	60	24	18h	0,3667	60	22
07h	0,3000	60	18	19h	0,2000	60	12
08h	0,8833	60	53	20h	0,3500	60	21
09h	1,3167	60	79	21h	0,1833	60	11
10h	1,0000	60	60	22h	0,3390	59	20
11h	0,8000	60	48	23h	0,1695	59	10

L'hétérogénéité intra-journalière est spectaculaire. Le pic le plus prononcé apparaît à 9h avec $\hat{\lambda}_9 = 1,3167$ signalements par heure, tandis que le minimum se situe à 2h avec $\hat{\lambda}_2 = 0,0833$ signalements par heure. Le rapport entre l'heure la plus active (9h) et la moins active (2h) est de $1,3167/0,0833 \approx 15,8$, soit une

variation de plus de 1500% d'un extrême à l'autre. Cette variabilité colossale contraste frappamment avec les variations jour-à-jour observées pour ACN-Data (ratio de 1,44, soit 44%), confirmant que la structure intra-journalière domine les données NYC 311.

On distingue clairement trois phases temporelles :

- **Heures creuses (0h-6h)** : Taux entre 0,08 et 0,40 signalements/heure.
- **Heures de pointe (8h-14h)** : Taux entre 0,63 et 1,32 signalements/heure, avec un pic aigu à 9h.
- **Heures déclinantes (15h-23h)** : Taux entre 0,17 et 0,75 signalements/heure, avec un second pic modéré autour de 14h.

Distribution empirique versus modèles. La figure 5.2 compare les distributions des comptes horaires observés, du modèle de Poisson homogène (paramètre $\lambda = 0,4618$), et du modèle PPNH stratifié par heure.




FIGURE 5.2 – NYC 311 : Distribution empirique des comptes horaires comparée aux prédictions du modèle de Poisson homogène et du PPNH. (Gauche) Histogramme empirique en barres bleues, superposé aux courbes théoriques du modèle homogène (orange) et du PPNH stratifié par heure (vert). (Droite) Profil horaire des taux $\hat{\lambda}_h$ pour chaque heure de la journée, avec la ligne pointillée rouge représentant le taux global $\hat{\lambda} = 0,46$ du modèle homogène et une zone grisée marquant les heures creuses (0h-6h).

Le panneau gauche révèle une structure très distincte de celle d'ACN-Data :

1. **Concentration extrême à zéro.** La distribution empirique (barres bleues) affiche une concentration massive à 0 signalements (67,73%), reflétant les longues périodes creuses de nuit. Le modèle homogène prédit 63,01% (sous-estime légèrement), tandis que le PPNH prédit 65,90% (quasi identique à l'empirique).
2. **Heures surchargées vs heures vides.** Contrairement à ACN-Data où le pic était à 4-5 sessions, NYC 311 présente un contraste binaire : soit très peu (0-1), soit un peu plus (2-3). Ceci reflète l'alternance nuit-jour des services municipaux.

3. **Ajustement excellent du PPNH.** Pour $k = 0, 1, 2$, le PPNH épouse presque parfaitement les fréquences empiriques, bien mieux que le modèle homogène.

Le panneau droit visualise le profil horaire des taux $\hat{\lambda}_h$ (courbe bleue marquée par des points), clairement bimodal avec deux pics distincts : un pic principal à 9h (1,32) et un second pic atténué autour de 14h (0,75). La zone grisée marque les heures creuses (0h-6h) où l'activité est quasi inexistante.

Tableau comparatif des probabilités. Le tableau 5.6 présente, pour les valeurs de comptes allant de 0 à 7 signalements par heure, une comparaison détaillée des probabilités observées, prédites par le modèle homogène, et prédites par le PPNH.

TABLE 5.6 – Comparaison des fréquences/probabilités : empirique vs Poisson homogène vs PPNH (NYC 311)

k	Empirique	Homogène	PPNH	Écart (Emp - PPNH)
0	0,6773	0,6301	0,6590	0,0183
1	0,2239	0,2910	0,2485	-0,0246
2	0,0675	0,0672	0,0703	-0,0028
3	0,0250	0,0103	0,0175	0,0075
4	0,0042	0,0012	0,0039	0,0003
5	0,0014	0,0001	0,0008	0,0006
6	0,0007	0,0000	0,0001	0,0006
7	0,0000	0,0000	0,0000	0,0000

Ce tableau révèle l'excellente concordance entre l'empirique et le PPNH :

- **Pour $k = 0$:** L'empirique affiche 0,6773, le modèle homogène prédit 0,6301 (sous-estime de 7%), et le PPNH prédit 0,6590 (sous-estime de seulement 3%).
- **Pour $k = 1$:** L'empirique est 0,2239, l'homogène prédit 0,2910 (sur-estime de 30%), tandis que le PPNH prédit 0,2485 (sur-estime de seulement 11%).
- **Pour $k \geq 2$:** Les écarts diminuent drastiquement. Le PPNH capture excellent bien la queue de distribution, bien mieux que l'homogène.

Analyse comparative

L'objectif de cette section est de comparer quantitativement l'ajustement du modèle PPNH à celui du modèle homogène, en utilisant trois critères : l'indice de dispersion, le test du chi-deux, et l'interprétation substantielle des améliorations.

Indice de dispersion. Pour le modèle homogène (chapitre 4), nous avons observé :

$$I_d^{\text{homogène}} = 1,3704.$$

Pour le modèle PPNH, en tenant compte de la variabilité inter-horaire, la variance théorique devient :

$$\text{Var}_{\text{PPNH}}(X) = E[\lambda_h] + \text{Var}[\lambda_h] = 0,4615 + 0,1033 = 0,5648,$$

où $E[\lambda_h] = 0,4615$ (moyenne des taux par heure) et $\text{Var}[\lambda_h] = 0,1033$ (variance inter-heures).

L'indice de dispersion théorique du PPNH est alors :

$$I_d^{\text{PPNH}} = \frac{0,5648}{0,4615} = 1,2238.$$

Ceci représente une amélioration modérée mais significative :

$$\frac{I_d^{\text{homogène}} - I_d^{\text{PPNH}}}{I_d^{\text{homogène}}} = \frac{1,3704 - 1,2238}{1,3704} = 10,70\%.$$

Interprétation. Bien que la réduction de 10,7% soit moins spectaculaire que celle observée pour ACN-Data (29,5%), elle demeure significative. Elle démontre que le PPNH capture environ 11% de la surdispersion observée. Cependant, l'indice résiduel de 1,22 reste élevé, reflet de la variation jour-à-jour non capturée par le modèle horaire seul.

Test du chi-deux. Nous avons appliqué un test d'adéquation du chi-deux pour évaluer si la distribution empirique des comptes horaires concorde avec la distribution théorique du PPNH. Les résultats sont résumés dans le tableau 5.7.

TABLE 5.7 – Résultats des tests du chi-deux : Homogène vs PPNH (NYC 311)

Modèle	χ^2	ddl	p -valeur	Conclusion
Poisson homogène	57,58	2	$< 0,001$	Rejeté
PPNH (stratifié heure)	9,13	4	0,0579	Accepté

Contrairement à ACN-Data où le PPNH était encore rejeté, NYC 311 présente un résultat remarquable : la statistique du chi-deux du PPNH (9,13) tombe en-dessous du seuil critique (environ 9,49 pour 4 degrés de liberté au seuil 5%), et la p -valeur (0,0579) reste justement au-dessus de 0,05.

Conclusion du test. Le modèle PPNH s'ajuste significativement bien aux

données NYC 311. Cela suggère que la structure intra-journalière, une fois capturée par la stratification horaire, explique essentiellement toute la variabilité observable dans les comptes horaires. La variation jour-à-jour, bien que présente (tableau 4.6), n'est pas suffisamment prononcée pour rejeter le modèle PPNH.

Comparaison avec ACN-Data. Ce contraste entre ACN-Data et NYC 311 est instructif :

- **ACN-Data** : Indice I_d réduit de 29,5%, mais PPNH toujours rejeté ($p=0,0006$). La surdispersion résiduelle provient de la tendance progressive (mars-août 2019) non capturée.
- **NYC 311** : Indice I_d réduit de 10,7%, mais PPNH accepté ($p=0,0579$). La variation jour-à-jour, bien qu'existante, ne génère pas de rejet statistique.

Cette différence reflète la nature des données : pour un parking avec une tendance intra-période marquée, la simple stratification temporelle ne suffit pas ; pour un service municipal avec une variation jour-à-jour modérée, la capture du profil intra-journalier suffit largement.

Conclusion partielle. Le modèle PPNH constitue une amélioration spectaculaire pour NYC 311. Non seulement l'indice de dispersion diminue, mais le test du chi-deux passe du rejet catégorique ($p<0,001$) à l'acceptation ($p=0,0579$). Cela valide pleinement la stratégie de modélisation par heure de la journée et démontre que la capture de la structure bimodale intra-journalière est cruciale pour modéliser correctement les signalements de dysfonctionnement de feux.

Le PPNH horaire offre ainsi un modèle parcimonieux, interprétable et statistiquement validé pour les données NYC 311, contrairement au cas ACN-Data où une extension supplémentaire (tendance temporelle ou effets mensuels) serait nécessaire.

5.4.7 Synthèse comparative

Comparaison globale

Le tableau 5.8 présente une synthèse des résultats obtenus pour les deux applications, en comparant le modèle de Poisson homogène au modèle PPNH sur les trois critères clés : le paramètre estimé, l'indice de dispersion, et le résultat du test du chi-deux.

Ce tableau révèle immédiatement deux histoires différentes, bien que les deux applications aboutissent à une amélioration substantielle.

TABLE 5.8 – Comparaison modèles homogène vs non-homogène : ACN-Data et NYC 311

Application	$\hat{\lambda}$	I_d	χ^2	$\hat{\lambda}(t)$	I'_d	Amél. I_d	χ^2 PPNH
ACN-Data	5,4619	1,5681	36,15	[par jour]	1,1062	29,46%	29,32
NYC 311	0,4618	1,3704	57,58	[par heure]	1,2238	10,70%	9,13

Pour **ACN-Data**, le PPNH stratifié par jour de la semaine réduit l'indice de dispersion de 29,46%, ramenant I_d de 1,5681 à 1,1062. Cette réduction spectaculaire démontre que la variabilité hebdomadaire représente une source majeure de non-stationnarité. Le test du chi-deux passe de $\chi^2 = 36,15$ (rejeté) à $\chi^2 = 29,32$, une amélioration de 19%, mais le rejet persiste avec une p -valeur de 0,000573. Cette persistance indique que, bien que le PPNH capture l'hétérogénéité jour-à-jour, une source de variabilité supplémentaire subsiste : probablement la tendance progressive observée entre mars et août 2019.

Pour **NYC 311**, le PPNH stratifié par heure réalise une amélioration plus modérée en termes d'indice de dispersion (10,70%, ramenant I_d de 1,3704 à 1,2238), mais atteint un résultat remarquable au test du chi-deux : $\chi^2 = 9,13$ avec une p -valeur de 0,0579, ce qui signifie **l'acceptation du modèle PPNH** au seuil 5%. Cette différence traduit une caractéristique structurelle des données : pour NYC 311, la variation intra-journalière est prédominante, tandis que la variation jour-à-jour, bien que présente, reste secondaire. Une fois la structure horaire capturée, le modèle est statistiquement validé.

Ajustement à la réalité

Question 1 : Le PPNH réduit-il l'indice de dispersion vers 1 ? Oui, mais de manière inégale selon l'application. Pour ACN-Data, l'indice passe de 1,5681 à 1,1062, se rapprochant significativement de la valeur idéale 1. Pour NYC 311, il passe de 1,3704 à 1,2238, une amélioration plus modérée en pourcentage relatif, mais qui suffit à qualifier le modèle d'acceptable au seuil statistique.

Dans les deux cas, l'indice résiduel demeure supérieur à 1, ce qui indique qu'une surdispersion persiste. Pour ACN-Data, cette surdispersion résiduelle reflète probablement des variations intra-mensuelles (montée en charge progressive) non capturées par la stratification hebdomadaire. Pour NYC 311, elle reflète la variation jour-à-jour, admise lors de la spécification du modèle comme une source secondaire non modélisée.

Question 2 : Les distributions empiriques concordent-elles mieux avec le PPNH qu'avec le modèle homogène ? Oui, clairement dans les deux

cas, comme le montrent les figures 5.1 et 5.2.

Pour **ACN-Data** (figure 5.1, panneau gauche), la courbe verte (PPNH) épouse mieux l'histogramme empirique que la courbe orange (homogène), notamment dans la région des valeurs 4-7 sessions par jour où la distribution empirique affiche des concentrations locales plus marquées que le modèle homogène n'en prédit. Le PPNH capture mieux ces structures de pic.

Pour **NYC 311** (figure 5.2, panneau gauche), l'amélioration est encore plus frappante. Le PPNH prédit 65,90% de probabilité pour 0 signalement, contre 67,73% empiriquement, soit une erreur de seulement 3%. L'homogène prédisait 63,01%, soit une erreur de 7%. Pour $k = 1$, le PPNH prédit 24,85% contre 22,39% empiriquement (erreur de 11%), tandis que l'homogène prédisait 29,10% (erreur de 30%). Cette amélioration du PPNH sur la queue de distribution est particulièrement visible pour $k \geq 2$.

Graphiquement, on observe une meilleure capture de la bimodalité intra-journalière (figure 5.2, panneau droit) : le profil horaire des taux $\hat{\lambda}_h$ reflète clairement les deux pics (matin et fin d'après-midi) et le creux nocturne que seul le PPNH peut reproduire.

Question 3 : Existe-t-il une surdispersion résiduelle après le PPNH ?

Oui, dans les deux cas, mais avec des implications différentes.

Pour **ACN-Data**, l'indice résiduel $I'_d = 1,1062$ reste supérieur à 1 de 10,62%. Cette surdispersion résiduelle est probablement due à la montée en charge progressive du site. Les données du tableau 3.5 montraient une activité très faible en mars 2019 (10 sessions), puis une hausse progressive jusqu'aux 137-162 sessions par mois observées en septembre 2019 et février 2020. Cette tendance temporelle n'est pas capturée par une simple stratification hebdomadaire, qui suppose un niveau d'activité constant d'une semaine à l'autre.

Pour **NYC 311**, l'indice résiduel $I'_d = 1,2238$ reste supérieur à 1 de 22,38%. Cette surdispersion résiduelle est explicitement admise dans la spécification du modèle : elle reflète la variation jour-à-jour non modélisée, visible au tableau 4.6 où le jeudi concentre environ 3 fois plus de signalements que le dimanche. Le PPNH horaire ne capture que la structure intra-journalière ; l'hétérogénéité hebdomadaire subsiste donc naturellement comme source de variabilité secondaire.

La différence conceptuelle est importante : pour ACN-Data, la surdispersion résiduelle représente une *limitation* du modèle actuel, qui appellerait une extension supplémentaire. Pour NYC 311, elle représente une *acceptation consciente*

d'une source de variabilité jugée secondaire au regard de l'amélioration majeure apportée par la capture de la structure horaire.

Interprétation

Cas ACN-Data. Le modèle non-homogène améliore significativement l'ajustement pour ACN-Data, réduisant la surdispersion de 29,46% et montrant que les variations jour-à-jour représentent une source substantielle de non-stationnarité capturée par la structure paramétrique $\lambda(t) = \lambda_d$ pour $d \in \{\text{lun, mar, } \dots, \text{ven}\}$.

Les cinq taux estimés, $\hat{\lambda}_{\text{lun}} = 5,80$, $\hat{\lambda}_{\text{mar}} = 4,36$, $\hat{\lambda}_{\text{mer}} = 5,00$, $\hat{\lambda}_{\text{jeu}} = 5,84$, $\hat{\lambda}_{\text{ven}} = 6,26$, révèlent clairement un pattern : l'activité est minimale le mardi et maximale le vendredi. Cette alternance reflète probablement les comportements de recharge liés aux patterns de travail sur le campus Caltech : des trajets moins fréquents en début de semaine, une accélération en fin de semaine.

Cependant, le PPNH jour-à-jour n'élimine pas entièrement la déviation au modèle : le test du chi-deux reste rejeté avec $p = 0,000573$. Cela signale qu'une source supplémentaire de variabilité non capturée persiste. L'analyse descriptive du chapitre 3 avait mis en évidence une montée en charge progressive entre mars et août 2019 (tableau 3.5). Cette tendance temporelle, absente d'une stratification purement hebdomadaire, explique probablement les écarts résiduels, notamment la concentration empirique à 4 sessions (20,6% vs 15,4% prédit) et à 5 sessions (9,9% vs 16,5% prédit). Un modèle enrichi, par exemple $\lambda(t) = \lambda_d \cdot f(\text{mois})$ combinant jour et tendance mensuelle, pourrait améliorer encore l'ajustement.

Cas NYC 311. Le modèle non-homogène améliore très significativement l'ajustement pour NYC 311, réduisant la surdispersion de 10,70% et, surtout, passant du rejet catégorique (test du chi-deux, $p < 0,001$) à l'acceptation ($p = 0,0579$). Cela démontre que les variations temporelles prévisibles – en particulier la structure bimodale intra-journalière – sont bien capturées par la structure paramétrique $\lambda(t) = \lambda_h$ pour $h \in \{0, 1, \dots, 23\}$.

Les 24 taux horaires estimés (tableau 5.5) révèlent un profil remarquablement régulier et interprétable. Les heures creuses nocturnes (0h-6h), avec des taux entre 0,08 et 0,40 signalements/heure, reflètent la faible circulation urbaine et l'activité réduite des services municipaux la nuit. Le pic matinal (8h-11h), avec des taux entre 0,88 et 1,32 signalements/heure, correspond aux heures de trafic maximum et à l'activation progressive des équipes municipales. Le pic d'après-midi (13h-15h), avec des taux entre 0,68 et 0,75 signalements/heure, reflète une activité résiduelle mais notable. Le déclin en soirée (18h-23h) traduit la réduction

de l'activité urbaine et le désengagement progressif des services.

Cette régularité et cette interprétabilité du profil horaire, combinées à l'acceptation statistique du modèle, suggèrent que le PPNH horaire constitue une description satisfaisante et parcimonieuse de la dynamique des signalements de dysfonctionnement de feux à New York. La surdispersion résiduelle de 22,4% reflète uniquement la variation jour-à-jour non modélisée, qui demeure secondaire en comparaison de la structure horaire dominante.

Synthèse comparative : deux régimes de non-stationnarité. Ces deux applications illustrent deux régimes de non-stationnarité distincts, chacun appelant une stratégie de modélisation adaptée.

ACN-Data présente une non-stationnarité **cyclique et de long terme**. La variation hebdomadaire est régulière et prévisible, mais elle est superposée à une tendance progressive de montée en charge du site. Cette combinaison de cyclicité et de tendance exige un modèle capable de capturer les deux composantes. Un PPNH enrichi, incorporant à la fois l'effet jour et un terme de tendance ou des effets mensuels, serait requis pour une modélisation satisfaisante.

NYC 311 présente une non-stationnarité **intra-journalière et structurelle**. La variation horaire est le résultat direct de rythmes urbains immuables : heures de pointe matin et soir, creux nocturne, fin de semaine réduite. Ces rythmes sont gouvernés par des facteurs externes et relativement stables au fil du temps (tant qu'on ne considère pas de ruptures majeures comme des confinements ou des changements de politique urbaine). Une fois cette structure horaire capturée, le modèle atteint une adéquation statistique satisfaisante.

Cette distinction soulève une question méthodologique générale : le choix de la stratégie de modélisation dépend fondamentalement de la nature de la non-stationnarité observée. Un processus dominé par des cycles réguliers (heures, jours de semaine) peut être modélisé par un PPNH paramétrique simple. Un processus comportant des tendances temporelles plus longues (mois, années) ou des changements structurels ponctuels nécessite des approches additionnelles : inclusion de covariables temporelles, modèles bayésiens hiérarchiques avec évolution temporelle, ou méthodes de segmentation pour identifier des phases distinctes.

Conclusion de la synthèse. Les résultats de ce chapitre valident la pertinence du processus de Poisson non homogène comme extension naturelle du modèle homogène pour des données urbaines et d'infrastructures partagées. Le

PPNH capture les variations temporelles prévisibles qui avaient invalidé le modèle homogène, et fournit dans le cas de NYC 311 une description statistiquement satisfaisante des données. Cependant, il ne représente pas une panacée : pour ACN-Data, une modélisation encore plus sophistiquée serait bénéfique, tandis que pour NYC 311, l'acceptation du modèle PPNH horaire signifie que la capture de la structure dominante suffit pour les objectifs pratiques, même si une surdispersion résiduelle subsiste.

Ce dernier point souligne une tension méthodologique importante : la distinction entre adéquation statistique et utilité pratique. Un modèle peut ne pas être rejeté statistiquement et rester imparfait au regard d'une analyse plus fine. Inversement, un modèle peut être rejeté statistiquement tout en étant utile à des fins de prévision ou de planification. Le choix du modèle dépend donc du contexte, des objectifs de l'analyse, et des compromis acceptables entre simplicité et fidélité.

Conclusion générale

Ce travail avait pour objectif d'étudier le processus de Poisson depuis ses fondements théoriques jusqu'à son application à des données réelles. La démarche suivie a consisté à comprendre le modèle, à le valider par simulation, puis à le confronter à deux jeux de données de nature différente, ACN-Data et NYC 311.

Le chapitre 1 a permis de poser les bases du modèle en montrant comment le processus de Poisson émerge naturellement d'hypothèses simples sur des arrivées indépendantes. À partir d'un unique paramètre λ , on obtient une structure probabiliste cohérente, avec la loi de Poisson pour le compteur, la loi exponentielle pour les temps inter-arrivées, la propriété sans mémoire, ainsi que les résultats de superposition et d'amincissement.

Le chapitre 2 a ensuite joué un rôle de vérification. Les simulations réalisées sous R puis sous Python ont confirmé de façon convaincante les résultats théoriques. Dans les deux cas, la relation fondamentale

$$\mathbb{E}[N(\tau)] = \text{Var}(N(\tau)) = \lambda\tau$$

a été retrouvée numériquement, et les tests statistiques n'ont pas conduit à rejeter les hypothèses d'adéquation. Cette étape a été importante, car elle a permis d'établir un cadre de référence solide avant de passer à l'analyse de données réelles.

Les chapitres 3 et 4 ont constitué le cœur applicatif du travail. Le modèle de Poisson homogène y a été confronté à deux flux différents : les arrivées de sessions de recharge sur un parking de bureau, puis les signalements de dysfonctionnement de feux de signalisation dans le Bronx. Dans les deux cas, les tests statistiques ont conduit au rejet du modèle homogène. Ce résultat n'est cependant pas un échec du modèle ; il montre plutôt que les flux réels ne sont pas gouvernés par un taux constant dans le temps.

Pour ACN-Data, l'écart au modèle homogène s'explique notamment par une variabilité selon le jour de la semaine et par une évolution progressive du niveau

d'activité du site. Pour NYC 311, l'écart provient surtout d'une forte structure horaire, avec des pics d'activité et des périodes creuses bien marquées. Autrement dit, les deux jeux de données conduisent au même constat général, mais pour des raisons différentes.

Le chapitre 5 a permis de prolonger cette analyse en introduisant le processus de Poisson non homogène. Cette extension conserve le cadre probabiliste du modèle de base, tout en autorisant le taux d'arrivée à varier dans le temps. Les résultats obtenus montrent que cette approche améliore l'ajustement. Dans le cas de NYC 311, elle permet de prendre en compte de manière satisfaisante la structure horaire du flux. Dans le cas d'ACN-Data, l'amélioration est réelle, mais elle ne suffit pas encore à absorber toute la variabilité observée, ce qui suggère que la structure du flux y est plus complexe.

Au terme de ce travail, une idée essentielle se dégage. Le processus de Poisson homogène reste un modèle de référence précieux : simple, lisible et mathématiquement rigoureux, il fournit une première approximation utile du flux moyen d'arrivées. Mais dès que les données présentent des rythmes temporels marqués, cette version homogène devient trop restrictive. Le processus de Poisson non homogène apparaît alors comme une extension naturelle, à la fois cohérente sur le plan théorique et plus fidèle aux données.

Ce TER montre ainsi qu'en statistique appliquée, la valeur d'un modèle ne tient pas seulement à son élégance mathématique, mais aussi à sa capacité à dialoguer avec les données. Comprendre un modèle, c'est aussi savoir reconnaître le moment où il faut le faire évoluer. C'est dans cet équilibre entre rigueur théorique et attention portée au réel que se construit, au fond, la démarche de modélisation.

Bibliographie

- [1] J. Tsitsiklis et P. Jaillet, *Introduction to Probability — Lecture 22 : The Poisson Process Part I*, MIT OpenCourseWare, 2018.
- [2] J. Tsitsiklis et P. Jaillet, *Introduction to Probability — Lecture 23 : More on the Poisson Process*, MIT OpenCourseWare, 2018.
- [3] Harvard University, *Stats 110 : Introduction to Probability*, 2023.
- [4] H. P. Keeler, *Poisson Point Processes*, notes de cours, 2018.
- [5] ACN-Data, *A Public EV Charging Dataset*. <https://ev.caltech.edu/dataset>
- [6] Z. J. Lee, T. Li et S. H. Low, *ACN-Data : Analysis and Applications of an Open EV Charging Dataset*, ACM e-Energy, 2019.
- [7] NYC Open Data, *311 Service Requests from 2020 to Present*. <https://data.cityofnewyork.us>
- [8] C. R. Harris et al., *Array programming with NumPy*, Nature, 585, 357–362, 2020.
- [9] P. Virtanen et al., *SciPy 1.0 : Fundamental Algorithms for Scientific Computing in Python*, Nature Methods, 17, 261–272, 2020.
- [10] H. Wickham, *ggplot2 : Elegant Graphics for Data Analysis*, Springer-Verlag, 2016.
- [11] M. L. Delignette-Muller et C. Dutang, *fitdistrplus : An R Package for Fitting Distributions*, Journal of Statistical Software, 64(4), 2015.
- [12] A. C. Cameron et P. K. Trivedi, *Regression Analysis of Count Data*, 2^e édition, Cambridge University Press, 2013.