

01 BP 1515 Lomé 01 – TOGO
Tel : (0028) 22 25 33 29 Fax : (0028) 22 21 85 95
Site web: www.univ-lome.tg

UTBM – 90010 BELFORT CEDEX
Tel : +33 (0) 3 84 58 30 00 Fax : +33 (0) 3 84 58 30
Site web : www.utbm.fr

MEMOIRE DE FIN DE FORMATION

Pour l'obtention du diplôme de
MASTER EN INFORMATIQUE

Spécialité : Intelligence Artificielle et Big Data

Promotion 2022-2024

N° d'ordre : 2025/MIA- 001

Thème

**CONCEPTION ET DEVELOPPEMENT D'UN SYSTEME
D'IDENTIFICATION BIOMETRIQUE MULTIMODAL
INTEGRANT LES RECONNAISSANCES FACIALE, VOCALE
ET RECONNAISSANCE OPTIQUE DE CARACTERES**

Présenté et soutenu publiquement le 09 août 2025

HONOU Koessivi Jean

Devant le jury composé de :

Président de jury : **Prof LARE Y.,** Enseignant Chercheur à l'UL (FDS)

Examineur : **Dr PALANGA Eyouléki T. G.,** Maître de
Conférences, Enseignant-Chercheur à l'UL

Directeur de mémoire : **MAO Barèrèm-Mêlgueba, Ph.D.**
Enseignant-Chercheur à l'UL / Maître de Conférences

DEDICACE

Je dédie cet ouvrage à ma mère, source inépuisable de ma motivation quotidienne. Elle qui, à chaque étape de ce parcours, m'a soutenu avec tant de bienveillance et d'encouragement. Je tiens ici à lui exprimer ma plus profonde gratitude.

À mon frère et à mes sœurs adorées, qui ont toujours veillé sur moi avec affection et attention. Vous avez été des piliers tout au long de cette aventure.

À tous ceux qui ont partagé avec moi des moments riches en émotions tout au long de la réalisation de ce travail. Vous avez su m'encourager et me soutenir, et je vous en suis infiniment reconnaissant.

Que Dieu vous bénisse.

REMERCIEMENTS

Au terme de ce mémoire de master, je tiens à exprimer ma profonde gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à l'élaboration et à l'aboutissement de ce travail.

Je remercie tout particulièrement mon directeur de mémoire, D. MAO Barèrèm-Mêlgueba,

Ph. D, pour son encadrement rigoureux, ses conseils avisés et son accompagnement constant tout au long de cette recherche. J'exprime également ma reconnaissance à l'ensemble des enseignants, chercheurs et collaborateurs des laboratoires LPMCS et LARSI, ainsi qu'à mes professeurs de l'EPL et à mes camarades de promotion pour leur soutien, leur disponibilité et leurs encouragements.

Mes remerciements s'adressent aussi à ma famille, en particulier à mes parents, mon frère et mes sœurs, pour leur soutien moral, affectif et spirituel qui a constitué un véritable moteur tout au long de ce parcours.

Je tiens enfin à adresser une mention spéciale au jury de soutenance, composé du Prof. LARE Y., Président du jury, de D. PALANGA E., Examineur, et de D. MAO Barèrèm-Mêlgueba, Ph. D, Directeur de mémoire. Je leur suis reconnaissant pour le temps qu'ils ont consacré à l'évaluation de ce travail, pour leurs remarques constructives et pour leurs suggestions pertinentes qui ont permis d'améliorer la qualité scientifique de ce mémoire.

À toutes ces personnes et à tous ceux qui, d'une manière ou d'une autre, ont contribué à la réalisation de ce projet, j'exprime ma sincère reconnaissance.

.

RESUME

Ce travail de stage, réalisé au sein des laboratoires **LPMCS & LARSI**, s'inscrit dans le domaine de la reconnaissance biométrique multimodale et de l'extraction de caractères. Les systèmes d'authentification actuels, basés sur des méthodes traditionnelles telles que le remplissage manuel de formulaires, présentent plusieurs inconvénients, notamment une lenteur de traitement, des erreurs humaines fréquentes et une faible sécurité face aux tentatives de fraude. Dans le domaine des télécommunications, ces faiblesses nuisent à la qualité du service et à la satisfaction des utilisateurs. Pour répondre à ces défis, l'objectif principal de ce projet est de concevoir un système multimodal d'extraction de texte à partir de documents, tout en développant une application permettant l'identification et la reconnaissance des individus à travers plusieurs traits biométriques, tels que la reconnaissance faciale et vocale. L'application repose sur des technologies avancées d'intelligence artificielle, incluant **FaceNet** pour la reconnaissance faciale, **Wav2Vec2.0** pour le traitement du signal vocal, et **EasyOCR** pour la reconnaissance optique de caractères (en anglais : optical character recognition OCR). Ces technologies assurent une identification biométrique précise et fiable, tout en extrayant automatiquement des informations textuelles à partir d'images de documents. L'interface utilisateur, développée avec **Tkinter**, facilite l'acquisition en temps réel des données biométriques et textuelles, garantissant une expérience fluide et intuitive. Les résultats des tests effectués montrent une bonne précision des différents modules, malgré quelques difficultés liées aux variations d'éclairage ou aux bruits de fond pour la reconnaissance faciale et vocale. Ces résultats sont discutés en détail afin d'identifier les points forts du système ainsi que les possibilités d'amélioration. Cette solution vise à offrir une méthode rapide, précise et sécurisée pour l'enregistrement et l'authentification des abonnés ou des utilisateurs, répondant aux besoins actuels en matière d'identification biométrique et documentaire.

Mots clés : Extraction de texte, Reconnaissance multimodale, Reconnaissance faciale, Reconnaissance vocale, Intelligence Artificielle

ABSTRACT

This internship work, conducted within the **LPMCS & LARSI** laboratories, focuses on multimodal biometric recognition and character extraction. Current authentication systems, based on traditional methods such as manual form filling, have several drawbacks, including slow processing, frequent human errors, and low security against fraud attempts. In the telecommunications sector, these weaknesses impact on service quality and customer satisfaction. To address these challenges, the main objective of this project is to design a multimodal system for text extraction from documents while developing an application that allows for the identification and recognition of individuals through multiple biometric features, such as facial and vocal recognition. The application relies on advanced artificial intelligence technologies, including **FaceNet** for facial recognition, **Wav2Vec2.0** for voice signal processing, and **EasyOCR** for optical character recognition (OCR). These technologies ensure precise and reliable biometric identification while automatically extracting textual information from document images. The user interface, developed with **Tkinter**, facilitates real-time acquisition of biometric and textual data, ensuring a smooth and intuitive experience. The results of the tests show good accuracy of the various modules, despite some challenges related to lighting variations or background noise for facial and vocal recognition. These results are discussed in detail to identify the strengths of the system as well as potential areas for improvement. This solution aims to provide a fast, precise, and secure method for subscriber registration and authentication, meeting current needs for biometric and document-based identification.

Keywords: Text extraction, Multimodal recognition, Facial recognition, Speech recognition, Artificial Intelligence

TABLE DES MATIERES

DEDICACE	I
REMERCIEMENTS	II
RESUME	III
ABSTRACT	IV
LISTES DES FIGURES	VIII
LISTES DES TABLEAUX.....	IX
INTRODUCTION GENERALE	1
CHAPITRE 1	4
ETAT DE L'ART DE L'IDENTIFICATION BIOMETRIQUE	4
1.1 INTRODUCTION	5
1.2 RECONNAISSANCE BIOMETRIQUES	5
1.2.1 Définition et principe généraux	5
1.2.2 Architecture d'un système biométrique	6
1.2.3 Mode de fonctionnement d'un système biométrique.....	7
1.2.4 Avantages des systèmes biométriques.....	8
1.3 RECONNAISSANCE FACIALE	8
1.3.1 Historique et évolution de la reconnaissance faciale	8
1.3.2 Méthodes classiques.....	8
1.3.2.3 Méthodes Hybrides.....	13
1.3.2.4 Détecteurs et Descripteurs de Points d'Intérêt	14
1.3.3 Intelligence Artificielle	19
1.3.3.1 Machine Learning.....	20
1.3.3.2 Deep Learning et Reconnaissance Faciale	21
1.4 RECONNAISSANCE AUTOMATIQUE DE LOCUTEUR	28
1.4.1 Principes fondamentaux de la reconnaissance automatique du locuteur.....	29
1.4.1.1 Branches de la RAL	29
1.4.1.2 Modalités de RAL.....	32
1.4.2 Extraction des caractéristiques.....	33
1.4.3 Modélisation du locuteur.....	36
1.4.4 Approches modernes de la RAL	38
1.4.5 Approche i-vector/PLDA	39
1.4.5.1 i-vector.....	39
1.4.5.2 Analyse discriminante linéaire probabiliste (PLDA)	39
1.4.6 Deep learning et Reconnaissance automatique de locuteur	40
1.4.6.1 Réseaux de Neurones Profonds (DNN)	40
1.4.6.2 Réseaux Convolutionnels (CNN)	41
1.4.6.3 Réseaux Récurrents (RNN) et LSTM	41
1.4.6.4 Réseaux Antagonistes Génératifs (GAN)	42
1.4.6.5 Apprentissage Auto-Supervisé (Self-Supervised Learning)	42
1.5 CONCLUSION.....	43
CHAPITRE 2	44
ETAT DE L'ART DE LA RECONNAISSANCE OPTIQUE DE CARACTERE.....	44

.....

2.1	INTRODUCTION	45
2.2	RECONNAISSANCE OPTIQUE DE CARACTERE	45
2.2.1	<i>Méthodes traditionnelles</i>	45
2.2.2	<i>Méthodes basées sur des Réseaux de neurones.....</i>	46
2.2.2.1	<i>Reconnaissance de caractères.....</i>	46
2.2.2.2	<i>Reconnaissance de mots</i>	47
2.2.3	<i>Détection et reconnaissance de caractère.....</i>	47
2.3	DETECTION DE ZONES DE TEXTES	48
2.3.1	<i>Méthodes basées sur la détection de régions</i>	48
2.3.1.1	<i>Détection de régions : Méthodes par composantes connexes et approche ascendante</i>	48
2.3.1.2	<i>Détection de régions : Approche par fenêtres glissantes</i>	49
2.3.2	<i>Méthodes basées sur le Deep Learning</i>	50
2.4	CONCLUSION.....	51
CHAPITRE 3		52
MATERIEL ET METHODE		52
.....		
3.1	INTRODUCTION	53
3.2	RECONNAISSANCE FACIALE AVEC OPENCV ET METHODES AVANCEES DE DEEP LEARNING	53
3.2.1	<i>Comparaison des techniques de reconnaissance faciale</i>	53
3.2.2	<i>Justification du Choix d'OpenCV et FaceNet</i>	54
3.3	ANALYSE ET RECONNAISSANCE VOCALE AVEC LIBROSA ET MODELES IA AVANCES	55
3.3.1	<i>Comparaison des Techniques de Reconnaissance Vocale</i>	55
		56
3.3.2	<i>Justification du Choix des Modèles de Reconnaissance Vocale</i>	56
3.4	EXTRACTION DE TEXTE AVEC EASYOCR ET TESSERACT	56
3.4.1	<i>Comparaison des Techniques d'Extraction de Texte.....</i>	56
3.4.2	<i>Justification du Choix des Techniques d'Extraction de Texte</i>	57
3.5	ARCHITECTURE GENERALE DE L'APPLICATION.....	57
3.5.1	<i>Interface Utilisateur (Tkinter) :</i>	57
3.5.2	<i>Module de Reconnaissance Faciale (FaceNet) :.....</i>	58
3.5.3	<i>Module de Reconnaissance Vocale (Wav2Vec2.0) :</i>	58
3.5.4	<i>Module de Reconnaissance de Texte (EasyOCR) :</i>	58
3.5.5	<i>Base de Données :.....</i>	58
3.5.6	<i>Résultats affichés dans l'Interface Utilisateur :</i>	58
3.6	RECONNAISSANCE FACIALE AVEC FACENET.....	58
3.7	RECONNAISSANCE VOCALE AVEC WAV2VEC2.0.....	59
3.8	RECONNAISSANCE OPTIQUE DE CARACTERES (OCR) AVEC EASYOCR	59
3.9	INTEGRATION ET INTERFACE UTILISATEUR	59
3.10	OPTIMISATION ET PERFORMANCE.....	60
3.11	CONCLUSION.....	60
CHAPITRE 4		61
RESULTATS ET DISCUSSION.....		61
.....		
4.1	INTRODUCTION	62
4.2	RESULTATS DE LA RECONNAISSANCE FACIALE	62
4.2.1	<i>Methodologie des Tests.....</i>	62
4.2.1.2	<i>Présentation des données :.....</i>	62
4.2.1.3	<i>Environnement de test :</i>	63

4.2.1.4	Mesures de Performance.....	64
A)	Précision de la reconnaissance faciale	64
4.2.2	Discussion des Résultats	65
4.2.2.1	Points forts	65
4.2.2.2	Limitations observées	66
4.2.2.3	Solutions envisagées pour améliorer la reconnaissance faciale :	66
4.3	RESULTATS DE LA RECONNAISSANCE VOCALE	66
4.3.1	Méthodologie des Tests.....	66
4.3.1.1	Scénarios de test.....	67
A)	Environnement silencieux.....	67
4.3.1.2	Présentation des données.....	67
4.3.1.3	Environnement de test	68
4.3.2	Discussion des Résultats	70
4.3.2.1	Points forts	70
4.3.2.2	Points faibles	70
4.3.2.3	Idées d'amélioration pour la reconnaissance vocale	71
4.4	RESULTATS DE L'OCR (RECONNAISSANCE DE TEXTE)	71
4.4.1	Méthodologie des Tests.....	71
4.4.1.2	Prétraitement des images	72
A)	Conversion en niveaux de gris	72
4.4.2	Discussion des résultats	73
4.4.2.1	Points forts	73
4.4.2.2	Points faibles	74
4.4.2.3	Propositions d'améliorations	75
4.5	DESCRIPTION DE L'INTERFACE UTILISATEUR DE L'APPLICATION BIOID VISION	75
4.5.1	Boutons et Fonctionnalité.....	75
4.5.1.1	Démarrer Reconnaissance Faciale.....	75
4.5.1.2	Arrêter Reconnaissance Faciale.....	75
4.5.1.3	Démarrer Reconnaissance Vocale	75
4.5.1.4	Arrêter Reconnaissance Vocale	75
4.5.1.5	Importer une Image pour OCR.....	75
4.5.1.6	Capturer une Image pour OCR.....	75
4.5.1.7	Enrôler un nouveau visage	76
4.5.1.8	Enrôler une nouvelle voix.....	76
4.5.1.9	Enregistrer dans Excel.....	76
4.5.2	Zone d'affichage des résultats.....	76
4.6	CONCLUSION.....	77
CONCLUSION GENERALE		78
BIBLIOGRAPHIE.....		80

LISTES DES FIGURES

Figure 1 : Différents types de traits biométriques utilisés dans la reconnaissance biométrique multimodale [1] ..	5
Figure 2 : Modalités biométrique par types [2]	6
Figure 3 : Architecture d'un système biométrique [2]	7
Figure 4 : Mode de fonctionnement d'un système biométrique [3]	8
Figure 5 : Reconnaissance faciale par eigenfaces [3]	9
Figure 6 : modèle de mélange Gaussien [2,3].....	10
Figure 7 : Application de la transformation par ondelette pour l'analyse multi-échelle d'une image [4].....	11
Figure 8 : Hidden Markov Model [2]	12
Figure 9 : Image reconnue par EBGm [2]	13
Figure 10 : SIFT-Coding [2].....	14
Figure 11 : Utilisation de HOG pour la détection d'Object [2]	16
Figure 12: Points clés détectés sur un visage par SURF [4]	18
Figure 13 : Architecture de base de CNN [13]	22
Figure 14 : Architecture du ResNet50 [19]	23
Figure 15 : Architecture du VGG-Face [22].....	24
Figure 16 : Aperçu de l'architecture du DeepFace [22]	25
Figure 17 : Illustration d'un Spectrogramme [44].....	34
Figure 18 : processus d'extraction d'un vecteur MFCC à partir d'une trame de parole [44]	35
Figure 19 : Procédure d'évaluation du modèle GMM/UBM pour la tâche de VAL [53].....	37
Figure 20 : Technique de reconnaissance de caractère [70]	46
Figure 21 Réseau CNN pour la reconnaissance de mots proposés par Jaderberg [73]	47
Figure 22 : Procédure proposée par Zhang et al [87]	50
Figure 23 : Enrôlement du visage d'un individu	63
Figure 24 : Galerie des images envoyées dans le fichier face_data	63
Figure 25 : Résultat de la reconnaissance faciale	66
Figure 26 : Indication pour être prêt pour l'enregistrement	67
Figure 27 : Mise à jour de la base voice_data	68
Figure 28 : Visualisation des données vocales	68
Figure 29 : Résultat de la reconnaissance de locuteur	70
Figure 30 : Image textuelle	72
Figure 31 : Image de carte d'identité.....	72
Figure 32 : Extraction à partir d'image texte avec notre application	74
Figure 33 : Extraction à partir de carte d'identité	74
Figure 34 : Interface de l'application	76

LISTES DES TABLEAUX

Tableau 1 : Quelques algorithmes d'AE pour la RF [31].....	26
Tableau 2 : Comparaison des techniques de reconnaissance faciale	53
Tableau 2 : Comparaison des techniques de reconnaissance faciale	54
Tableau 3 : Comparaison des techniques de reconnaissance vocale.....	55
Tableau 3 : Comparaison des techniques de reconnaissance vocale.....	56
Tableau 4 : Comparaison des techniques d'extraction de texte.....	56
Tableau 4 : Comparaison des techniques d'extraction de texte.....	57

LISTE DES SIGLES ET ABREVIATIONS

AE : Autoencoder

AI : Artificial Intelligence

ACP : Analyse en Composantes Principales

CNN : Convolutional Neural Network

DNN : Deep Neural Network

FFT : Fast Fourier Transform

GAN : Generative Adversarial Network

GMM/UBM : Gaussian Mixture Model/Universal Background Model

HMM : Hidden Markov Model

HOG : Histogram of Oriented Gradients

IAL : Identification Automatique de Locuteur

KNN : K-Nearest Neighbors

LightCNN : Light Convolutional Neural Network

LSTM : Long Short-Term Memory

MFCC : Mel-Frequency Cepstral Coefficients

ML : Machine Learning

OCR : Optical Character Recognition

RAL : Reconnaissance Automatique de Locuteur

RF : Reconnaissance Faciale

RNN : Recurrent Neural Network

ResNet50 : Residual Networks 50 Layers

SIFT : Scale-Invariant Feature Transform

SURF : Speeded-Up Robust Features

SVM : Support Vector Machine

VAL : Vérification Automatique du Locuteur

VGGFace : Visual Geometry Group Face

VQ : Vector Quantization

**WISARD : WEIGHTLESS INTERCONNECTIONS OF SELF-ADAPTIVE AND
RANDOM DISCRIMINATION**

INTRODUCTION GENERALE

1. Contexte et justification

La sécurisation des informations personnelles et l'authentification des utilisateurs dans les systèmes et réseaux de télécommunications sont devenues des enjeux majeurs à l'ère du numérique. Les entreprises de téléphonie mobile doivent traiter des volumes importants de données clients, notamment lors de la souscription aux abonnements. La nécessité d'extraire rapidement et efficacement des informations critiques, telles que celles présentes sur des documents d'identité, est cruciale pour simplifier les processus d'inscription, assurer la conformité à la réglementation en matière de données, et améliorer l'expérience utilisateur.

Dans cette optique, les systèmes de reconnaissance biométrique et Reconnaissance Optique de Caractères (en anglais : optical character recognition OCR) jouent un rôle déterminant. La reconnaissance biométrique permet d'authentifier les abonnés à travers des traits uniques tels que le visage et la voix, tandis que l'OCR automatise l'extraction de données à partir de documents physiques, réduisant ainsi le temps nécessaire pour enregistrer les abonnés et limitant les erreurs humaines.

Ce projet vise donc à développer une application multimodale intégrant la reconnaissance faciale et vocale, tout en y ajoutant un module d'OCR capable d'extraire rapidement les informations des abonnés d'un service de téléphonie mobile à partir de leurs pièces d'identité.

2. Problématique

Les systèmes actuels d'authentification et de gestion des abonnés à un service reposent souvent sur des méthodes traditionnelles comme le remplissage de fiche d'information, qui peuvent être lentes et sujettes aux erreurs humaines. Dans les télécommunications, la rapidité et la précision de l'enregistrement des abonnés sont essentielles pour offrir un service de qualité. Les systèmes unidimensionnels (par exemple, la reconnaissance faciale seule) souffrent de limitations telles que les variations environnementales ou les tentatives de fraude. De plus, l'extraction manuelle des informations d'identité à partir de documents remplis manuellement ralentit considérablement le processus d'enregistrement sans oublier les erreurs qui peuvent survenir au cours du processus.

Ainsi, la problématique principale de ce mémoire est la suivante : comment combiner les reconnaissances faciale et vocale ainsi que l'OCR pour créer une solution rapide, précise et sécurisée d'enregistrement et d'authentification des abonnés des services de téléphonie mobile.

3. Objectifs

L'objectif général de ce projet est de faire un état de l'art et développer une solution multimodale intégrant la reconnaissance faciale, vocale et un module OCR pour l'enregistrement rapide et sécurisé des abonnés.

Les objectifs spécifiques sont :

- Concevoir et implémenter un système d'OCR capable d'extraire automatiquement les informations d'identité des abonnés à partir de documents scannés ou capturés en photo ;
- Concevoir et intégrer un système de reconnaissance faciale performant, utilisant des algorithmes d'apprentissage automatique ;
- Ajouter un module de reconnaissance vocale pour une authentification vocale rapide et précise ;
- Combiner ces trois modalités (OCR, reconnaissance faciale et vocale) dans une application unique afin d'optimiser les processus d'enregistrement des abonnés ;

Evaluer les performances du système en termes de rapidité, précision et robustesse dans des conditions réelles d'utilisation.

4. Organisation du Mémoire

Le présent mémoire est structuré en plusieurs chapitres détaillant l'approche méthodologique utilisée et les résultats obtenus :

- Introduction générale : Elle introduit le contexte et la justification du projet, en précisant la problématique, les objectifs ainsi que l'organisation du mémoire ;
- Chapitre 1 : Etat de l'art sur l'identification biométrique : Ce chapitre offre une revue des travaux existants dans le domaine de la reconnaissance biométrique ;
- Chapitre 2 : Etat de l'art de la reconnaissance optique de caractère ;
- Chapitre 3 : Méthodologie et matériel : le chapitre décrit les techniques utilisées pour conception de l'application ;
- Chapitre 4 : Développement de l'application : ce chapitre couvre les détails techniques du développement, de l'intégration des modules OCR et biométriques, et de la création de l'interface utilisateur ;
- Chapitre 5 : Résultats et discussions : ce chapitre présente les performances de l'application, ses forces et ses limites, et propose des comparaisons avec d'autres systèmes ;
- Conclusion générale : Cette partie récapitule les conclusions du projet, met en avant les limites et propose des perspectives d'améliorations futures.

CHAPITRE 1

ETAT DE L'ART DE L'IDENTIFICATION BIOMETRIQUE

1.1 Introduction

L'état de l'art est une étape essentielle dans toute démarche de recherche scientifique ou technique. Il permet de faire un point sur les connaissances actuelles dans un domaine précis et d'identifier les outils et les approches existantes pour résoudre une problématique donnée. Dans ce premier chapitre, nous nous concentrons sur la reconnaissance biométrique, qui constitue l'une des bases de notre système multimodal d'authentification. La reconnaissance biométrique, en particulier par des traits tels que le visage et la voix, offre une méthode d'authentification robuste et fiable, réduisant les risques d'usurpation d'identité. Ce chapitre met en lumière les algorithmes, les techniques, les avantages et les défis liés aux systèmes biométriques, tout en posant les fondements théoriques et technologiques de notre solution.

1.2 Reconnaissance Biométriques

1.2.1 Définition et principe généraux

La reconnaissance biométrique est un processus permettant d'identifier ou de vérifier l'identité d'un individu à partir de ses caractéristiques biologiques uniques, telles que son visage, sa voix, ses empreintes digitales ou encore son iris. Contrairement aux méthodes d'authentification traditionnelles basées sur des mots de passe ou des cartes d'accès, la biométrie repose sur des caractéristiques inhérentes à l'individu dont quelques caractéristiques sont montrées par la figure 1[1] :




Figure 1 : Différents types de traits biométriques utilisés dans la reconnaissance biométrique multimodale [1]

Ces caractéristiques sont regroupées par modalités. La figure 2 montre les modalités biométriques regroupées par type (morphologique, comportementales, biologiques)




Figure 2 : Modalités biométrique par types [2]

Une caractéristique est qualifiée de biométrique lorsqu'elle remplit les critères suivants :

- **Universalité** : cette caractéristique doit exister chez chaque individu que l'on souhaite identifier ;
- **Unicité** : la caractéristique doit être unique à chaque individu dans la base de données, sans possibilité de confusion ;
- **Permanence** : elle doit être stable et rester identique tout au long de la vie de la personne ;
- **Collectable** : la caractéristique doit être mesurable et enregistrable pour pouvoir être comparée ;
- **Acceptabilité** : elle doit pouvoir être facilement recueillie et ne doit pas poser de problème majeur d'acceptation pour les individus concernés.

1.2.2 Architecture d'un système biométrique

Un système biométrique peut être divisé en quatre modules principaux [3] qui sont :

- La capture ou acquisition, qui est chargée de collecter les données biométriques d'un individu à l'aide de dispositifs comme un appareil photo, un lecteur d'empreintes digitales ou une caméra de sécurité ;

- L'extraction de caractéristiques, qui utilise les données biométriques acquises pour isoler les informations pertinentes, créant ainsi une représentation unique pour chaque personne ;
- La correspondance, qui compare les caractéristiques extraites avec les modèles enregistrés dans la base de données lors de l'enrôlement pour évaluer la similarité ou divergence entre eux.
- La décision, qui vérifie l'identité déclarée ou détermine l'identité d'une personne en fonction du niveau de correspondance entre les caractéristiques extraites et les modèles stockés.

La figure 3 montre l'architecture d'un système biométrique.




Figure 3 : Architecture d'un système biométrique [2]

1.2.3 Mode de fonctionnement d'un système biométrique

Un système biométrique fonctionne selon trois modes principaux [4] qui sont :

- Enrôlement : L'enrôlement est la première étape dans le fonctionnement d'un système biométrique. Il s'agit du processus par lequel un utilisateur est enregistré pour la première fois dans le système. Ce mode est crucial, car il permet de capturer et de stocker les informations biométriques de l'individu pour une utilisation future lors de l'identification ou de la vérification ;
- Identification : L'identification est le processus par lequel un système biométrique compare les données biométriques d'un utilisateur avec l'ensemble des modèles biométriques stockés dans la base de données ;
- Vérification : La vérification, aussi appelée authentification, est le processus où le système biométrique vérifie si l'utilisateur est bien celui qu'il prétend être. Contrairement à l'identification, où le système doit déterminer l'identité de l'utilisateur, ici l'utilisateur affirme son identité et le système compare ses données biométriques avec celles déjà enregistrées pour cette identité spécifique.

La figure 4 montre le mode de fonctionnement d'un système biométrique.




Figure 4 : Mode de fonctionnement d'un système biométrique [3]

1.2.4 Avantages des systèmes biométriques

La biométrie est une technologie efficace pour identifier et authentifier les individus rapidement et de manière fiable grâce à des caractéristiques uniques. Elle offre plusieurs avantages, notamment une sécurité accrue avec des techniques peu coûteuses, la réduction des coûts liés à la gestion des mots de passe, la diminution de la fraude, une identification rapide des personnes, l'élimination des problèmes liés aux pertes de codes d'accès en les remplaçant par des caractéristiques physiologiques, et la prévention des pertes de temps.

Dans ce travail, deux traits biométriques spécifiques sont considérés : le facial et la voix. Nous allons maintenant aborder l'étude de la reconnaissance faciale avant de nous pencher sur la reconnaissance automatique de locuteur basée sur la voix.

1.3 Reconnaissance faciale

1.3.1 Historique et évolution de la reconnaissance faciale

La reconnaissance faciale est née dans les années 1960 avec les travaux pionniers de Woodrow Wilson Bledsoe, un mathématicien et informaticien américain [2]. Bledsoe est reconnu pour ses premières tentatives de reconnaître les visages humains à l'aide d'ordinateurs rudimentaires. Son approche consistait à cartographier manuellement certaines caractéristiques du visage, telles que la distance entre les yeux, la largeur du nez ou encore la forme de la mâchoire, pour identifier les individus. Cependant, à cette époque, ces systèmes étaient loin d'être précis et souffraient de limitations importantes en raison de la puissance de calcul limitée, des conditions d'éclairage, et des variations dans les expressions faciales et les angles de prise de vue.

1.3.2 Méthodes classiques

Les méthodes classiques se concentrent sur l'extraction de caractéristiques à partir d'images 2D du visage et se les divisent en plusieurs catégories en fonction de l'approche adoptée : globales, locales, hybrides, et détecteurs et descripteurs de points d'intérêt.

1.3.2.1 Méthodes Globales

Les méthodes globales traitent la totalité du visage en tant qu'entité unique, sans prêter attention aux caractéristiques locales (yeux, bouche, nez, etc.). On recense plusieurs techniques courantes.

A) Analyse en Composantes Principales (PCA)

Le PCA connue sous le nom de méthode des Eigenfaces, décompose les images de visage en une combinaison linéaire d'images de base [3].

$$I = \sum_{i=1}^N a_i e_i \quad (1)$$

Où :

- I est l'image du visage représentée ;
- e_i représente les Eigenfaces (les composantes principales) ;
- a_i sont les coefficients pondérant chaque composante principale ;
- N est le nombre total d'Eigenfaces utilisées pour la reconstruction.

La figure 5 montre une reconnaissance faciale par eigenfaces.



Figure 5 : Reconnaissance faciale par eigenfaces [3]

B) Modèles de Mélanges Gaussiens

Le modèle de mélange gaussien (MMG) permet de modéliser les distributions statistiques des pixels du visage en supposant qu'ils suivent une combinaison de plusieurs distributions gaussiennes. Un MMG est défini comme une somme pondérée de plusieurs distributions normales (ou gaussiennes), chacune étant caractérisée par sa propre moyenne et covariance. La figure 6 illustre un modèle de mélange gaussien.




Figure 6 : modèle de mélange Gaussien [2,3]

La fonction de densité de probabilité d'un GMM est donnée par la formule :

$$P(x) = \sum_{i=1}^k w_i \cdot \mathcal{N}(x|\mu_i, \Sigma_i) \quad (2)$$

Où :

- x est le vecteur de caractéristiques (pixels du visage par exemple), k est le nombre de gaussiennes dans le mélange ;
- w_i est le poids (ou probabilité a priori) de la i -ème gaussienne, avec $\sum_{i=1}^k w_i = 1$;
- $\mathcal{N}(x|\mu_i, \Sigma_i)$ est la densité de probabilité de la distribution normale gaussienne avec une moyenne ;
- μ_i et une matrice de covariance Σ_i .

C) Les ondelettes (Wavelets)

Les ondelettes sont des fonctions mathématiques qui décomposent un signal ou une image en différentes échelles et fréquences, permettant de représenter à la fois les aspects locaux (détails) et globaux (structure générale) d'une image. Cette capacité à analyser les signaux à plusieurs résolutions est extrêmement utile en reconnaissance faciale pour capturer des caractéristiques distinctives à diverses échelles du visage.

La figure 7 montre une transformation d'une image par les ondelettes.



Figure 7 : Application de la transformation par ondelette pour l'analyse multi-échelle d'une image [4]

L'équation générale d'une ondelette est donnée par :

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right) \quad (3)$$

Où

$\psi_{a,b}(t)$ est l'ondelette obtenue après transformation de l'ondelette mère $\psi(t)$

a est le paramètre d'échelle qui contrôle l'étirement ou la compression de l'ondelette,

b est le paramètre de translation qui contrôle la position de l'ondelette dans le temps (ou dans l'espace pour les images).

L'analyse par ondelettes permet donc de décomposer un signal $f(t)$ comme :

$$f(t) = \sum_{a,b} c_{a,b} \psi_{a,b}(t) \quad (4)$$

Où $c_{a,b}$ sont les coefficients d'ondelettes, qui indiquent combien chaque ondelette contribue à la reconstruction du signal.

1.3.2.2 Méthodes Locales

Les méthodes locales se concentrent sur des caractéristiques spécifiques du visage, telles que les yeux, le nez, et la bouche. Elles accordent une importance particulière à l'apparence et à la géométrie locale des traits du visage.

A) Hidden Markov Models (HMM)

Les Hidden Markov Models (HMM) sont utilisés pour modéliser des séquences discrètes, telles que les parties spécifiques du visage (yeux, nez, bouche). Ils représentent ces zones par des "états cachés" et sont capables de gérer les variations des visages à travers différentes images. Ces modèles sont particulièrement efficaces pour modéliser des séquences faciales où les relations spatiales et temporelles entre différentes parties du visage sont importantes.

La figure 8 montre un modèle de Hidden Markov model

Hidden Markov Model




Figure 8 : Hidden Markov Model [2]

L'objectif d'un HMM est d'estimer la séquence d'états cachés (S) donnée une séquence d'observations (O) via l'algorithme de Viterbi. Cet algorithme maximise la probabilité $P(O, S)$, et l'expression clé utilisée est :

$$P(O|S) = \prod_{t=1}^T P(o_t|s_t)P(s_t|s_{t-1}) \quad (5)$$

Où $P(o_t|s_t)$ est la probabilité d'émission et $P(s_t|s_{t-1})$ est la probabilité de transition.

B) Elastic Bunch Graph Matching (EBGM)

Le EBGM est une méthode utilisée pour la reconnaissance faciale qui s'appuie sur des graphes élastiques pour correspondre aux caractéristiques spécifiques d'un visage. Cette méthode est basée sur la théorie des graphes, où un visage est modélisé comme un ensemble de points caractéristiques, appelés *jets*, qui correspondent aux zones clés du visage, comme les yeux, le nez, la bouche, etc. Les *jets* sont représentés par des vecteurs caractéristiques, qui contiennent des informations sur les propriétés locales des images, comme la texture, l'intensité, ou la fréquence. Ces *jets* sont organisés dans un graphe, et la méthode EBGM applique un ajustement élastique pour correspondre ces points clés avec ceux des visages à reconnaître.

La figure 9 montre la reconnaissance d'une image par EBGM




Figure 9 : Image reconnue par EBGM [2]

L'objectif est de trouver la meilleure correspondance entre deux graphes élastiques. La fonction de correspondance cherche à minimiser une fonction de coût, qui mesure la dissimilarité entre les *jets* des deux visages tout en permettant une certaine déformation élastique du graphe. La méthode cherche à résoudre un problème d'optimisation basé sur une transformation géométrique qui peut être exprimée comme :

$$E = \sum_i |J_i^{\text{ref}} - J_i^{\text{test}}|^2 + \alpha \sum_{(i,j)} |d_{ij}^{\text{ref}} - d_{ij}^{\text{test}}|^2 \quad (6)$$

Où

- J_i^{ref} et J_i^{test} représentent les *jets* du visage de référence et du visage testé
- d_{ij}^{ref} et d_{ij}^{test} représentent les distances entre les *jets* des graphes,
- α est un facteur de régulation pour ajuster le poids de la transformation géométrique.

Cette méthode est particulièrement robuste aux variations de position, d'expression, et d'éclairage. Elle permet de capturer à la fois les détails géométriques et texturaux d'un visage, ce qui la rend efficace pour des tâches de reconnaissance faciale dans des environnements moins contrôlés.

1.3.2.3 Méthodes Hybrides

Les méthodes hybrides combinent les approches globales et locales afin de bénéficier des avantages des deux types de méthodes. Ces approches sont plus robustes, car elles intègrent à la fois les caractéristiques globales et locales. Par exemple, une approche hybride pourrait utiliser l'ACP pour la globalité du visage tout en appliquant les HMM pour modéliser des

caractéristiques spécifiques. Tout d'abord, PCA réduit la dimensionnalité de l'image du visage, créant une représentation compacte. Ensuite, HMM est appliqué aux zones spécifiques, pour modéliser les transitions entre ces parties du visage.

Cette approche est pertinente dans les systèmes de reconnaissance biométrique où la précision est essentielle, notamment dans des environnements variés et non contrôlés. L'approche hybride PCA-HMM combine la rapidité de traitement de PCA avec la capacité d'analyse en détail de HMM, offrant ainsi un équilibre idéal entre performance et précision.

1.3.2.4 Détecteurs et Descripteurs de Points d'Intérêt

Les détecteurs et descripteurs identifient des points ou régions d'intérêt dans une image de visage et analysent leur voisinage immédiat. Ces méthodes sont largement utilisées en reconnaissance d'objets et ont été adaptées à la reconnaissance faciale.

A) SIFT (Scale-Invariant Feature Transform)

Le SIFT est une méthode de détection et de description des points d'intérêt qui est très largement utilisée en reconnaissance d'images, y compris pour la reconnaissance faciale. Ce qui fait la force de l'algorithme SIFT est sa capacité à identifier des points d'intérêt (ou "features") invariants par rapport aux transformations géométriques telles que l'échelle, la rotation, et en partie aux variations d'illumination. Il est également robuste face à des déformations partielles. La figure 10 montre comment le SIFT identifie les points d'intérêt




Figure 10 : SIFT-Coding [2]

L'algorithme SIFT fonctionne en quatre étapes principales :

▪ **Etape 1 : Détection des points-clés (keypoints)**

Cette étape consiste à identifier les emplacements dans une image où il y a une variation significative des intensités de pixels. Cela est fait en appliquant une pyramide de différences de Gaussiennes (DoG, Difference of Gaussians) à l'image, permettant d'identifier les points d'intérêt à différentes échelles. Mathématiquement, on peut exprimer cette opération par la convolution d'une image $I(x, y)$ avec un noyau gaussien $G(x, y, \sigma)$ à différentes échelles de σ , puis en calculant la différence entre ces images floutées :

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y) \quad (7)$$

Où $G(x, y, \sigma)$ est le noyau gaussien de lissage, k est un facteur d'échelle et $I(x, y)$ est l'image originale.

▪ **Etape 2 : Affinage des points-clés**

Après avoir détecté les points d'intérêt potentiels, un affinage est effectué pour éliminer les points faibles ou instables (fausse détection). Cela se fait en ajustant la position exacte et l'échelle de chaque point-clé en utilisant une interpolation polynomiale. Cela permet également d'éliminer les points qui ne sont pas bien localisés.

▪ **Etape 3 : Calcul de l'orientation**

Pour chaque point-clé, une orientation dominante est attribuée afin de garantir l'invariance à la rotation. Cela est fait en calculant l'histogramme des gradients dans une région autour du point-clé. L'orientation qui correspond à l'histogramme de gradient maximal est attribuée au point-clé.

▪ **Etape 4 : Création du descripteur**

Une fois l'orientation assignée, un descripteur local est construit pour chaque point-clé. Ce descripteur est basé sur une grille de gradients autour du point d'intérêt, généralement représentée sous forme de blocs de 4x4 cellules, où chaque cellule contient l'orientation dominante des gradients. Cela aboutit à un vecteur de caractéristiques de dimension 128, invariant à l'échelle et à la rotation.

SIFT est souvent utilisé en reconnaissance faciale pour extraire des points-clés robustes sur les différentes parties du visage. Le descripteur SIFT permet de capturer des informations précises sur les caractéristiques locales, telles que les yeux, le nez, et la bouche, tout en étant invariant aux changements d'échelle, d'orientation et partiellement à la lumière.

B) Histogram of Oriented Gradients

Histogram of Oriented Gradients (HOG) est une méthode de description d'images qui est largement utilisée pour la reconnaissance d'objets, y compris la reconnaissance faciale. Son principal objectif est d'extraire des informations relatives à la forme et aux contours d'une image, en analysant les gradients locaux de l'image. Cette méthode est particulièrement robuste face aux variations d'éclairage et est souvent utilisée conjointement avec d'autres méthodes pour des tâches telles que la détection de visages. La figure 11 montre comment le HOG permet d'identifier les objets



Figure 11 : Utilisation de HOG pour la détection d'Object [2]

L'algorithme HOG fonctionne en ces étapes :

- **Etape 1 : Détection des gradients**

Le premier pas dans HOG consiste à calculer le gradient d'intensité de chaque pixel de l'image. Les gradients dans les directions horizontale et verticale sont calculés à l'aide de dérivées discrètes :

$$G_x = I(x + 1, y) - I(x - 1, y) \quad (8)$$

$$G_y = I(x, y + 1) - I(x, y - 1) \quad (9)$$

Où $I(x, y)$ représente l'intensité du pixel en position (x, y) . Les magnitudes des gradients sont ensuite calculées par la formule suivante :

$$M(x, y) = \sqrt{G_x^2 + G_y^2} \quad (10)$$

Et l'orientation du gradient est déterminée par :

$$\theta(x, y) = \tan^{-1} \left(\frac{G_y}{G_x} \right) \quad (11)$$

Ces gradients capturent les contours et les zones de transition rapide dans l'image, ce qui permet de déterminer les formes locales du visage.

- **Etape 2 : Division en cellules et blocs**

L'image est ensuite divisée en petites cellules rectangulaires (typiquement de 8x8 pixels).

- **Etape 3 : Construction d'histogrammes**

Dans chaque cellule, un histogramme est construit en comptant le nombre de fois que les gradients ont une certaine orientation. Les orientations sont généralement regroupées en bins (typiquement 9 bins, chacun représentant une plage de 20 degrés). Ainsi, chaque cellule est décrite par un vecteur contenant les valeurs de ces 9 bins.

- **Etape 4 : Normalisation**

Pour obtenir une meilleure invariance aux variations d'éclairage, les cellules sont regroupées en blocs, et les histogrammes des cellules sont normalisés. Cela permet de s'assurer que la description est robuste aux changements d'illumination locale. La normalisation est effectuée en divisant chaque valeur de l'histogramme par la norme du vecteur représentant les valeurs du bloc, en utilisant souvent la norme L2 :

$$v' = \frac{v}{\sqrt{|v|^2 + \epsilon^2}} \quad (12)$$

Où v est le vecteur des valeurs de l'histogramme, et ϵ est une petite constante pour éviter la division par zéro.

- **Etape 5 : Concaténation des descripteurs**

Après avoir calculé les histogrammes pour chaque cellule et avoir normalisé ces histogrammes dans les blocs, les vecteurs descripteurs de toutes les cellules de l'image sont concaténés pour former un vecteur global, décrivant ainsi l'image de manière complète mais compacte. Ce vecteur de caractéristiques peut ensuite être utilisé dans des algorithmes de classification comme les SVM ou les réseaux de neurones pour effectuer la reconnaissance faciale.

En reconnaissance faciale, l'algorithme HOG est particulièrement utile pour extraire les contours du visage, tels que les bords des yeux, du nez et de la bouche. Ces informations permettent de générer des descripteurs qui peuvent ensuite être utilisés dans des algorithmes de classification pour reconnaître un individu.

C) Speeded-Up Robust Features

Le Speeded-Up Robust Features (SURF) est une méthode d'extraction de caractéristiques locales similaire à SIFT, mais conçue pour être plus rapide tout en maintenant une robustesse comparable. Le principe général de SURF est de détecter des points d'intérêt dans une image, comme des coins ou des bords, qui peuvent ensuite être utilisés pour diverses tâches de reconnaissance, y compris la reconnaissance faciale. La figure 12 montre comment le SURF fonctionne dans la reconnaissance d'image.




Figure 12: Points clés détectés sur un visage par SURF [4]

Voici les différentes étapes de l'algorithme :

- **Etape 1 : Détection des points d'intérêt**

Contrairement à SIFT, qui utilise une approche basée sur les différences gaussiennes, SURF se base sur l'utilisation de la **réponse Hessienne**, qui repose sur des approximations discrètes des dérivées secondes d'images. La réponse Hessienne d'un point x dans une image est calculée à l'aide du déterminant de la matrice Hessienne $H(x)$, définie comme suit :

$$H(x) = \begin{bmatrix} L_{xx}(x, \sigma) & L_{xy}(x, \sigma) \\ L_{xy}(x, \sigma) & L_{yy}(x, \sigma) \end{bmatrix} \quad (13)$$

Où $L_{xx}(x, \sigma)$, $L_{yy}(x, \sigma)$, et $L_{xy}(x, \sigma)$ représentent les dérivées secondes gaussiennes de l'image aux points x dans les directions x, y respectivement, et σ est l'échelle de la détection.

La matrice Hessienne permet de détecter les points d'intérêt dans une image, et son déterminant est utilisé pour juger de l'importance de ces points.

▪ Etape 2 : Invariance à l'échelle et à la rotation

Pour rendre la méthode robuste aux variations d'échelle, SURF construit une image pyramidale en plusieurs résolutions (ou échelles). À chaque échelle, la réponse Hessienne est recalculée pour identifier les points d'intérêt dominants.

En ce qui concerne l'invariance à la rotation, les descripteurs sont calculés en alignant les gradients locaux autour des points d'intérêt dans une orientation dominante.

▪ Etape 3 : Description locale par filtres de Haar

L'utilisation des filtres de Haar permet de calculer rapidement les réponses des gradients locaux autour de chaque point d'intérêt. Ces réponses sont ensuite normalisées et converties en un vecteur descripteur invariant à l'échelle et à la rotation. Ce vecteur est utilisé pour comparer les points d'intérêt entre différentes images.

Bien que les méthodes classiques de reconnaissance faciale reposent sur des techniques d'extraction de caractéristiques et d'algorithmes analytiques traditionnels, elles présentent certaines limites en termes de précision et de capacité à s'adapter à des situations complexes. C'est ici qu'intervient l'intelligence artificielle (IA), qui offre des solutions innovantes pour surmonter ces défis. Grâce à sa capacité à analyser des volumes massifs de données et à apprendre de manière autonome, l'IA, notamment à travers des approches telles que le machine learning et le deep learning, permet d'atteindre des niveaux de performance bien supérieurs dans le domaine de la reconnaissance faciale. Avant de plonger dans ces nouvelles méthodes, il est essentiel de comprendre l'impact global de l'IA et ses principales caractéristiques.

1.3.3 Intelligence Artificielle

L'Intelligence Artificielle (IA) consiste à faire reproduire à des machines automatiques comme les ordinateurs, des capacités de raisonnement et de prise de décision proches de celles des humains. Son objectif principal est de doter des systèmes informatiques d'une intelligence comparable à celle des êtres humains, leur permettant d'effectuer des tâches telles que l'analyse, la reconnaissance et l'apprentissage. L'IA repose sur une variété de techniques et de théories mises en œuvre dans des systèmes dynamiques, capables de traduire les processus cognitifs humains en programmes informatiques efficaces.

John McCarthy [5], un des pionniers dans le domaine, est l'un des premiers à avoir conceptualisé l'IA dès 1949. Aujourd'hui, l'intelligence artificielle est présente dans de nombreux secteurs parmi lesquels la reconnaissance de formes [6]. Ses applications sont conçues pour simuler des mécanismes de réflexion afin de résoudre des problèmes complexes ou de faciliter la prise de décision. L'IA se distingue par sa fiabilité, sa permanence et sa capacité à traiter des situations d'incertitude avec rapidité.

L'apprentissage automatique (Machine Learning) et l'apprentissage profond (Deep Learning) sont deux sous-domaines majeurs de l'IA qui permettent aux machines d'apprendre à partir de données, améliorant leur performance de manière autonome. Ces technologies sont au cœur des récentes avancées dans le domaine de l'IA.

1.3.3.1 Machine Learning

L'apprentissage est un processus naturel chez les êtres humains, et avec les avancées technologiques, il est devenu une compétence clé pour les machines. Le but principal de l'apprentissage automatique (Machine Learning - ML) est de permettre aux ordinateurs d'apprendre sans intervention humaine directe. Il existe plusieurs types d'apprentissage automatique, parmi lesquels l'apprentissage supervisé, l'apprentissage non supervisé, l'apprentissage semi-supervisé et l'apprentissage par renforcement.

A) Apprentissage supervisé

L'apprentissage supervisé consiste à entraîner une machine à partir d'exemples étiquetés pour prédire des résultats futurs. Dans ce cas, les algorithmes apprennent à associer des données d'entrée avec des sorties correctes. Par exemple, dans le domaine de la reconnaissance faciale (RF), on peut utiliser des méthodes supervisées pour classer des visages selon leur appartenance à une classe. Des techniques comme Support Vector Machines (SVM) [7], les arbres de décision, l'Analyse Discriminante Linéaire (ADL) [8], ou encore le K-Nearest Neighbors (KNN) sont couramment utilisées.

SVM permet de trouver l'hyperplan optimal séparant les différentes classes avec le moins d'erreur possible.

ADL, une méthode statistique utilisée pour prédire l'appartenance à une classe, est particulièrement efficace en reconnaissance faciale pour discriminer des groupes.

KNN est une méthode de classification qui utilise les plus proches voisins pour identifier les similarités entre les nouvelles données et les exemples connus. Il est beaucoup utilisé en Reconnaissance faciale [9].

B) Apprentissage non supervisé

Contrairement à l'apprentissage supervisé, l'apprentissage non supervisé ne repose pas sur des données étiquetées. L'algorithme tente d'identifier des modèles ou des structures dans des ensembles de données non étiquetées. En RF, l'Analyse en Composantes Principales (PCA) est souvent utilisée pour réduire la dimensionnalité des données et extraire des caractéristiques significatives. Ce type d'algorithme a été largement adopté dans les années 1990 [10] pour l'analyse de visages avec les méthodes Eigenfaces.

C) Apprentissage semi-supervisé

L'apprentissage semi-supervisé se situe entre les deux approches précédentes. Il utilise une petite quantité de données étiquetées et une grande quantité de données non étiquetées. Cela permet de tirer parti des données non étiquetées pour améliorer la précision de la prédiction, tout en minimisant le coût de l'étiquetage manuel.

D) Apprentissage par renforcement

L'apprentissage par renforcement consiste à apprendre à un agent comment interagir avec un environnement en recevant des retours sur ses actions. L'algorithme apprend à optimiser ses actions pour maximiser une récompense. Par exemple, dans un système de reconnaissance faciale, un agent autonome pourrait ajuster sa détection de visage en fonction des retours positifs ou négatifs qu'il reçoit.

Ces différentes approches constituent la base des techniques d'apprentissage en intelligence artificielle et sont utilisées dans divers domaines comme la reconnaissance d'images, les assistants virtuels, les systèmes de recommandation, et bien d'autres.

1.3.3.2 Deep Learning et Reconnaissance Faciale

La dernière décennie a marqué un tournant décisif dans l'évolution du Machine Learning (ML), grâce à l'émergence de techniques d'apprentissage beaucoup plus avancées, communément désignées sous le terme de Deep Learning (DL). Les Réseaux de Neurones Artificiels (RNA), qui étaient initialement assez simples dans leur conception, ont évolué vers des architectures plus profondes et complexes, permettant une capacité d'apprentissage inégalée et révolutionnant de nombreux domaines dont la reconnaissance faciale (RF) [11].

A) Les premières approches de reconnaissance faciale par RNA

Dès les premières années de l'utilisation des Réseaux de Neurones Artificiels (RNA), des chercheurs comme Aleksander [12] ont développé des systèmes rudimentaires de reconnaissance faciale, comme le WISARD, qui était un réseau de neurones à une seule couche. Ce système contenait un réseau séparé pour chaque individu stocké, une architecture assez rudimentaire mais pionnière. Ces systèmes ont jeté les bases des futures avancées en RF, en posant les premières pierres dans l'utilisation des RNA pour extraire les caractéristiques des visages.

Dans les années qui ont suivi, des travaux comme ceux de Kumar et al. [13] en 2011 ont renforcé l'utilisation des RNA pour la RF. Ces chercheurs ont introduit des techniques mixtes, combinant les ondelettes de Gabor, l'Analyse en Composantes Principales (ACP), et l'Analyse Discriminante Linéaire (LDA) avec un réseau de neurones à rétropropagation. Cette approche a permis d'extraire des caractéristiques du visage à partir des ondelettes de Gabor, les réduire avec l'ACP, puis les classer avec un RNA, obtenant ainsi des résultats prometteurs.

B) Impact du Deep Learning

Le Deep Learning (DL) marque une extension du Machine Learning avec des architectures de réseaux de neurones beaucoup plus profondes, d'où l'utilisation du terme Réseaux de Neurones Profonds (DNN). Ces réseaux sont capables de traiter de grandes quantités de données et d'apprendre des représentations complexes à partir de celles-ci. L'utilisation du DL pour la reconnaissance faciale a permis des avancées significatives en termes de précision et de robustesse des systèmes.

Contrairement aux algorithmes de ML traditionnels qui nécessitaient une ingénierie manuelle des caractéristiques, le DL permet de découvrir automatiquement des caractéristiques pertinentes à partir des données d'image, grâce à des architectures multicouches. Cela a rendu possible la reconnaissance faciale dans des environnements beaucoup plus variés et complexes, comme la surveillance en temps réel dans des conditions d'éclairage variées, ou encore la reconnaissance de visages partiellement occultés.

C) Architectures de réseaux de neurones pour la reconnaissance faciale

Dans le domaine de la reconnaissance faciale, plusieurs architectures de Deep Learning sont utilisées pour améliorer la précision et la robustesse des systèmes. Les architectures les plus fréquemment exploitées sont :

- Les Réseaux de neurones convolutifs (CNN) ;
- Les Auto-Encodeurs (AE) ;
- Les réseaux génératifs contradictoires (GAN) ;
- Les réseaux hybrides ;
- L'apprentissage par renforcement profond.

a.1 Réseaux de neurones convolutifs (CNN)

Les réseaux de neurones convolutifs (CNN) sont constitués de plusieurs couches interconnectées qui coopèrent pour analyser des images. Contrairement aux réseaux de neurones artificiels classiques (ANN), les CNN sont spécialement conçus pour extraire automatiquement des caractéristiques d'images. Le premier CNN a été développé par **Yann LeCun** et *al* [14] dans les années 1990. Ces réseaux se distinguent par leur capacité à effectuer des convolutions, une opération mathématique qui consiste à appliquer un filtre sur une image pour en extraire des caractéristiques importantes.

Le processus dans les CNN se divise en deux étapes principales : **l'extraction de caractéristiques** et **la classification** (souvent effectuée par un ANN). L'opération de convolution est répétée sur l'image à l'aide de plusieurs filtres pour extraire les détails pertinents, créant ainsi un vecteur de caractéristiques. Ce vecteur sert ensuite d'entrée pour l'ANN, qui effectue la classification finale. L'architecture d'un CNN est composée de plusieurs couches, notamment :

- La couche convolutive, qui applique les filtres pour détecter des caractéristiques spécifiques dans l'image ;
- La couche de regroupement (ou pooling), qui réduit la dimensionnalité des cartes de caractéristiques tout en conservant les informations les plus importantes ;
- La couche ReLU (Rectified Linear Unit), qui introduit de la non-linéarité dans le réseau, ce qui aide à modéliser des relations complexes ;
- La couche entièrement connectée, où chaque neurone est relié à tous les neurones de la couche précédente, facilitant ainsi la prise de décision finale.

Cette structure de base peut varier et être empilée selon la complexité du problème à résoudre, formant ainsi des architectures plus profondes pour traiter des images complexes.

La figure 13 montre une architecture de base de CNN




Figure 13 : Architecture de base de CNN [13]

Tout réseau de neurones convolutifs (CNN) commence par une couche de convolution et se termine par une couche entièrement connectée. Les couches intermédiaires peuvent varier et s'empiler de différentes manières, à condition que la sortie d'une couche soit compatible avec l'entrée de la suivante. Par exemple, une couche entièrement connectée, qui génère toujours un vecteur, ne peut pas être positionnée avant une couche de pooling, car cette dernière nécessite une matrice tridimensionnelle (3D) en entrée.

L'utilisation des CNN en reconnaissance faciale a démontré des performances remarquables, avec des précisions atteignant jusqu'à 100 % dans certains systèmes de reconnaissance faciale. De nombreux systèmes actuels de reconnaissance faciale reposent sur des architectures CNN avancées, telles que **VGGNet** [15], **GoogLeNet** [16] (avec 22 couches), **ResNet50** [17], **LightCNN-v9** [18], et **SqueezeNet** [19], **DeepFace**.

Ces architectures sont réputées pour leur efficacité et leur capacité à traiter des tâches complexes de reconnaissance faciale. Explorons à présent quelques modèles de reconnaissance faciale basée sur le CNN.

⇒ **ResNet50 et la reconnaissance faciale**

ResNet50 est un réseau de neurones convolutifs (CNN) largement utilisé pour l'apprentissage supervisé en reconnaissance faciale. Ce modèle contient 50 couches profondes, d'où son nom. Il a été testé sur plusieurs ensembles de données d'images, dont **VGGFace2** [20], un ensemble d'images utilisé pour tester les performances des modèles comme **SqueezeNet** et **ResNet50**. Une étude réalisée par Wen [21] a proposé une approche de reconnaissance faciale (RF) basée sur l'invariance de l'âge. Les résultats ont montré une précision atteignant 98,72 % sur des bases de données spécifiques comme MORPH Album2, FGNET, et CACD-VS. La figure 14 montre une architecture du RestNet50




Figure 14 : Architecture du RestNet50 [19]

⇒ **GTNN et la fusion de caractéristiques**

Hu [22] a développé un CNN appelé GTNN (Gated Two-Stream Neural Network) pour améliorer les performances de la RF. Le modèle fusionne les caractéristiques du visage avec des tenseurs non linéaires pour atteindre une précision de 99,65 % sur l'ensemble de données LFW et 99,94 % sur CASIA NIR-VIS2.

⇒ **VGG-Face et Lightened CNN**

Ghazi [23] a utilisé des CNN pré-entraînés, tels que **VGG-Face** et **Lightened CNN**, pour développer une nouvelle approche de reconnaissance faciale. Leur méthode prend en compte des variations comme l'éclairage, l'occlusion, et les angles de pose de la tête, testée sur des ensembles de données comme **Yale**, **CMU PIE**, et **FERET**. Malgré ces variations, **VGG-Face** a montré de meilleures performances que Lightened CNN sur ces données. La figure 15 montre une architecture du VGG-Face




Figure 15 : Architecture du VGG-Face [23]

⇒ **LightCNN-v9 et LightCNN-v29 pour les visages basse résolution**

Chen et al. [24] ont proposé une méthode innovante pour reconnaître des visages de basse résolution à partir des réseaux **LightCNN-v9** et **LightCNN-v29**. Ces modèles fonctionnent avec des images de résolutions aussi faibles que 32×32 pixels et atteignent une précision allant jusqu'à 98,98 %.

⇒ **Recursive Spatial Transformer (ReST)**

Wu et al. [25] ont présenté une approche basée sur un module appelé **Recursive Spatial Transformer (ReST)**, intégrant un CNN modifié d'AlexNet avec des couches de convolution et de transformation spatiale. Ce modèle est particulièrement efficace pour identifier les visages à partir de différentes poses.

⇒ ELANet et la reconnaissance faciale attentionnelle

Zhang et al [26] ont développé en 2022 le réseau **ELANet** (Efficient Lightweight Attention Network), un réseau léger qui améliore la performance de la RF malgré les variations de pose et d'âge. Ce modèle a surpassé d'autres réseaux sur les ensembles de données **CPLFW**, **VGG2_FP**, et **CALFW**.

⇒ PoreNet : la reconnaissance faciale à l'échelle des pores

Lai et al. [27] ont conçu PoreNet, un système qui détecte les pores à partir des images de visages pour la RF. Grâce à des images haute résolution, le système analyse les pores pour effectuer la reconnaissance. PoreNet est une version modifiée du réseau **HardNet** développé en 2017 par Mishchuk et al. [28].

⇒ DeepFace : un modèle révolutionnaire

DeepFace, développé par Facebook, a révolutionné la RF en combinant des techniques de transformation géométrique 3D et de CNN. DeepFace permet d'aligner des visages même sous différents angles de vue, puis applique plusieurs couches de convolution pour extraire des caractéristiques pertinentes. Le modèle a atteint une précision de 97,35 % sur l'ensemble de données **Labelled Faces in the Wild (LFW)**, démontrant ainsi l'efficacité de la RF basée sur les CNN. La figure 16 montre une architecture du DeepFace.




Figure 16 : Aperçu de l'architecture du DeepFace [22]

⇒ GTNN et l'agrégation de caractéristiques vidéo

Enfin, J. Yang et al. [29] ont présenté une approche d'agrégation neuronale pour la reconnaissance faciale vidéo. Ce modèle prend en entrée des vidéos ou ensembles d'images faciales et utilise le **CNN GoogLeNet** pour extraire des caractéristiques avant d'appliquer un réseau d'agrégation neuronale siamoise pour vérifier l'identité des visages.

a.2 Auto-encodeurs (AE)

Les auto-encodeurs (AE) jouent un rôle clé dans l'amélioration des performances des systèmes de reconnaissance faciale (RF), notamment lorsque les images à traiter contiennent du bruit.

Plus une image est bruitée, plus elle compromet l'efficacité des systèmes de reconnaissance. Les AE sont une technique de reconstruction qui permet de récupérer une image nette à partir d'une version bruitée. Ces réseaux de neurones profonds, non supervisés, se concentrent sur l'apprentissage des caractéristiques essentielles des données.

Un AE comprend deux étapes principales : l'encodage et le décodage. Pendant l'encodage, l'image d'entrée est compressée en une représentation de plus petite taille, tout en conservant ses caractéristiques essentielles. Le décodage, lui, permet de reconstituer l'image d'origine à partir de cette représentation compressée. Grâce à ces étapes, les AE facilitent la réduction de la dimension des données volumineuses, comme les images faciales, tout en maintenant leur qualité.

Plusieurs variantes d'AE sont apparues au fil des années pour améliorer la reconnaissance faciale. Par exemple, Xu et al. [30] (2017) ont développé un modèle de réseau neuronal appelé **auto-encodeurs couplés (CAN)**, destiné à résoudre le problème de l'impact du vieillissement sur la reconnaissance faciale. Cette approche se distingue par sa capacité à séparer l'image du visage en trois composantes : les caractéristiques d'identité, d'âge et de bruit.

En 2018, Usman et al. [31] ont mis au point des AE profonds pour la sélection des caractéristiques et la réduction des dimensions, optimisant ainsi la reconnaissance des expressions faciales. Cette méthode a surpassé d'autres techniques avancées en termes d'extraction de caractéristiques.

Plus récemment, Kantarci et al. [32] ont proposé un AE profond pour la reconnaissance faciale hétérogène, visant à résoudre les problèmes d'alignement entre les images visibles et thermiques.

Ces avancées soulignent l'importance des AE dans le domaine de la reconnaissance faciale, en tant qu'outils puissants pour le traitement des données complexes et bruitées.

Le tableau 1 inclut quelques algorithmes d'AE récemment développés dans ce contexte, montrant l'évolution et les améliorations continues dans ce domaine.

Tableau 1 : Quelques algorithmes d'AE pour la RF [31]

Algorithmes	Base d'images	Précision (%)
CAN[56]	CACD-VS	92,5
U-net[58]	EURECOM	88,33
DC-SSDA[59]	CMU-PIE	85
D²AE	CalebA	87,82%

a.3 Réseaux antagonistes génératifs (GAN)

Les réseaux antagonistes génératifs (GAN) sont une approche novatrice de la modélisation générative basée sur l'apprentissage profond non supervisé. Comme leur nom l'indique, ils fonctionnent sur le principe de l'adversité entre deux modèles : le générateur et le discriminateur. Le générateur a pour rôle de produire de nouvelles données, tandis que le discriminateur doit déterminer si ces données sont authentiques ou générées. Ce processus de compétition entre les deux réseaux permet d'améliorer la qualité des données générées.

Dans le cadre de la reconnaissance faciale (RF), les GANs sont utilisés pour générer des visages synthétiques ou compléter des images manquantes afin de résoudre des problèmes comme les variations d'apparence dues à l'âge, à la pose, ou à l'éclairage. Parmi les systèmes de RF utilisant les GANs, on trouve TR-GAN [33], ACSFC (Adversarial Cross-spectral Face Completion) [34], Age-cGAN [35], et DR-GAN [36]. Ces approches visent à améliorer la qualité des images faciales en prenant en compte les défis posés par les conditions variées auxquelles sont soumises les images des visages dans la réalité.

a.4 Réseaux hybrides

Les réseaux hybrides représentent une combinaison de plusieurs modèles d'apprentissage automatique visant à améliorer les performances d'un système ou à résoudre un problème spécifique avec une meilleure précision. Dans ces architectures hybrides, un modèle d'algorithme complète un autre pour atteindre des performances optimales. En reconnaissance faciale (RF), les réseaux hybrides sont souvent choisis pour optimiser l'efficacité du système. Parmi les types de combinaisons courantes, on retrouve :

⇒ CNN+GAN :

Utilisé pour combiner la puissance des réseaux convolutifs (CNN) avec la capacité des réseaux génératifs adversaires (GAN) pour générer et reconnaître des visages avec un haut niveau de précision.

⇒ CNN+AE :

Une combinaison entre CNN et les auto-encodeurs (AE), où les CNN sont utilisés pour extraire les caractéristiques tandis que les AE permettent de réduire la dimensionnalité des données.

⇒ GAN+RL (Reinforcement Learning) :

Ce type de combinaison intègre l'apprentissage par renforcement (RL) aux GAN, renforçant ainsi la capacité à générer des données tout en adaptant dynamiquement les modèles aux nouvelles données.

Plusieurs systèmes de reconnaissance faciale hybrides ont été développés dans la littérature, parmi lesquels :

- **DeepID3** : Proposé par Sun et al. [37], ce réseau est une combinaison de VGG-Net et GoogLeNet. Il modifie l'architecture externe des réseaux pour améliorer la vérification et l'identification des visages, atteignant une précision de 99,52 % sur la base d'images LFW ;
- **MDLFace** : Développé par Goswami et al. [38], ce réseau hybride combine des auto-encodeurs de débruitage avec des machines de Boltzmann profondes pour reconnaître les visages les plus mémorables ;
- **DCNN+GAN** : Zhang et al. [39] ont mis au point un système hybride pour la reconnaissance faciale hétérogène en combinant un réseau convolutif profond (DCNN) et un GAN.

a.5 Apprentissage par renforcement

L'apprentissage par renforcement est un domaine de l'intelligence artificielle qui se concentre sur la manière dont un agent intelligent peut apprendre à interagir avec un environnement en maximisant une récompense cumulative au fil du temps. En combinant cette approche avec l'apprentissage profond, on obtient l'apprentissage par renforcement profond, qui améliore les capacités d'apprentissage dans des environnements complexes.

L'apprentissage par renforcement profond est particulièrement utile dans les systèmes de reconnaissance faciale (RF), car il permet d'ajuster dynamiquement les modèles aux nouvelles données tout en optimisant les décisions basées sur les interactions passées. Par exemple, Duong et al. [40] ont développé un système de reconnaissance du vieillissement facial utilisant l'apprentissage par renforcement profond. Dans ce système, un réseau de neurones convolutifs (VGG19) est utilisé pour extraire les caractéristiques du visage, tandis que le modèle d'apprentissage par renforcement choisit des voisins similaires pour exploiter la relation temporelle entre deux images consécutives. Cela permet, par exemple, de prédire l'apparence d'un visage plus âgé à partir de l'image d'une personne plus jeune dans une séquence vidéo. Ainsi, cette technique optimise la reconnaissance faciale dans des situations complexes comme les changements liés à l'âge, et elle est devenue un outil puissant dans le développement de systèmes de reconnaissance de plus en plus performants.

Après avoir exploré les différentes approches de reconnaissance faciale, un autre trait biométrique clé mérite notre attention : la voix. En effet, la reconnaissance automatique de locuteur constitue un domaine en pleine expansion, où la biométrie vocale joue un rôle crucial. Tout comme la reconnaissance faciale, cette technique utilise des caractéristiques uniques à chaque individu, en l'occurrence les particularités de la voix, pour identifier ou vérifier l'identité d'une personne. La suite de cette étude portera donc sur les méthodes utilisées pour l'analyse et la reconnaissance biométrique vocale, en mettant l'accent sur l'automatisation du processus.

1.4 Reconnaissance automatique de locuteur

La reconnaissance automatique du locuteur (RAL) fait partie intégrante des technologies biométriques, notamment dans le domaine de la reconnaissance vocale. Elle permet d'identifier ou de vérifier l'identité d'un individu en analysant sa voix, une caractéristique biométrique unique. À travers l'analyse des propriétés acoustiques, telles que la hauteur, le timbre, et les modulations de la voix, les systèmes de RAL parviennent à établir un lien entre une personne et un échantillon vocal donné.

Cette section explore le cadre théorique et les méthodes utilisées dans la reconnaissance automatique du locuteur. Nous y aborderons les principes de base de la RAL, ses différentes branches, ainsi que les techniques modernes d'extraction et de modélisation des caractéristiques vocales. L'objectif est de comprendre comment ces techniques sont mises en œuvre dans des contextes pratiques tels que l'authentification, la sécurité, et l'analyse de grandes bases de données vocales.

L'essor des technologies basées sur l'intelligence artificielle et le machine learning, en particulier le deep learning, a permis des avancées significatives dans ce domaine. Ces progrès ont considérablement amélioré la précision et la robustesse des systèmes de reconnaissance vocale, en particulier dans des environnements complexes et variés, où les voix peuvent être altérées par du bruit de fond, des variations d'accent ou d'expression émotionnelle.

L'étude des techniques avancées de RAL se concentrera sur les modèles mathématiques et les approches computationnelles qui permettent d'extraire les caractéristiques distinctives de la voix humaine et de les modéliser.

Ce cadre théorique servira de base pour comprendre les systèmes de RAL dans le contexte de la biométrie et de la sécurité, et pour aborder les défis et opportunités liés à son implémentation dans le cas de notre travail.

1.4.1 Principes fondamentaux de la reconnaissance automatique du locuteur

La reconnaissance automatique du locuteur (RAL), souvent appelée biométrie vocale, couvre des processus visant à identifier, vérifier, classer ou détecter un individu à partir de sa voix. Elle regroupe un ensemble de méthodes qui permettent de déterminer l'identité d'une personne en analysant ses caractéristiques vocales uniques.

Cependant, il existe une certaine confusion entre la RAL et la reconnaissance automatique de la parole (RAP). La RAL concerne l'identification d'une personne en fonction de sa voix, alors que la RAP vise à comprendre le contenu du discours. De plus, le terme « reconnaissance vocale » a souvent été utilisé de manière incorrecte pour désigner ces deux concepts, bien que la reconnaissance vocale soit davantage liée à la RAP.

Plusieurs termes sont utilisés pour désigner la reconnaissance vocale [41], [42] dans divers contextes : biométrie vocale, identification du locuteur, ou encore voiceprint identification. Ces termes peuvent varier, mais tous se concentrent sur l'usage de la voix comme facteur d'identification biométrique.

Dans un système de RAL, les caractéristiques vocales d'une personne sont modélisées, soit à travers un modèle physiologique du tractus vocal humain, soit via un modèle statistique. Une fois ce modèle établi, il permet d'évaluer les nouvelles voix en fonction de la probabilité qu'elles appartiennent à un modèle donné.

La RAL est appliquée dans de nombreux domaines, notamment dans la sécurité, pour des applications telles que l'authentification vocale, ou dans des systèmes automatisés où l'identification rapide et précise est essentielle. Les avancées dans les techniques d'apprentissage machine et d'intelligence artificielle ont permis de rendre les systèmes de reconnaissance vocale plus robustes et performants, même dans des environnements variés ou bruyants.

1.4.1.1 Branches de la RAL

La discipline de la reconnaissance automatique du locuteur (RAL) se divise en plusieurs branches, directement ou indirectement reliées les unes aux autres. De manière générale, ces branches peuvent être classées en deux groupes distincts : les branches simples et les branches composées. Les branches simples correspondent à des processus autonomes, tandis que les branches composées impliquent l'utilisation de plusieurs branches simples, parfois complétées par d'autres techniques spécifiques.

Parmi les branches simples de la RAL, on retrouve la **vérification**, l'**identification**, et la **classification automatique du locuteur**. Ces approches permettent de déterminer si une personne est bien celle qu'elle prétend être (vérification), d'identifier une personne à partir d'un échantillon de voix (identification), ou encore de regrouper des locuteurs selon des caractéristiques partagées (classification).

Les branches composées incluent la **segmentation**, la **détection**, et le **suivi automatique** du locuteur. Ces branches font appel aux branches simples tout en intégrant des techniques supplémentaires pour segmenter un flux vocal en différentes parties, détecter la présence d'un locuteur ou encore suivre son discours au fil du temps. Parmi ces branches, la vérification automatique du locuteur reste la plus répandue, en raison de la forte demande dans les domaines de la sécurité et de l'authentification vocale.

Ces différentes branches permettent d'appliquer la RAL à divers secteurs tels que les systèmes de sécurité, la biométrie vocale, et les interfaces vocales, renforçant ainsi leur importance dans l'innovation technologique actuelle.

A) Vérification automatique du locuteur

Dans une application standard de vérification automatique du locuteur (VAL), la personne soumise à vérification, appelée locuteur de test, déclare son identité par des moyens généralement non vocaux, tels qu'un nom d'utilisateur ou un numéro d'identification. Bien que cette information puisse être exprimée vocalement, le signal vocal en lui-même n'est pas utilisé pour établir l'identité. L'identité proclamée sert à extraire un modèle vocal associé à la personne depuis une base de données, appelé modèle du locuteur cible. Ensuite, la voix du locuteur de test (le segment vocal) est comparée à ce modèle.

Cependant, il ne suffit pas de comparer uniquement au modèle du locuteur cible. Pour que la vérification soit pertinente, il faut également un modèle de comparaison opposé, un modèle générique représentant "le reste du monde". Cela permet d'évaluer à quel point la voix du locuteur de test est similaire à celle du locuteur cible, mais aussi à celle d'autres locuteurs non concernés. C'est comme évaluer une qualité morale en la comparant à son contraire : pour juger de la bonté, il faut aussi connaître la méchanceté.

Dans le domaine de la VAL, une des méthodes les plus courantes pour créer ce modèle générique est le Modèle Universel de Référence (UBM - Universal Background Model) [41].

Il est construit à partir de données recueillies auprès d'un large éventail de locuteurs, offrant ainsi une référence pour distinguer le locuteur de test du reste de la population. Cela permet une double comparaison : d'un côté, le locuteur de test est comparé au modèle cible, et de l'autre, au modèle UBM pour évaluer les différences et déterminer l'identité.

B) Identification automatique du locuteur

Dans le processus d'identification automatique du locuteur (IAL), la voix du locuteur à identifier est comparée à un ensemble de modèles vocaux pré-enregistrés. L'algorithme retourne le ou les modèles ayant la plus grande probabilité de correspondance avec la voix testée.

Il existe deux types d'identification dans ce cadre : l'identification dans un ensemble fermé et l'identification dans un ensemble ouvert. Pour l'identification dans un ensemble fermé, la comparaison se fait uniquement entre le locuteur testé et un nombre limité de modèles connus. Ainsi, l'algorithme choisit les locuteurs qui présentent la plus grande similarité avec le segment vocal.

En revanche, l'identification dans un ensemble ouvert combine à la fois des éléments de la vérification automatique du locuteur (VAL) et de l'identification dans un ensemble fermé. Cela signifie que le locuteur est d'abord identifié dans un ensemble fermé de modèles, suivi d'une étape de vérification pour confirmer la validité des résultats obtenus.

C) Classification automatique du locuteur

La classification est, de manière générale, le processus consistant à attribuer des étiquettes à des formes ou des données en fonction de caractéristiques partagées. En ce qui concerne la classification des locuteurs, il s'agit de regrouper les signaux audio similaires selon des critères spécifiques.

Les deux sous-catégories les plus répandues dans la classification des locuteurs sont la classification par genre et la classification par âge. La classification par genre vise à regrouper les locuteurs masculins et féminins dans des catégories distinctes. Quant à la classification par âge, elle permet de classer les locuteurs en fonction de tranches d'âge, par exemple, en séparant les enfants, les jeunes adultes et les personnes âgées.

Les mêmes caractéristiques utilisées pour l'identification et la vérification des locuteurs peuvent également être exploitées pour la classification. Pour la classification par genre, les voyelles et les fricatives sont particulièrement importantes, car elles dépendent de la fréquence fondamentale du conduit vocal et de ses harmoniques supérieures, ce qui permet de différencier les hommes, les femmes et les enfants (les fréquences fondamentales sont environ de 130 Hz pour les hommes, 220 Hz pour les femmes et 265 Hz pour les enfants) [43]. Pour la classification par âge, des caractéristiques telles que le Jitter et le Shimmer [44] sont souvent utilisées pour évaluer les changements liés à l'âge dans la voix.

D) Segmentation automatique du locuteur

La segmentation automatique du locuteur consiste à diviser un flux audio en plusieurs segments correspondant à différents locuteurs, en se basant sur leurs caractéristiques vocales spécifiques. Elle repose sur l'identification des moments où des changements acoustiques sont détectés dans l'audio. Ces transitions sont considérées comme des points de rupture entre différents segments, où chaque locuteur est identifié et étiqueté.

La segmentation des locuteurs est souvent associée à la reconnaissance automatique du locuteur, car les deux processus partagent des techniques communes. En pratique, chaque changement acoustique est marqué par une coupure, et ces segments sont ensuite étiquetés avec les locuteurs associés. Cette technique est largement utilisée dans les applications de téléconférence où il est utile d'identifier les interventions de chaque participant et de les segmenter pour une meilleure organisation de la conversation.

De plus, dans certaines utilisations, le terme "segmentation du locuteur" est parfois employé comme synonyme de la diarisation du locuteur, qui combine à la fois la segmentation et la classification des différents locuteurs présents dans l'audio.

E) Détection et le suivi automatique du locuteur

La détection automatique du locuteur combine à la fois la segmentation des locuteurs et des techniques d'identification ou de vérification du locuteur. Elle vise à identifier un ou plusieurs locuteurs dans un flux audio donné. Par exemple, si nous avons une liste de locuteurs connus, la détection permet de segmenter le flux audio en identifiant le locuteur pour chaque segment, suivie d'une identification automatique du locuteur dans un ensemble fermé.

Dans des situations plus complexes, comme lorsque le flux audio inclut des locuteurs non répertoriés, de la musique ou d'autres types de sons, on peut recourir à une vérification automatique du locuteur pour déterminer si chaque segment appartient à un locuteur de la liste. Si le nombre de locuteurs est important, une identification automatique dans un ensemble ouvert peut être appliquée.

Le suivi automatique du locuteur, quant à lui, consiste à suivre un ou plusieurs locuteurs au sein d'un flux audio. Cela se rapproche de la détection, mais ici, les segments audios sont attribués à des locuteurs cibles connus et suivis tout au long du flux. Le suivi du locuteur est largement utilisé dans des contextes comme les conversations, où il est nécessaire de marquer chaque intervention et d'attribuer les segments aux bons locuteurs.

1.4.1.2 Modalités de RAL

Les modalités de la reconnaissance automatique du locuteur (RAL) peuvent être mises en œuvre de différentes manières. Dans le cadre de la vérification automatique du locuteur (VAL), ces modalités se réfèrent principalement à la façon dont les informations acoustiques issues de la voix sont combinées avec d'autres types d'informations en fonction des besoins de l'application. Selon les exigences spécifiques, des informations supplémentaires peuvent être intégrées aux caractéristiques acoustiques du conduit vocal pour renforcer la fiabilité du processus de vérification.

A) RAL dépendante du texte

La reconnaissance automatique du locuteur (RAL) en mode dépendant du texte exige que le locuteur prononce une phrase spécifique lors du test. Ce système a été conçu principalement pour contrer les tentatives d'usurpation d'identité. En effet, si l'usurpateur ne connaît pas à l'avance la phrase qui lui sera demandée, il lui est impossible de se préparer pour tromper le système.

L'une des approches principales dans la conception de la RAL dépendante du texte consiste à générer des phrases aléatoires que le locuteur doit prononcer. Cela permet de s'assurer que la réponse correspond non seulement aux caractéristiques vocales du locuteur cible, mais aussi au contexte linguistique de la phrase prononcée. Ce mode est principalement utilisé dans les systèmes de vérification automatique du locuteur (VAL), où il est essentiel que l'identification soit précise et sécurisée.

B) RAL indépendante du texte

La reconnaissance automatique du locuteur (RAL) en mode indépendant du texte est une méthode flexible, applicable à toutes les branches de la RAL. Dans ce mode, le système se base uniquement sur les caractéristiques physiologiques du tractus vocal du locuteur, sans se préoccuper du contenu de ce qui est dit. Un des défis majeurs de cette approche est le risque de mauvaise couverture du spectre phonétique dans les segments d'entraînement.

Par exemple, dans un système indépendant du texte, l'entraînement n'impose pas de contrainte sur le contenu du texte prononcé, ce qui peut entraîner un manque de correspondance entre les sons du segment d'entraînement et ceux du segment de test. Cela signifie que certaines parties du discours test peuvent ne pas avoir été observées lors de l'entraînement, augmentant ainsi le risque d'erreurs de reconnaissance.

Pour compenser cette limitation, les systèmes indépendants du texte nécessitent généralement des durées d'entraînement et de test plus longues afin d'obtenir une précision de reconnaissance satisfaisante.

1.4.2 Extraction des caractéristiques

Un signal est une représentation mesurée d'un phénomène physique observé. Il décrit souvent une observation d'un phénomène lié à des concepts de temps ou d'espace. Dans le cadre de la reconnaissance vocale, un signal vocal est une mesure enregistrée sur une échelle de temps, représentant les vibrations produites par les cordes vocales d'une personne.

Afin de faciliter l'analyse de ces signaux continus, il est souvent nécessaire de les échantillonner, c'est-à-dire de les discrétiser en un ensemble fini de points. Ce processus est connu sous le nom de discrétisation, où le signal continu est converti en un signal discret, plus adapté aux méthodes de traitement numérique.

La parole est un signal qui varie dans le temps, et qui porte une multitude d'informations telles que le contenu verbal, l'identité du locuteur, ainsi que des caractéristiques acoustiques comme l'émotion ou le langage. Ces informations peuvent être analysées dans les domaines du temps et de la fréquence. Un des outils les plus couramment utilisés pour représenter ces informations est *le spectrogramme*, qui montre la variation des fréquences au fil du temps sous forme d'image, où l'axe horizontal représente le temps, l'axe vertical la fréquence, et l'intensité d'un point donné indique l'amplitude d'une certaine fréquence à un moment donné.

Cependant, bien que les spectrogrammes soient utiles pour visualiser les signaux vocaux, ils ne sont pas optimisés pour la reconnaissance vocale. Deux principales raisons expliquent cela : d'une part, la dimension fréquentielle est souvent trop élevée pour une modélisation statistique efficace. Par exemple, une Transformée de Fourier rapide (FFT) sur 1024 points produit 512 composantes fréquentielles, ce qui est bien trop important pour des modèles statistiques. D'autre part, les composantes de fréquence après la FFT sont souvent très corrélées entre elles, ce qui complique l'utilisation des modèles avec des matrices de covariance diagonale pour la reconnaissance des locuteurs. La figure 17 illustre un exemple de spectrogramme, représentant les variations fréquentielles du signal vocal en fonction du temps.




Figure 17 : Illustration d'un Spectrogramme [44]

Pour remédier à cela, une représentation plus compacte du signal de la parole est nécessaire. C'est pourquoi *les coefficients cepstraux de fréquence Mel* (MFCC) [45] sont couramment utilisés dans les applications de reconnaissance vocale et de locuteur. Ces coefficients sont obtenus en divisant le signal vocal en courtes trames et en appliquant une transformation cepstrale pour décorréler les différentes composantes et obtenir une représentation plus compacte et efficace du signal vocal.

Les MFCC permettent ainsi de réduire la complexité tout en conservant l'essence des informations nécessaires pour la reconnaissance du locuteur ou de la parole.

La puissance des coefficients MFCC réside dans leur capacité à modéliser la forme du tractus vocal d'une personne à travers un spectre de puissance sur une courte période. Les MFCC associés à ce processus sont notés par o_i , comme défini par l'équation (14) :

$$o_i = \sum_{m=1}^M \cos \left[i \left(m - \frac{1}{2} \right) \frac{\pi}{2} \right] X(m), i = 1, \dots, P \quad (14)$$

Où les symboles Δ et $\Delta\Delta$ (Δ^2) représentent respectivement la vitesse (variation des coefficients dans le temps) et l'accélération (variation de la vitesse) des coefficients cepstraux en fréquence mélodique (MFCC). En désignant par e l'énergie logarithmique, le vecteur acoustique correspondant au signal $s(n)$ est donné par l'expression suivante :

$$o = [e, o_1, \dots, o_p, \Delta c, \Delta o_1, \dots, \Delta o_p, \Delta\Delta c, \Delta\Delta o_1, \dots, \Delta\Delta o_p] \quad (15)$$

Dans la plupart des systèmes de RAL, $P = 12$, ce qui donne $o \in \mathbb{R}^{39}$ [44] La figure 18 nous montre comment se passe l'extraction d'un vecteur MFCC




Figure 18 : processus d'extraction d'un vecteur MFCC à partir d'une trame de parole [44]

1.4.3 Modélisation du locuteur

En utilisant les vecteurs de caractéristiques extraits à partir des paroles d'entraînement d'un locuteur, un modèle de locuteur est ensuite créé et stocké dans la base de données du système. Dans la reconnaissance automatique du locuteur (RAL) dépendante du texte, ce modèle est spécifique à une phrase ou un énoncé et inclut les dépendances temporelles entre les vecteurs de caractéristiques. Le processus de comparaison dans la reconnaissance du locuteur dépendante du texte est similaire à celui de la reconnaissance vocale. Cependant, dans la RAL indépendante du texte, on modélise généralement la distribution des caractéristiques sans prendre en compte ces dépendances temporelles.

Il est important de noter que dans le mode dépendant du texte, il est possible d'aligner temporellement les segments d'entraînement et de test puisque les énoncés sont identiques en termes de phonèmes. Cependant, dans le mode indépendant du texte, il n'y a pas cette correspondance temporelle, ce qui rend l'alignement des trames plus complexe. Pour surmonter cette difficulté, certaines méthodes utilisent la segmentation phonétique [46] [47] ou des unités pilotées par les données pour structurer les modèles de locuteurs.

Les modèles classiques de locuteurs peuvent être divisés en deux grandes catégories : les modèles *Templates* et les modèles *stochastiques*. Dans les modèles *Templates*, les vecteurs de caractéristiques des phases d'entraînement et de test sont comparés directement, et la différence entre les deux indique leur degré de similarité. Des techniques telles que la *quantification vectorielle (VQ)* [48] et la distorsion temporelle dynamique (DTW) [49] sont des exemples de ces méthodes, utilisées respectivement dans les modes indépendants et dépendants du texte.

Les modèles stochastiques [50], quant à eux, modélisent chaque locuteur comme une source probabiliste, dont la densité de probabilité est fixe mais inconnue. La phase d'entraînement permet d'estimer les paramètres de cette fonction de densité. Un modèle de mélange gaussien (GMM) [51] est souvent utilisé pour ce type de reconnaissance. Par exemple, en 2000, Reynolds a proposé d'entraîner un modèle GMM à partir des données d'une large population de locuteurs [52], créant ainsi un modèle universel de référence appelé Universal Background Model (UBM). Le modèle UBM permet de modéliser les caractéristiques acoustiques d'une population générale, et la densité des vecteurs acoustiques est ensuite évaluée pour effectuer la reconnaissance. La densité du vecteur acoustique est donnée par

$$p(o|\text{UBM}) = p(o|\Lambda^{\text{ubm}}) = \sum_{c=1}^C \pi_c^{\text{ubm}} \mathcal{N}(o|\mu_c^{\text{ubm}}, \Sigma_c^{\text{ubm}}) \quad (16)$$

avec

$$\Lambda^{\text{ubm}} = \{\pi_c^{\text{ubm}}, \mu_c^{\text{ubm}}, \Sigma_c^{\text{ubm}}\}_{c=1}^C \quad (17)$$

Les paramètres de GMM, qui modélisent les locuteurs individuels, sont estimés par l'algorithme *Expectation-Maximization (EM)* [53]. Cet algorithme utilise les données vocales

provenant d'un large ensemble de locuteurs pour ajuster les paramètres du modèle universel de référence (UBM). Alors que l'UBM représente la population globale, chaque locuteur est ensuite modélisé par un **modèle GMM spécifique au locuteur**. Pour un locuteur cible donné, son modèle GMM est généré en adaptant les paramètres de l'UBM pour mieux correspondre aux caractéristiques vocales uniques de ce locuteur par l'équation :

$$p(o|\text{Locuteur}^{(\text{cible})}) = p(o|\Lambda^{(\text{cible})}) = \sum_{c=1}^C \pi_c^{(\text{cible})} \mathcal{N}(o|\mu_c^{(\text{cible})}, \Sigma_c^{(\text{cible})}) \quad (18)$$

Où
$$\Lambda^{(\text{cible})} = \{\pi_c^{(\text{cible})}, \mu_c^{(\text{cible})}, \Sigma_c^{(\text{cible})}\}_{c=1}^C \quad (19)$$

sont appris en utilisant une adaptation maximale a posteriori, *maximum a posteriori adaptation (MAP)* [54]

Pour la vérification d'un locuteur, étant donné les vecteurs acoustiques $O^{(\text{test})}$ d'un segment de test et le modèle du locuteur cible, le processus revient à calculer le rapport logarithmique de vraisemblance :

$$S_{\text{GMM/UBM}}(O^{(\text{test})}|\Lambda^{\text{ubm}}) = \log \left(\frac{p(O^{(\text{test})}|\Lambda^{\text{cible}})}{p(O^{(\text{test})}|\Lambda^{\text{ubm}})} \right) \quad (20)$$

qui compare la probabilité que le segment ait été généré par le modèle du locuteur cible par rapport à la probabilité qu'il ait été généré par un autre modèle, comme le modèle UBM (Universal Background Model). La figure 19 montre la procédure d'évaluation du modèle GMM/UBM




Figure 19 : Procédure d'évaluation du modèle GMM/UBM pour la tâche de VAL [53]

Dans le cadre du paradigme d'entraînement, les modèles peuvent être divisés en deux grandes catégories : les modèles génératifs et les modèles discriminatifs. Les modèles génératifs, comme les Modèles de Mélanges Gaussiens (GMM) et la Quantification Vectorielle (VQ), tentent d'estimer la distribution des caractéristiques propres à chaque locuteur. En revanche, les modèles discriminatifs, tels que les *Réseaux de Neurones Artificiels* (ANN) [55] et les *Machines à Vecteurs de Support* (SVM) [56], se concentrent sur la modélisation des frontières entre différents locuteurs, optimisant ainsi la séparation entre eux.

En résumé, un locuteur est décrit par un modèle spécifique (par exemple, VQ, GMM ou SVM). Pendant l'exécution, un segment de test est converti en une série de vecteurs caractéristiques ou en un supervecteur, lequel est ensuite comparé aux modèles des locuteurs cibles pour une évaluation précise.

1.4.4 Approches modernes de la RAL

L'approche GMM/UBM repose sur l'utilisation de trames acoustiques pour modéliser les locuteurs, où les Modèles de Mélanges Gaussiens (GMM) sont utilisés pour décrire la distribution des trames. Cette approche a dominé la vérification automatique du locuteur pendant plusieurs années depuis son introduction à la fin des années 90. Cependant, elle présente des limitations. L'une des principales faiblesses réside dans le fait que l'entraînement des modèles GMM et UBM est dissocié. Cela signifie que les informations contrastantes entre les locuteurs cibles et les imposteurs ne sont pas intégrées de manière explicite dans le processus d'entraînement. De plus, cette méthode a du mal à supprimer les informations non liées aux locuteurs, comme les bruits ou les variations de canaux. Bien que des efforts aient été faits pour traiter ces variations, ils ne sont pas aussi performants que les approches modernes.

À partir de 2006, les chercheurs ont commencé à envisager la vérification du locuteur sous un angle différent. Plutôt que de se concentrer sur les scores de vraisemblance au niveau des trames, ils ont développé des méthodes reliant les caractéristiques acoustiques à un vecteur à haute dimension représentant l'ensemble de l'énoncé. Ce vecteur est indépendant de la durée de l'énoncé, ce qui permet d'appliquer des méthodes de *Machine Learning* comme les SVM et l'analyse factorielle. Les principales méthodes influentes basées sur cette idée sont les GMM/SVM, l'*analyse factorielle* conjointe (JFA) et les *i-vectors*.

Dans le modèle GMM/SVM [57], les supervecteurs sont construits à partir de GMM adaptés pour chaque locuteur cible à partir du modèle UBM. Un SVM dépendant du locuteur est ensuite entraîné à différencier ces supervecteurs de ceux des imposteurs. Pendant l'évaluation, les scores SVM des segments de test sont calculés, et les décisions sont basées sur un seuil.

Dans le modèle JFA [58], les variabilités des locuteurs et des sessions sont modélisées par des variables latentes, représentant les facteurs liés au locuteur et ceux liés aux canaux. Lors de l'évaluation, la variabilité des sessions est intégrée dans le modèle à travers ces variables latentes, ce qui permet de mieux gérer les conditions de canal.

1.4.5 Approche i-vector/PLDA

Dans un système i-vector [59], les énoncés sont représentés par une estimation de la moyenne postérieure des facteurs latents, appelés *i-vectors*. Ces *i-vectors* capturent simultanément les informations relatives au locuteur ainsi qu'au canal. Lors de la phase d'évaluation, l'objectif est de supprimer les variabilités indésirables liées au canal, ce qui est réalisé à travers *l'analyse discriminante linéaire* (LDA) [60] ou en intégrant ces facteurs latents dans un modèle LDA probabiliste. Ces étapes permettent de mieux isoler les caractéristiques spécifiques au locuteur, en minimisant les interférences dues au canal de communication.

1.4.5.1 i-vector

Le modèle i-vector postule que pour un segment de parole donné, le super vecteur M , dépendant du locuteur, est généré par la formule suivante :

$$M = m + Tw \quad (21)$$

Où :

- m est un super vecteur qui ne dépend ni du locuteur, ni du canal,
- T est une matrice de rang inférieur,
- w est un vecteur de faible dimension représentant le segment de parole.

En supposant que w suit une distribution normale standard $N(0, I)$, cette équation ci-dessus est la représentation d'un modèle linéaire gaussien, ce qui signifie que M suit une distribution gaussienne $N(m, TT^T)$. L'estimation des paramètres de ce modèle et l'inférence des variables se font de manière relativement simple.

1.4.5.2 Analyse discriminante linéaire probabiliste (PLDA)

Le modèle i-vector est un modèle à variabilité totale, ce qui signifie qu'un i-vector contient à la fois les informations relatives au locuteur ainsi que d'autres facteurs non liés au locuteur, notamment ceux liés aux canaux. Cela présente un problème lorsque l'objectif est de discriminer précisément les locuteurs, car la présence de ces variabilités liées aux canaux réduit l'efficacité de la reconnaissance.

Pour résoudre ce problème, l'analyse discriminante linéaire probabiliste (PLDA) est utilisée. Elle sépare l'espace de variabilité totale en deux sous-espaces distincts : un sous-espace dédié aux locuteurs et un autre aux canaux. De cette façon, les i-vectors peuvent mieux représenter les locuteurs en minimisant l'impact des variations dues aux canaux. Cette approche permet d'améliorer la précision des modèles de reconnaissance vocale.

Ce modèle peut être formulé ainsi dans le cadre de la PLDA, où l'objectif est de maximiser la discrimination entre les locuteurs en tenant compte de la variabilité des canaux.

$$w_r = m + Ux_r + Vy + \epsilon_r \quad (22)$$

Où le vecteur w_r représente l'i-vector du r -ème segment de parole, tandis que m est la moyenne de la population. U représente le sous-espace du canal, et x_r est un vecteur associé au canal.

De plus, V désigne le sous-espace du locuteur, et y est un vecteur qui caractérise les informations propres au locuteur. Enfin, ϵ_r représente le résidu, c'est-à-dire les informations restantes qui ne peuvent être attribuées ni au canal ni au locuteur.

1.4.6 Deep learning et Reconnaissance automatique de locuteur

Dans le contexte spécifique de la reconnaissance automatique de locuteur (RAL), les méthodes traditionnelles se sont révélées limitées par leur capacité à capturer les variations subtiles de la voix entre les individus. Avec l'essor du deep learning, de nouveaux modèles comme les réseaux de neurones profonds (DNN), les réseaux convolutifs (CNN) et les architectures récurrentes (LSTM) permettent d'exploiter les caractéristiques riches des données vocales pour une reconnaissance plus fiable et robuste.

1.4.6.1 Réseaux de Neurones Profonds (DNN)

Les réseaux de neurones profonds (DNN) sont utilisés pour capturer les caractéristiques vocales uniques d'un individu sous la forme d'**embeddings**. Ces embeddings sont des vecteurs à haute dimension qui représentent les caractéristiques spécifiques de la voix. [61]

L'objectif principal du DNN dans la reconnaissance de locuteurs est de minimiser une fonction de perte (souvent la **cross-entropy**) entre les labels réels des locuteurs y et les prédictions du modèle $\hat{y}_i$

$$\mathcal{L}(\theta) = - \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (23)$$

Où :

- N est le nombre d'échantillons,
- y_i est le label réel de l'échantillon,
- $\hat{y}_i$ est la prédiction du DNN.

Un des modèles populaires est le *x-vector*, qui extrait les caractéristiques des segments vocaux et les compresse dans un vecteur de dimension fixe.

Les *x-vectors* peuvent être visualisés comme des points dans un espace multi-dimensionnel, où chaque point représente un locuteur unique. Les locuteurs proches dans cet espace ont des voix similaires, tandis que ceux éloignés ont des voix distinctes.

1.4.6.2 Réseaux Convolutionnels (CNN)

Les CNN sont efficaces pour la reconnaissance de locuteurs [62], car ils peuvent analyser les spectrogrammes vocaux. Un spectrogramme est une représentation graphique des variations des fréquences sonores au cours du temps.

Un CNN est constitué de plusieurs couches convolutives, où chaque filtre f extrait des caractéristiques locales d'un spectrogramme X par convolution.

$$f(X) = X \cdot W + b \quad (24)$$

Où :

- est l'opération de convolution,
- W est le filtre,
- b est le biais.

L'objectif est d'extraire des caractéristiques pertinentes dans le spectrogramme pour différencier les locuteurs.

1.4.6.3 Réseaux Récurrents (RNN) et LSTM

Les RNN et les **Long Short-Term Memory** (LSTM) [63] sont particulièrement adaptés pour le traitement des séquences temporelles, telles que la parole. Les LSTM peuvent mémoriser les informations sur de longues périodes, ce qui est crucial pour la reconnaissance de locuteurs.

Le LSTM utilise des **portes** (d'entrée, d'oubli et de sortie) pour contrôler le flux d'informations à chaque étape temporelle t :

$$h_t = o_t \cdot \tanh(C_t) \quad (25)$$

Où :

- h_t est l'état caché à l'instant t ,
- o_t est la porte de sortie,
- C_t est l'état de la mémoire à l'instant t .

Les LSTM sont particulièrement efficaces pour capturer les dépendances temporelles à long terme dans les données vocales.

1.4.6.4 Réseaux Antagonistes Génératifs (GAN)

Les GANs ont également été explorés dans la reconnaissance de locuteurs, en particulier pour générer des données vocales synthétiques pour améliorer les modèles existants.

Fonctionnement :

Un GAN est constitué de deux réseaux :

- **Le générateur** G, qui crée des données synthétiques,
- **Le discriminateur** D, qui tente de distinguer les données synthétiques des données réelles.

Le processus d'entraînement peut être décrit par la fonction de coût suivante :

$$\min_G \max_D E [\log D(x)] + E [\log (1 - D(G(z)))] \quad (26)$$

Où x est une donnée réelle et z est une variable aléatoire.

Les GANs peuvent générer des variations synthétiques des voix humaines [64], ce qui permet d'augmenter les jeux de données d'entraînement dans les situations où les données vocales sont limitées.

1.4.6.5 Apprentissage Auto-Supervisé (Self-Supervised Learning)

Des modèles comme **Wav2Vec2.0** exploitent l'apprentissage auto-supervisé pour apprendre des représentations à partir d'ensembles de données audio non étiquetées [65]. Ce modèle est particulièrement utile pour des tâches de reconnaissance de locuteurs lorsque les données annotées sont rares.

Le modèle Wav2Vec2.0 est entraîné en deux étapes :

- **Pré-formation** : Apprentissage des représentations à partir d'audio non étiqueté.
- **Affinement** : Utilisation de petits ensembles de données étiquetées pour affiner les représentations apprises.

$$\mathcal{L}_{SSL} = - \sum_i \log P(c_i | X_i, \theta) \quad (27)$$

Où c_i est la représentation cible, X_i est l'entrée audio, et θ représente les paramètres du modèle. Le modèle Wav2Vec2.0 est capable de capturer les représentations audios à différents niveaux de granularité (du bruit de fond à la parole claire) et améliore les performances de reconnaissance.

1.5 Conclusion

Dans ce premier chapitre, nous avons exploré les concepts fondamentaux de la reconnaissance faciale et de la reconnaissance automatique du locuteur, deux technologies phares dans le domaine de l'identification biométrique. Ces approches offrent des solutions efficaces pour authentifier et identifier les individus sur la base de caractéristiques physiques et vocales uniques. La reconnaissance faciale repose sur des algorithmes avancés permettant de capturer et analyser les traits du visage avec précision, tandis que la reconnaissance automatique du locuteur utilise les caractéristiques acoustiques de la voix humaine pour une identification fiable. Ces deux technologies constituent des piliers de l'authentification biométrique, et leur intégration dans des systèmes multimodaux améliore la robustesse et la sécurité des processus d'authentification. Leur combinaison permet d'optimiser la précision en tenant compte des différents scénarios d'utilisation où une modalité peut être plus adaptée qu'une autre.

CHAPITRE 2

ETAT DE L'ART DE LA RECONNAISSANCE OPTIQUE DE CARACTERE

2.1 Introduction

Dans ce deuxième chapitre, nous aborderons le domaine de la **reconnaissance optique de caractères (OCR)**, une technologie clé pour l'automatisation de la collecte d'informations à partir de documents. L'OCR permet d'extraire des données textuelles rapidement et efficacement à partir d'images, simplifiant ainsi le traitement de documents et l'intégration de ces données dans un système. Ce chapitre se concentrera sur les avancées récentes en matière de technologies OCR, en étudiant les algorithmes utilisés, leurs performances et les défis techniques qui leur sont associés. Ces éléments permettront d'évaluer les meilleures approches pour l'intégration de l'OCR dans notre solution d'authentification multimodale.

2.2 Reconnaissance Optique de caractère

La reconnaissance optique de caractères (OCR) vise à identifier les caractères présents dans une image. Elle consiste à interpréter les caractères d'une image d'entrée pour les convertir en une forme compréhensible par une machine, telle que le format ASCII ou un autre format équivalent. L'objectif de ce processus est d'extraire des segments d'image qui contiennent un mot ou un caractère spécifique, puis de prédire l'information textuelle associée à ces segments.

Les approches de la reconnaissance de caractères se divisent en deux catégories principales : celles basées sur la reconnaissance de caractères individuels et celles basées sur la reconnaissance de mots entiers. Les premières se concentrent sur l'identification et la classification des caractères un à un, tandis que les secondes analysent des blocs de texte pour reconnaître directement des mots.

2.2.1 Méthodes traditionnelles

Les méthodes traditionnelles de reconnaissance de caractères s'appuient sur des classifieurs spécifiques pour reconnaître chaque caractère dans une image de manière individuelle. Ces approches, qui dominent l'OCR (Optical Character Recognition) depuis ses débuts, reposent sur une classification séquentielle des caractères. Cela signifie que les systèmes doivent analyser chaque caractère un à un, en utilisant des caractéristiques visuelles préalablement définies par l'ingénierie manuelle. Ces caractéristiques peuvent inclure des éléments tels que les contours des lettres, leurs orientations ou leurs segments distincts.

L'extraction de ces caractères se fait souvent à l'aide de techniques comme les *fenêtres glissantes* ou encore la détection des *composantes connectées*. Une fenêtre glissante parcourt l'image, analysant chaque région à la recherche de caractères, tandis que les composantes connectées segmentent les pixels d'une image pour isoler les caractères. Neumann et Matas [66], par exemple, ont développé une méthode qui s'appuie sur l'orientation des traits pour classifier les caractères. Néanmoins, cette approche est limitée par les caractéristiques bas niveau qu'elle utilise, comme le périmètre ou la surface des caractères.

Yao et al. [67] ont proposé une avancée notable avec leur technique des *strokelets*, une représentation des sous-patches des caractères, permettant de mieux décrire les traits constitutifs des lettres. Cette méthode est à la fois robuste et efficace dans la détection des caractères sur des images variées.

Malgré leur efficacité, ces techniques sont bien adaptées aux ensembles de données homogènes, mais elles montrent leurs limites sur des données plus hétérogènes. La **nécessité d'une ingénierie complexe** pour ajuster ces modèles à différents types de données a ouvert la voie à l'utilisation de modèles d'apprentissage profond, notamment les *réseaux de neurones convolutionnels (CNN)*, qui sont devenus plus populaires en raison de leur capacité à traiter automatiquement les caractéristiques sans intervention humaine.

Ces **réseaux de neurones profonds** se sont révélés particulièrement performants pour l'OCR, permettant une généralisation plus efficace sur des données variées et une meilleure précision dans des conditions complexes.

2.2.2 Méthodes basées sur des Réseaux de neurones

2.2.2.1 Reconnaissance de caractères

Les récentes avancées dans l'utilisation des réseaux de neurones convolutifs pour l'analyse d'images ont permis de développer des méthodes de reconnaissance et de classification de caractères à la fois très rapides et précises. Plusieurs travaux, comme ceux de [68] [69] exploitent des réseaux convolutionnels profonds pour classifier les caractères.

Par exemple, les systèmes développés par [67] et [68] segmentent l'image en zones susceptibles de contenir des caractères. Dans le cas de [68], la segmentation est effectuée par des techniques de binarisation de l'image, tandis que [67] utilise un classifieur supervisé pour cette tâche. Le système « Photo OCR », présenté par Bissaco et ses collaborateurs dans [68], s'appuie sur un réseau de neurones "classique" composé de cinq couches entièrement connectées et utilisant la fonction d'activation ReLU. D'autres travaux, comme ceux de Wang et ses collaborateurs [70], exploitent des architectures de réseaux avec deux couches de convolution, composées de 115 et 720 filtres respectivement, pour classifier 62 classes de caractères (incluant les lettres majuscules, minuscules et les chiffres). Sur la base de données ICDAR2003, ce système a atteint une précision de 90 %, surpassant ainsi d'autres méthodes avec des performances intéressantes malgré la faible profondeur des réseaux. Ces approches, bien que limitées par la taille des bases de données, utilisent souvent des techniques d'augmentation des données en combinant différentes bases ou en générant des données synthétiques. Bien que les architectures utilisées ne soient pas très profondes en raison de la taille des ensembles d'apprentissage, elles permettent néanmoins d'atteindre des résultats remarquables.

La figure 20 montre comment la reconnaissance de caractère s'effectue




Figure 20 : Technique de reconnaissance de caractère [70]

2.2.2.2 Reconnaissance de mots

La reconnaissance de mots constitue une alternative à la reconnaissance de caractères et repose sur l'identification de mots entiers dans des images. Contrairement à la reconnaissance de caractères, qui classe chaque lettre séparément, les méthodes basées sur la reconnaissance de mots analysent les caractéristiques de l'ensemble du mot avant de procéder à la classification. Par exemple, Mishra et ses collègues [71] et Novikova et al. [72] utilisent des classificateurs de caractères explicites mais regroupent les preuves pour former un mot entier. Ils construisent un graphe qui aide à déduire les mots en combinant ces preuves.

Goel et al. [73] ont développé une méthode où des images synthétiques en noir et blanc sont créées pour chaque mot d'un lexique avec différentes polices et tailles. Ensuite, la reconnaissance se fait en faisant correspondre les caractéristiques de l'image requise avec celles des images synthétiques préconstruites.

Jaderberg et ses collègues [74] ont utilisé un réseau de neurones convolutifs (CNN) qui prend une image d'un mot unique, redimensionnée à 32x100 pixels, et la classe parmi les mots d'un dictionnaire de 90 000 mots anglais. Le réseau de Jaderberg comprend cinq couches de convolution et trois couches entièrement connectées, avec une dernière couche dédiée à la classification des mots à travers ce large dictionnaire. Pour entraîner un tel réseau sur un aussi grand nombre de classes, un ensemble de données synthétiques a été utilisé. Ces données sont si réalistes que le CNN, bien qu'entraîné uniquement sur des données synthétiques, est capable de traiter des données réelles. La figure 21 montre l'utilisation d'un CNN pour la reconnaissance de caractère




Figure 21 Réseau CNN pour la reconnaissance de mots proposés par Jaderberg [73]

2.2.3 Détection et reconnaissance de caractère

La détection et la reconnaissance de caractères impliquent plusieurs approches avancées. Jaderberg et al. [75] ont proposé une architecture de réseau de neurones convolutionnel (CNN) capable d'accomplir à la fois la détection des zones de texte et la reconnaissance de caractères. Ils démontrent que l'utilisation de la fonction d'activation *Maxout* au lieu de *ReLU* améliore les performances. Le CNN prend en entrée des images de petite taille (24x24 pixels) et produit

quatre sorties : un classifieur pour distinguer le texte de l'arrière-plan (2 classes), un classifieur de caractères insensibles à la casse (37 classes), un classifieur sensible à la casse (63 classes), et un classifieur de *bigrammes* (604 classes). Ces sorties permettent de mieux structurer l'information visuelle dans une image.

Pour entraîner ce réseau, les chercheurs ont d'abord entraîné le modèle sur la classification des caractères insensibles à la casse, puis ils ont utilisé les premières couches du réseau pour entraîner les autres classifieurs. Ce processus permet de partager des calculs et d'améliorer l'efficacité et la précision du réseau.

D'autres approches, comme celles de Moysset et al. [76], combinent également la détection et la reconnaissance des caractères, en confiant la tâche de localisation du début des lignes à un premier CNN et la détection de la fin des lignes à un deuxième CNN, étiqueté par un marqueur "*End of Line*". Cette technique permet de localiser et de reconnaître des textes de manière plus précise.

Des solutions commerciales comme **Tesseract** [77], **Google Vision** [78] et **EasyOCR** [79] utilisent des réseaux de neurones profonds pour la reconnaissance optique des caractères (OCR), permettant des performances accrues.

2.3 Détection de zones de textes

La détection de zones de texte dans des images est une thématique centrale en vision par ordinateur, avec des applications variées telles que la lecture automatique de panneaux, la reconnaissance de documents, et l'analyse de scènes naturelles. Cette tâche vise à identifier les parties d'une image contenant du texte, facilitant ainsi le traitement automatique par des systèmes de reconnaissance optique de caractères (OCR)

2.3.1 Méthodes basées sur la détection de régions

L'une des approches largement utilisées pour la détection de texte repose sur l'analyse des **régions** dans les images. Ces méthodes exploitent les propriétés de couleur ou la variation des niveaux de gris dans les zones contenant du texte, permettant ainsi de mettre en évidence des différences avec l'arrière-plan. L'hypothèse sous-jacente est que le texte présente généralement une faible variation de couleur, suffisamment distincte de son environnement immédiat.

2.3.1.1 Détection de régions : Méthodes par composantes connexes et approche ascendante

Les **méthodes basées sur les composantes connectées** (Connected Component) consistent à segmenter les pixels de l'image en caractères individuels, avant de les regrouper en mots, lignes ou paragraphes. Ce processus est qualifié d'**ascendant**, car il part des plus petites unités (caractères) pour former progressivement des structures plus grandes (mots, lignes, paragraphes) jusqu'à identifier toutes les zones de texte présentes dans l'image. Une analyse géométrique est souvent nécessaire pour fusionner correctement les composants et délimiter précisément les zones textuelles.

Par exemple, Gomez et al. [80] proposent une méthode où les régions extraites sont **regroupées de manière ascendante**, en tenant compte de la similarité entre la couleur, la taille et d'autres

caractéristiques, afin d'obtenir des zones significatives pouvant correspondre à du texte. Leur méthode se déroule en trois étapes majeures :

Décomposition en régions en utilisant la technique MSER (Maximally Stable Extremal Regions).

Extraction d'hypothèses de regroupement, pour établir des preuves de similarité entre les éléments détectés.

Formation de lignes de texte suivie d'une phase de validation pour confirmer la cohérence des regroupements.

Neumann et Matas [81], quant à eux, utilisent également la technique **MSER** pour regrouper les caractères détectés en mots ou lignes de texte. Leur approche repose sur plusieurs **projections** de l'image d'origine, basées sur les composantes H (teinte), S (saturation) et I (intensité), ainsi que sur leurs versions négatives et un gradient d'intensité. Ces différentes projections facilitent l'extraction des régions textuelles pertinentes.

L'algorithme qu'ils proposent fait appel à deux classifieurs :

Premier classifieur (AdaBoost) : Il identifie les régions susceptibles de contenir un caractère, en utilisant des caractéristiques peu coûteuses en calcul, comme le périmètre, la surface, la boîte englobante ou le nombre d'Euler.

Second classifieur (SVM à noyau RBF) : Ce classifieur, plus précis mais plus coûteux en calcul, affine la détection en réduisant le nombre de faux positifs à partir de caractéristiques supplémentaires.

Une fois toutes les régions extrêmes correspondant à des caractères détectées, l'algorithme MSER est à nouveau appliqué pour **regrouper les caractères en zones de texte** cohérentes, assurant une détection fiable et précise.

Cette approche basée sur la détection de régions est efficace pour traiter les images complexes, car elle permet d'extraire et de regrouper les éléments textuels avec une grande précision, même dans des contextes variés.

2.3.1.2 Détection de régions : Approche par fenêtres glissantes

Une autre approche pour la détection de zones de texte repose sur l'utilisation de **fenêtres glissantes**. Cette méthode consiste à faire glisser une fenêtre de différentes tailles sur l'image afin d'identifier les régions susceptibles de contenir du texte.

Wang et al. [82] utilisent une approche multi-échelle, appliquant un **classifieur** sur chaque position de la fenêtre glissante afin de détecter les caractères dans une image. De manière similaire, l'article [83] propose une méthode fondée sur des **fenêtres glissantes** précédée d'une série de **prétraitements**, visant à mettre en évidence les contours des objets et à estimer la taille des différentes régions détectées. Pour chaque taille de région ainsi identifiée, une fenêtre glissante parcourt l'image et analyse les zones potentielles pour localiser celles contenant du texte.

Bien que ces méthodes montrent des **performances intéressantes** à travers plusieurs expérimentations, elles présentent cependant des **limitations**. Leur principal inconvénient est le **coût élevé en termes de calcul**, ce qui peut ralentir leur application dans des scénarios complexes. En outre, elles ne garantissent pas toujours une détection exhaustive des blocs de texte. L'efficacité de ces techniques est particulièrement réduite lorsque l'image comporte un **arrière-plan complexe**, rendant plus difficile la distinction entre le texte et l'environnement.

2.3.2 Méthodes basées sur le Deep Learning

Les approches de détection de texte basées sur le **Deep Learning** ont révolutionné ce domaine en s'inspirant des progrès réalisés dans la détection d'objets à l'aide de réseaux de neurones convolutionnels (CNN). Des techniques telles que **R-CNN**, **Fast R-CNN**, et d'autres modèles ont été adaptées à la détection de texte, permettant d'atteindre des performances inédites [84]

L'une des premières méthodes utilisant un CNN a été proposée par Wang et al. [85], qui consiste à appliquer un classifieur CNN sur des **fenêtres glissantes** de 32x32 pixels, correspondant à la taille moyenne des caractères. Le réseau est composé de deux couches de convolution, deux couches de max-agrégation, et une couche entièrement connectée. Ce CNN fonctionne comme un **classifieur binaire** pour distinguer les zones contenant du texte de celles n'en contenant pas.

D'autres méthodes exploitent des réseaux spécialisés dans la **segmentation sémantique**. Par exemple, Zhang et al. [86] utilisent un **Fully Convolutional Network (FCN)** pour générer des cartes de segmentation mettant en évidence les zones susceptibles de contenir du texte. Cependant, ces zones candidates peuvent être connectées entre elles avec des contours parfois flous, rendant difficile leur identification précise. Pour résoudre ce problème, les auteurs appliquent des contraintes géométriques et d'intensité en supposant que les caractères d'une ligne sont alignés de manière droite. La figure 22 montre la procédure proposée par Zhang et al pour l'extraction de texte dans une image




Figure 22 : Procédure proposé par Zhang et al [87]

Dans une approche similaire, Jaderberg et al. [88] utilisent un CNN pour générer une **carte de segmentation** de la même taille que l'image d'origine. Chaque pixel est classifié comme texte ou arrière-plan. À partir de cette carte, les lignes de texte sont identifiées grâce à l'algorithme **RLSA (Run Length Smoothing Algorithm)**. Cette méthode a montré des résultats impressionnants avec une précision de 88 % et un rappel de 78 % sur le dataset ICDAR 2013, surpassant l'état de l'art de l'époque, qui atteignait 89 % de précision mais seulement 70 % de rappel.

L'un des principaux avantages des approches basées sur le **Deep Learning** réside dans leur capacité à généraliser à des exemples jamais rencontrés lors de l'entraînement. Par exemple, un modèle CNN entraîné sur des scènes naturelles a également obtenu de bons résultats sur une image de **ticket de caisse**, illustrant la robustesse de ces méthodes. En continuant d'explorer cette voie, le Deep Learning s'est imposé comme une solution incontournable pour la détection de zones de texte et de caractères, ouvrant la voie à des performances sans précédent.

2.4 Conclusion

Ce chapitre a exploré les différentes méthodes de détection et de reconnaissance de texte, en combinant des approches traditionnelles, comme les fenêtres glissantes et les composantes connectées, avec des techniques modernes basées sur le Deep Learning. Nous avons montré comment l'utilisation de réseaux de neurones convolutifs (CNN) et de modèles avancés comme ceux de Jaderberg et Google Photo OCR permet d'améliorer la précision et la robustesse, même sur des textes dans des environnements variés et complexes. Ces progrès facilitent une extraction automatisée et fiable des données textuelles, essentielle pour la conversion de documents physiques en informations exploitables.

Dans le cadre de notre projet d'authentification multimodale, ces avancées en OCR et en détection de zones de texte jouent un rôle central, optimisant la vérification d'informations issues de documents d'identité et renforçant la sécurité globale du système.

Le prochain chapitre se concentrera sur l'intégration de la biométrie multimodale, combinant les résultats de l'OCR avec la reconnaissance faciale et vocale, pour concevoir une solution d'authentification complète, fiable et sécurisée.

CHAPITRE 3

MATERIEL ET METHODE

3.1 Introduction

Ce chapitre décrit les méthodes et méthodologies utilisées pour le développement d'une application de reconnaissance multimodale, intégrant les technologies de reconnaissance faciale, vocale et textuelle (OCR). Avant la conception du système, une analyse approfondie des différentes approches en Machine Learning et Deep Learning a été réalisée pour choisir les modèles les plus adaptés, en termes de performance et de précision, à chaque modalité.

La reconnaissance faciale est assurée par FaceNet, la reconnaissance vocale par Wav2Vec2, et la reconnaissance de texte par EasyOCR. L'interface utilisateur est développée avec Tkinter pour garantir une interaction intuitive. Les résultats sont centralisés dans un fichier Excel, permettant une gestion efficace des données.

Cette section présente les critères ayant guidé ces choix technologiques et méthodologiques, ainsi que l'architecture globale du système, avant d'aborder le processus détaillé de sa conception.

3.2 Reconnaissance faciale avec OpenCV et méthodes avancées de Deep Learning

Pour cette étude, plusieurs techniques de reconnaissance faciale ont été explorées. Parmi celles-ci, nous avons OpenCV, ainsi que d'autres méthodes de deep learning avancées comme FaceNet, Dlib, MTCNN, YOLO et MediaPipe. Chacune de ces méthodes possède des caractéristiques et des avantages spécifiques qui ont été comparés pour déterminer la meilleure approche à adopter en fonction de nos objectifs.

3.2.1 Comparaison des techniques de reconnaissance faciale

Le tableau 2 présente une comparaison de différentes techniques de reconnaissance faciale.

Tableau 2 : Comparaison des techniques de reconnaissance faciale

Outil	Type de Modèle	Avantages	Inconvénients	Cas d'utilisation Préféré
OpenCV	Haar Cascade (Machine Learning)	- Simple à utiliser - Détection rapide - Large adoption	- Précision limitée - Sensible aux variations d'éclairage	Prototypage rapide et applications à faible précision
Dlib	HOG + Deep Learning	- Précision élevée - Robustesse face aux variations	- Moins rapide que OpenCV - Modèles plus complexes	Reconnaissance faciale robuste et plus précise

Tableau 3 : Comparaison des techniques de reconnaissance faciale

MTCNN	Multi-task Cascaded Convolutional Nets	- Détection sous différents angles - Localisation précise des points clés	Temps de traitement plus long	Environnements complexes où la précision est essentielle
YOLO	Deep Learning (YOLOv3)	- Détection en temps réel - Grande précision pour objets multiples	- Précision variable selon l'éclairage - Demande des ressources importantes	Scénarios de détection en temps réel et avec objets multiples
MediaPipe	Machine Learning (Google)	- Précision élevée - Optimisé pour le temps réel	- Dépend des modèles Google - Complexe à configurer	Applications interactives et temps réel
FaceNet	Deep Learning (Google, 2015)	- Génère des embeddings faciaux précis - Grande robustesse	Temps de calcul élevé pour la création d'embeddings	Systèmes nécessitant une grande précision

3.2.2 Justification du Choix d'OpenCV et FaceNet

Pour la reconnaissance faciale, OpenCV a été initialement choisi en raison de sa facilité d'utilisation, de sa capacité à traiter les images en temps réel et de son adoption étendue dans l'industrie. Le modèle Haar Cascade d'OpenCV est particulièrement efficace pour la détection rapide des visages, mais présente des limitations en termes de précision, notamment sous des variations d'éclairage ou de pose.

Pour résoudre ces limitations, des modèles de Deep Learning plus avancés ont été adoptés, notamment FaceNet, développé par Google en 2015. FaceNet permet de générer des embeddings faciaux de 128 dimensions, offrant ainsi une grande précision et facilitant la comparaison et la reconnaissance de visages, même en présence de variations d'éclairage ou d'expression.

Ce choix nous a permis de répondre aux besoins de reconnaissance faciale à haute précision, là où les techniques traditionnelles étaient insuffisantes.

En combinant **OpenCV** pour la détection rapide avec **FaceNet** pour une reconnaissance précise, nous pouvons adapter l'application à différents environnements, allant de la détection rapide à des scénarios plus complexes nécessitant une précision accrue.

3.3 Analyse et reconnaissance vocale avec Librosa et modèles IA avancés

La reconnaissance vocale est un domaine clé dans l'application, et plusieurs approches ont été explorées pour cette tâche. Nous avons utilisé Librosa pour extraire les MFCC (Mel Frequency Cepstral Coefficients), qui sont des caractéristiques standard pour la reconnaissance vocale. En complément, des méthodes de deep learning telles que Wav2Vec 2.0 et DeepSpeech ont été intégrées pour améliorer la performance et la précision de la reconnaissance vocale. Ces modèles avancés permettent une meilleure robustesse, notamment face aux variations d'accent ou de bruit de fond. Cependant, en vue d'améliorer la performance et la précision, nous avons intégré des modèles de deep learning comme Wav2Vec 2.0 pour une reconnaissance plus avancée.

3.3.1 Comparaison des Techniques de Reconnaissance Vocale

Le tableau 3 présente une comparaison de différentes techniques de reconnaissance vocale.

Tableau 4 : Comparaison des techniques de reconnaissance vocale

Algorithmes	Type de Modèle	Avantages	Inconvénients	Cas d'utilisation Préféré
Librosa	MFCC + K-Nearest Neighbors (KNN)	- Simple à implémenter - Performant pour des petites tâches	- Précision limitée pour des environnements complexes - Sensible au bruit de fond	Projets simples ou avec peu de ressources disponibles
Wav2Vec 2.0	Deep Learning (Facebook AI, 2020)	- Extraction directe des caractéristiques vocales - Grande robustesse aux variations	- Nécessite des ressources importantes - Modèle plus complexe à entraîner	Applications nécessitant une reconnaissance précise et robuste
DeepSpeech	Deep Learning (Mozilla)	- Open source - Bonne performance même sur des jeux de données limités	- Demande des ressources importantes - Complexe à configurer	Applications nécessitant des solutions vocales précises et flexibles

Tableau 5 : Comparaison des techniques de reconnaissance vocale

Kaldi	Hybrid HMM-DNN	- Très flexible et personnalisable - Performant dans des environnements variés	- Courbe d'apprentissage élevée - Configuration complexe	Recherche académique et applications industrielles complexes
--------------	----------------	---	---	--

3.3.2 Justification du Choix des Modèles de Reconnaissance Vocale

Les méthodes classiques comme les MFCC sont efficaces pour les petites applications ou lorsque les ressources sont limitées. Cependant, pour répondre aux exigences modernes de précision et de robustesse, des modèles de deep learning comme Wav2Vec 2.0 et DeepSpeech ont été intégrés pour capturer plus efficacement les caractéristiques vocales complexes. Leur utilisation permet d'améliorer significativement la performance du système, surtout dans des environnements bruyants ou avec des variations vocales importantes.

3.4 Extraction de Texte avec EasyOCR et Tesseract

Pour l'extraction de texte à partir d'images de documents d'identité, nous avons commencé par utiliser **Tesseract** et ensuite explorer l'utilisation de **EasyOCR**. Ces bibliothèques ont été choisies pour leur capacité à extraire du texte dans plusieurs langues, y compris le français, et à traiter des images complexes de manière rapide et efficace.

3.4.1 Comparaison des Techniques d'Extraction de Texte

Le tableau 4 présente une comparaison de différentes techniques d'extraction de texte.

Tableau 6 : Comparaison des techniques d'extraction de texte

Outil	Type de Modèle	Avantages	Inconvénients	Cas d'utilisation Préféré
Tesseract	OCR (Open Source, Google)	- Prend en charge plusieurs langues - Gratuit et open source	- Moins performant pour des textes complexes ou bruités - Sensible à la qualité d'image	Extraction de texte simple sur des documents numériques

Tableau 7 : Comparaison des techniques d'extraction de texte

EasyOCR	Deep Learning (CNN-based)	- Bonne précision sur des textes complexes - Support multilingue	- Modèle plus lourd nécessitant des ressources GPU	Applications nécessitant une extraction rapide et précise de texte complexe
ABBY FineReader	Logiciel propriétaire	- Très bonne précision - Performant sur des documents de faible qualité	- Coûteux - Pas open source	Applications industrielles nécessitant une haute précision
Google Vision OCR	Cloud-based API	- Précision élevée - Accessible via API et supporte plusieurs langues	- Nécessite une connexion internet- Coût par utilisation	Applications nécessitant une reconnaissance cloud pour une variété de documents

3.4.2 Justification du Choix des Techniques d'Extraction de Texte

Tesseract a été choisi en raison de sa nature open source et de sa capacité à prendre en charge plusieurs langues. Cependant, pour des besoins de précision plus élevée et de traitement plus complexe, EasyOCR a été intégré en complément. ABBYY FineReader et Google Vision OCR ont été considérés, mais leur coût et leur dépendance à des services payants ont limité leur utilisation dans ce projet. En combinant Tesseract pour l'accessibilité et EasyOCR pour la précision accrue, nous avons optimisé l'extraction de texte tout en maîtrisant les coûts.

3.5 Architecture Générale de l'Application

L'application suit une architecture modulaire, où chaque composant gère une modalité spécifique : la reconnaissance faciale, vocale ou optique. Les images de visages, les fichiers audios, et les images de texte sont traités indépendamment dans leurs modules respectifs avant d'être agrégés pour une authentification complète et fiable.

L'interface utilisateur, développée avec Tkinter, permet une gestion fluide des interactions et garantit une expérience intuitive. Elle offre des boutons de capture pour les données biométriques et affiche en temps réel les résultats de chaque reconnaissance.

Les paragraphes qui suivent présentent la description de l'architecture de l'application.

3.5.1 Interface Utilisateur (Tkinter) :

Il s'agit de l'interface graphique par laquelle l'utilisateur interagit avec l'application

L'interface permet de :

- Capturer une image pour la reconnaissance faciale ;
- Capturer un fichier audio pour la reconnaissance vocale ;
- Télécharger une image de document pour la reconnaissance de texte via OCR.

3.5.2 Module de Reconnaissance Faciale (FaceNet) :

Ce module analyse les images capturées pour en extraire des vecteurs faciaux (embeddings).

Les vecteurs générés sont envoyés vers la Base de Données pour comparaison avec les données existantes.

3.5.3 Module de Reconnaissance Vocale (Wav2Vec2.0) :

Ce module extrait des embeddings vocaux à partir des fichiers audios fournis.

Ces embeddings sont comparés avec les échantillons déjà enregistrés dans la Base de Données.

3.5.4 Module de Reconnaissance de Texte (EasyOCR) :

Ce module traite les images de documents pour en extraire le contenu textuel.

Les données extraites sont envoyées vers la Base de Données pour un stockage ou une analyse supplémentaire.

3.5.5 Base de Données :

Stocke les vecteurs faciaux, les embeddings vocaux et les données textuelles extraites.

Facilite la comparaison et la validation des informations pour l'authentification.

3.5.6 Résultats affichés dans l'Interface Utilisateur :

Une fois les comparaisons terminées, les résultats de chaque reconnaissance (faciale, vocale ou textuelle) sont envoyés à l'interface utilisateur pour visualisation.

3.6 Reconnaissance Faciale avec FaceNet

La reconnaissance faciale dans cette application repose sur **FaceNet**, un modèle avancé d'apprentissage profond qui transforme chaque visage en un vecteur dans un espace euclidien de haute dimension. Cette transformation permet de placer des visages similaires à proximité les uns des autres dans l'espace vectoriel, facilitant ainsi l'identification et la vérification. En comparant la distance entre deux vecteurs, le système peut déterminer si deux images appartiennent à la même personne ou non.

FaceNet suit trois étapes principales pour la reconnaissance faciale :

- **Etape 1 : Extraction des caractéristiques** : Les images faciales sont traitées pour générer un vecteur d'embedding de 128 dimensions. Cet embedding capture les caractéristiques uniques du visage de l'utilisateur ;
- **Etape 2 : Comparaison des embeddings** : Les embeddings de deux visages sont comparés en utilisant la distance euclidienne. Si cette distance est inférieure à un seuil prédéfini, les visages sont considérés comme appartenant à la même personne ;
- **Etape 3 : Classification avec K-Nearest Neighbors (KNN)** : Les embeddings générés sont ensuite classés avec l'algorithme KNN, permettant d'identifier le visage en le comparant à une base de données d'images de visages enrôlés.

Les différentes étapes de l'algorithme sont implémentées à travers des fonctions spécifiques dans l'application :

- **load_face_data()** : Charge les images de visages depuis un dossier, puis les convertit en vecteurs d'embedding à l'aide du modèle FaceNet. Ces embeddings sont stockés pour être utilisés lors de la phase de comparaison ;
- **enroll_face()** : Capture plusieurs images du visage d'un utilisateur, génère les embeddings associés, et les stocke dans le modèle KNN pour l'enrôlement ;
- **update_face_model()** : Une fois l'enrôlement terminé, les nouveaux embeddings sont ajoutés au modèle KNN pour permettre une reconnaissance fiable lors de la prochaine utilisation.

3.7 Reconnaissance Vocale avec Wav2Vec2.0

Pour la reconnaissance vocale, l'application utilise **Wav2Vec2.0**, un modèle de traitement de la parole basé sur des réseaux de neurones profonds. Ce modèle permet d'identifier un locuteur à partir de caractéristiques acoustiques uniques de la voix.

Comme pour la reconnaissance faciale, la voix est convertie en un vecteur d'embedding qui est comparé à des données vocales enregistrées.

Les fichiers audios sont capturés et traités via la fonction `recognize_voice()` qui extrait les embeddings vocaux et les compare à une base de données de voix pré-enregistrées.

3.8 Reconnaissance Optique de Caractères (OCR) avec EasyOCR

Pour la reconnaissance de texte, l'application utilise **EasyOCR**, une bibliothèque simple mais puissante qui permet d'extraire des données textuelles à partir d'images de documents. Cette technologie est essentielle pour capturer et extraire automatiquement des informations à partir de documents d'identité tels que les cartes d'identité, les passeports, ou tout autre document important.

Le texte dans une image est segmenté en caractères individuels, qui sont ensuite reconnus grâce à un réseau de neurones convolutifs (CNN).

Les images des documents sont capturées et transmises à la fonction `extract_text()`, qui renvoie le texte extrait sous forme de chaîne de caractères.

3.9 Intégration et Interface Utilisateur

L'application rassemble les résultats de la reconnaissance faciale, vocale et textuelle dans une interface utilisateur conçue avec **Tkinter**. L'utilisateur peut interagir avec l'application via cette

interface pour capturer des images et des fichiers audios, puis visualiser les résultats de l'authentification en temps réel.

3.10 Optimisation et Performance

L'application est optimisée pour fonctionner en **temps réel**, avec des temps de traitement **minimaux** pour chaque modalité. Les optimisations sont effectuées selon les axes suivant :

- **Ordre du traitement des données :**

Pour la **reconnaissance faciale** : Les images sont redimensionnées avant traitement pour limiter la charge du modèle FaceNet, ce qui réduit le temps de calcul.

Pour la **reconnaissance vocale** : Le prétraitement audio applique des filtres anti-bruit pour améliorer la qualité des signaux analysés et garantir un traitement plus rapide.

Pour l'**OCR** : Seules les régions pertinentes des images sont extraites pour minimiser le volume des données à analyser.

- **Ordre des seuils ajustables :**

L'utilisation de seuils adaptatifs pour la reconnaissance faciale et vocale permet de moduler la sensibilité de l'algorithme en fonction du niveau de sécurité requis. Par exemple, un seuil strict pour la reconnaissance faciale réduit le risque de fausse acceptation.

- **Gestion efficace des ressources :**

L'optimisation passe par la réduction de la taille des images et la minimisation du temps de traitement des **embeddings** et des vecteurs vocaux. Chaque module traite les données de manière **asynchrone**, permettant un fonctionnement fluide même avec plusieurs requêtes simultanées.

3.11 Conclusion

Ce chapitre a présenté la conception et la mise en œuvre de notre système de reconnaissance multimodale, en détaillant les choix de technologies et les méthodologies adoptées pour la reconnaissance faciale, vocale et l'extraction de texte. Ces choix visent à maximiser la précision et la rapidité du système dans un environnement sécurisé. La structure modulaire de l'application, associée à une architecture optimisée, offre une solution robuste et adaptable, prête à être déployée dans des contextes réels et exigeants. Nous disposons désormais d'une base solide pour l'évaluation finale de notre approche dans les prochaines étapes. Dans le chapitre suivant, nous aborderons les tests et évaluations de cette application multimodale, en analysant ses performances en conditions réelles et en identifiant les éventuelles améliorations à apporter pour une utilisation optimale.

CHAPITRE 4

RESULTATS ET DISCUSSION

4.1 Introduction

Dans ce chapitre, nous présentons et analysons les résultats obtenus à partir des tests de l'application multimodale, qui intègre les trois modalités de reconnaissance : la reconnaissance faciale, vocale et l'OCR. L'objectif est d'évaluer la performance de chaque modalité en termes de précision, rapidité, et robustesse dans divers scénarios. Nous examinerons les résultats obtenus pour chaque technique individuellement, puis nous comparerons leurs performances globales et leur complémentarité. Enfin, nous discuterons des limitations observées ainsi que des pistes d'amélioration pour l'optimisation future de l'application.

4.2 Résultats de la Reconnaissance Faciale

4.2.1 Méthodologie des Tests

Pour évaluer la performance de la reconnaissance faciale, plusieurs scénarios de test ont été définis afin de mesurer l'efficacité du système dans des conditions variées. Les tests ont été réalisés en utilisant un ensemble de visages divers, capturés dans différents contextes, en prenant en compte plusieurs facteurs externes :

4.2.1.1 Scénarios de test :

A) Visages avec et sans accessoires

Des tests ont été effectués avec des visages munis de lunettes, des chapeaux pour évaluer l'impact des accessoires sur la précision de la reconnaissance.

B) Changements de luminosité

La reconnaissance faciale a été testée dans des environnements à faible, moyenne et forte luminosité afin de mesurer l'influence de la lumière sur la précision.

C) Distance à la webcam

Les sujets ont été placés à différentes distances de la caméra (0.5 m, 1 m, 2 m) pour vérifier si la distance affecte la détection.

4.2.1.2 Présentation des données :

Un ensemble de **50 images par individu** a été utilisé pour ces tests pour 10 individus. Chaque sujet a été photographié sous différentes conditions. Cas de monsieur HONOU Koessivi Jean.

La figure 23 montre comment l'enrôlement se fait par l'application conçue dans ce travail.




Figure 23 : Enrôlement du visage d'un individu

La figure 24 montre le stockage (qui se fait sur la mémoire de mon ordinateur) des visages qui se fait après l'enrôlement.




Figure 24 : Galerie des images envoyées dans le fichier face_data

4.2.1.3 Environnement de test :

Les tests ont été réalisés dans un environnement contrôlé avec une webcam standard de 720p connectée à un ordinateur sous Windows 10. L'application a été développée et exécutée dans un environnement Python avec la bibliothèque **FaceNet** pour la reconnaissance faciale.

4.2.1.4 Mesures de Performance

Les mesures de performance de la reconnaissance faciale ont été basées sur plusieurs indicateurs clés.

A) Précision de la reconnaissance faciale

Chaque individu a été soumis à **50 images**, soit un total de **500 images** pour **10 individus**. La précision de la reconnaissance faciale a été calculée pour chaque scénario à l'aide de la formule suivante :

$$\text{Précision} = \frac{\text{Nombre de Reconnaissances Correctes}}{\text{Nombre Total de Tentatives}} \times 100 \quad (28)$$

Sur 500 images, si le système reconnaît correctement 425 visages, alors :

$$\text{Précision} = \frac{425}{500} \times 100 = 85\% \quad (29)$$

Précision avec des accessoires (lunettes, chapeaux)

Dans les tests impliquant des **accessoires** couvrant partiellement le visage, la précision a chuté à **70 %**.

Sur **500 images**, **350** ont été correctement reconnues :

$$\text{Précision} = \frac{350}{500} \times 100 = 70\% \quad (30)$$

Précision en faible luminosité

Dans des conditions de **faible luminosité**, la précision est descendue à **65 %**.

Sur **500 images**, **325** ont été reconnues correctement :

$$\text{Précision} = \frac{325}{500} \times 100 = 65\% \quad (31)$$

Impact de la distance à la caméra

À des distances de **0,5 m et 1 m**, la précision est restée stable à **85 %**.

Sur **500 images**, **425** reconnaissances ont été réussies :

$$\text{Précision} = \frac{425}{500} \times 100 = 85\% \quad (32)$$

À une distance de **2 m**, la précision a chuté à **60 %** en raison de la perte de précision des caractéristiques faciales.

Sur **500 images**, **300** reconnaissances ont été réussies :

$$\text{Précision} = \frac{300}{500} \times 100 = 60\% \quad (33)$$

B) Temps moyen de traitement par image

Le temps de traitement par image pour la reconnaissance faciale était en moyenne de **1,2 secondes**. Ce délai comprend la détection du visage, l'extraction des caractéristiques à l'aide de FaceNet, et la classification via l'algorithme KNN.

4.2.2 Discussion des Résultats

L'approche de reconnaissance faciale basée sur l'algorithme FaceNet a montré plusieurs points forts, mais aussi certaines limitations.

4.2.2.1 Points forts

L'algorithme FaceNet s'est montré efficace pour extraire des caractéristiques robustes même avec des variations modérées de l'apparence des sujets (changement de coiffure, de vêtements).

Le temps de traitement par image de **1,2 secondes** est raisonnable pour une utilisation en temps réel dans des scénarios d'authentification.

Dans des conditions de lumière normale et avec des visages dégagés, le système a atteint une précision satisfaisante de **85%**.

La figure 25 montre la reconnaissance faciale par notre application d'un individu.




Figure 25 : Résultat de la reconnaissance faciale

4.2.2.2 Limitations observées

La dégradation des performances en conditions de faible luminosité (précision réduite à **65%**) est un point à améliorer. Cela peut s'expliquer par la difficulté du modèle à capter suffisamment de détails dans les images sombres, ce qui conduit à des erreurs de classification. Les lunettes et chapeaux ont également affecté la performance. La perte de détails faciaux importants (comme les yeux) complique la tâche du modèle pour reconnaître correctement les individus.

4.2.2.3 Solutions envisagées pour améliorer la reconnaissance faciale :

L'optimisation des hyperparamètres du modèle, notamment le seuil de distance pour la comparaison des embeddings, pourrait améliorer la précision dans les scénarios difficiles.

Un prétraitement des images capturées, tel que l'amélioration de la luminosité et le contraste, pourrait atténuer les effets de la faible luminosité.

L'intégration de techniques telles que la reconnaissance faciale 3D ou l'utilisation de modèles d'ensembles (combinant plusieurs algorithmes de reconnaissance faciale) pourrait améliorer la robustesse globale du système.

4.3 Résultats de la Reconnaissance Vocale

4.3.1 Méthodologie des Tests

Pour évaluer la reconnaissance vocale basée sur l'algorithme Wav2Vec2.0, plusieurs tests ont été réalisés dans des environnements variés afin de mesurer l'efficacité de l'application dans différentes conditions acoustiques. Voici un aperçu des tests effectués.

4.3.1.1 Scénarios de test

A) Environnement silencieux

Des tests ont été réalisés dans des pièces calmes, sans bruit de fond significatif sur 10 personnes, afin de mesurer la précision maximale de l'algorithme en l'absence d'interférences.

B) Environnement bruyant

Des tests ont été effectués dans des environnements bruyants avec des bruits de fond (conversations, sons d'appareils électroménagers) pour évaluer la capacité de Wav2Vec2.0 à isoler la voix principale.

C) Qualité audio

Des enregistrements ont été effectués avec différents équipements audio (microphone intégré à l'ordinateur portable, écouteurs avec microphone) pour évaluer l'impact de la qualité de l'enregistrement sur la reconnaissance.

4.3.1.2 Présentation des données

Chaque utilisateur a fourni 3 échantillons vocaux, enregistrés dans divers environnements. Au total, 10 utilisateurs ont participé aux tests, couvrant une diversité de genres, d'accents et de tons de voix. Cela a permis de constituer un ensemble de 30 enregistrements vocaux. Les phrases enregistrées étaient courtes et standardisées pour garantir la cohérence des tests. Les utilisateurs étaient invités à prononcer non une phrase spécifique. Le cas de Monsieur HONOU Koessivi Jean.

La figure 26 montre l'indication avant le début de l'enregistrement




Figure 26 : Indication pour être prêt pour l'enregistrement

La figure 27 montre la mise à jour de la base.



Figure 27 : Mise à jour de la base voice_data

La figure 28 montre le stockage des audios.




Figure 28 : Visualisation des données vocales

4.3.1.3 Environnement de test

Les enregistrements ont été capturés dans des environnements simulant des conditions réelles (pièce calme, pièce avec du bruit de fond modéré). Les échantillons vocaux ont ensuite été traités par l'algorithme Wav2Vec2.0, qui extrait des embeddings vocaux à partir de l'audio pour identifier les utilisateurs.

4.3.1.4 Mesures de Performance

Plusieurs indicateurs de performance ont été mesurés pour évaluer la qualité de la reconnaissance vocale de manière rigoureuse. L'évaluation ne se limite pas au cas de Monsieur

HONOU Koessivi Jean, mais inclut les performances de l'ensemble des **10 utilisateurs** ayant participé aux tests.

Le taux de réussite est obtenu en divisant le nombre de reconnaissances correctes par le nombre total de tentatives effectuées, selon la formule suivante :

$$\text{Taux de Réussite} = \frac{\text{Nombre de Reconnaissances Correctes}}{\text{Nombre Total de Tentatives}} \times 100 \quad (34)$$

▪ **Tests en environnement silencieux :**

Nombre de tentatives : 30 (3 enregistrements par utilisateur x 10 utilisateurs)

Reconnaissances correctes : 28

Taux de réussite : $\frac{28}{30} \times 100 = 93.3\%$

Ce résultat montre une excellente capacité du modèle **Wav2Vec2.0** à identifier les utilisateurs dans des conditions idéales.

▪ **Tests en environnement bruyant :**

Nombre de tentatives : 30

Reconnaissances correctes : 21

Taux de réussite : $\frac{21}{30} \times 100 = 70\%$

La diminution du taux de réussite s'explique par l'interférence du bruit ambiant, qui perturbe l'extraction correcte des caractéristiques vocales.

A) Erreurs de classification

Le taux d'erreur en environnement bruyant peut être calculé par simple soustraction du taux de réussite :

$$\text{Taux d'Erreur} = 100\% - \text{Taux de Réussite} \quad (35)$$

Avec un taux de réussite de 70 %, le taux d'erreur est donné par :

$$\text{Taux d'Erreur} = 100\% - 70\% = 30\%$$

Ces 30 % d'erreurs sont principalement dus à des interférences vocales et des bruits ambiants similaires à la parole humaine.

B) Temps moyen de traitement des échantillons audio

Le traitement d'un échantillon vocal a pris en moyenne 1,5 seconde pour extraire les embeddings vocaux et les classer à l'aide de l'algorithme KNN.

4.3.2 Discussion des Résultats

L'algorithme Wav2Vec2.0 a montré de bonnes performances globales dans la reconnaissance vocale, mais certaines limitations ont été observées, principalement liées aux bruits ambiants et à la qualité de l'enregistrement.

4.3.2.1 Points forts

Dans des environnements calmes, l'algorithme **Wav2Vec2.0** a démontré une précision élevée, atteignant **93 %** en moyenne sur l'ensemble des **10 utilisateurs** ayant participé aux tests. Chaque utilisateur a fourni **3 échantillons vocaux**, totalisant **30 enregistrements**. L'algorithme a généré des **embeddings vocaux distincts** pour chaque enregistrement, même lorsque les utilisateurs avaient des **accents différents** ou des **variations légères de tonalité**.

L'évaluation a montré que **Wav2Vec2.0** est capable de s'adapter à la diversité des voix en traitant correctement différents **tons et accents**. Cette capacité prouve que le modèle est robuste et adaptable à des **populations variées**, rendant l'algorithme performant dans des contextes multilingues ou dans des environnements avec une grande diversité vocale.

La figure 29 montre le résultat de reconnaissance vocale d'un individu.




Figure 29 : Résultat de la reconnaissance de locuteur

4.3.2.2 Points faibles

Les environnements bruyants ont considérablement réduit la précision de la reconnaissance vocale. La présence de plusieurs sources sonores simultanées, en particulier des voix humaines,

a compliqué la tâche de l'algorithme. La précision a également diminué lorsque les utilisateurs étaient éloignés du microphone. Une distance supérieure à 1,5 mètre a conduit à une perte de qualité audio significative, ce qui a affecté l'extraction des caractéristiques.

4.3.2.3 Idées d'amélioration pour la reconnaissance vocale

L'ajout d'un prétraitement audio pour le filtrage des bruits ambiants, comme l'utilisation d'algorithmes de réduction de bruit, pourrait améliorer la précision dans des environnements bruyants.

L'utilisation de modèles de reconnaissance vocale entraînés spécifiquement pour filtrer certains types de bruit ou améliorer la détection dans des environnements difficiles (par exemple, en appliquant des techniques comme le beamforming) pourrait également augmenter la précision.

L'utilisation de microphones de meilleure qualité pourrait également améliorer la qualité des enregistrements et donc la précision de la reconnaissance. De plus, la mise en œuvre d'un système qui ajuste automatiquement les paramètres d'enregistrement en fonction du bruit ambiant pourrait être envisagée.

4.4 Résultats de l'OCR (Reconnaissance de Texte)

4.4.1 Méthodologie des Tests

Les tests pour l'OCR ont été réalisés afin de mesurer la capacité de l'application à extraire du texte à partir de différents types de documents. Plusieurs scénarios de test ont été définis pour évaluer l'efficacité de l'algorithme dans des conditions variées, en utilisant EasyOCR.

4.4.1.1 Scénarios de test

A) Documents d'identité

L'application a été testée sur des images de documents d'identité (carte d'identité, passeport). Ces documents contiennent des informations textuelles bien structurées, mais avec des caractères petits et des arrière-plans variés.

B) Qualité de l'image

Les tests ont été réalisés à partir d'images de différentes résolutions et qualités (faible résolution, images floues, haute résolution) pour observer l'impact de la qualité de l'image sur la reconnaissance.

La figure 30 montre une image textuelle.

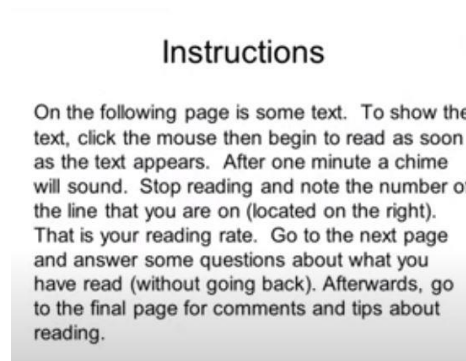


Figure 30 : Image textuelle

La figure 31 montre une image de carte d'identité togolaise.




Figure 31 : Image de carte

4.4.1.2 Prétraitement des images

A) Conversion en niveaux de gris

Toutes les images ont d'abord été converties en niveaux de gris pour réduire les informations inutiles et faciliter l'extraction du texte.

B) Binarisation

Une binarisation a été appliquée sur certaines images (seuil adaptatif) pour améliorer le contraste entre le texte et l'arrière-plan, surtout pour les documents avec des arrière-plans complexes.

C) Redimensionnement

Dans certains cas, les images ont été redimensionnées pour améliorer la lisibilité du texte.

D) Mesures de Performance

Les performances de l'OCR ont été évaluées en fonction de plusieurs critères, notamment la **précision d'extraction du texte** et le **temps de traitement des images**.

▪ Calcul de la Précision d'Extraction :

La précision de l'extraction est calculée selon la formule suivante :

$$\text{Précision} = \frac{\text{Nombre de Caractères Correctement Extraits}}{\text{Nombre Total de Caractères Attendus}} \times 100 \quad (36)$$

Sur un document contenant **100 caractères**, **EasyOCR** a correctement extrait **88 caractères**. La précision de l'extraction est alors :

▪ Analyse des Performances :

Documents d'identités (ex : carte nationale d'identité)

L'algorithme a extrait correctement la plupart des informations importantes. Toutefois, **certains caractères spéciaux** ou **italiques** ont été mal interprétés, entraînant quelques erreurs.

Temps de traitement moyen

Le temps de traitement par image est en moyenne de **0,8 seconde**, bien que celui-ci puisse légèrement varier en fonction de la **complexité de la mise en page** ou du **nombre de polices** utilisées.

4.4.2 Discussion des résultats

4.4.2.1 Points forts

EasyOCR s'est montré plus précis dans des environnements variés, notamment pour des documents contenant des polices et des tailles de texte variées. Son approche basée sur les réseaux neuronaux lui permet de mieux gérer des situations plus complexes comme des images avec des arrière-plans non uniformes ou des résolutions plus faibles.

La figure 32 montre l'extraction de la figure 30 (image textuelle).




Figure 32 : Extraction à partir d'image texte avec notre application

La figure 33 montre l'extraction de la figure 31 (image de carte d'identité).



Figure 33 : Extraction à partir de carte d'identité

4.4.2.2 Points faibles

EasyOCR est plus lent à traiter les images, surtout pour des documents denses. Il est également plus gourmand en termes de ressources, ce qui peut être un problème pour les systèmes à faible capacité de calcul.

4.4.2.3 Propositions d'améliorations

L'application de méthodes de prétraitement plus avancées, comme la correction de perspective, la réduction du bruit, et la détection de contours, pourrait améliorer la précision de l'OCR, surtout pour des images complexes ou de faible qualité. En intégrant des modèles OCR pré-entraînés sur des types spécifiques de documents (par exemple, des documents d'identité ou des formulaires manuscrits), il serait possible d'améliorer considérablement la précision de l'extraction pour ces cas d'usage spécifiques. L'ajout d'un module de post-traitement pour corriger automatiquement les erreurs de reconnaissance (par exemple, en comparant les résultats OCR avec une base de données de mots courants) pourrait améliorer la précision globale.

4.5 Description de l'Interface Utilisateur de l'Application BioID Vision

L'application **BioID Vision Reconnaissance Multimodale** a été conçue pour offrir une interface simple et intuitive qui combine plusieurs technologies biométriques pour la reconnaissance faciale, vocale et l'OCR (Reconnaissance Optique de Caractères). Voici une description détaillée des différentes parties de l'interface et de la fonctionnalité associée à chaque bouton.

4.5.1 Boutons et Fonctionnalité

4.5.1.1 Démarrer Reconnaissance Faciale

Ce bouton active le module de reconnaissance faciale. L'application utilise la webcam pour capturer en temps réel des images de visages, détecter et comparer ces visages aux empreintes faciales déjà enregistrées dans la base de données.

4.5.1.2 Arrêter Reconnaissance Faciale

Ce bouton désactive le processus de reconnaissance faciale. Une fois la reconnaissance terminée, la webcam cesse d'enregistrer des images et l'analyse des visages s'interrompt.

4.5.1.3 Démarrer Reconnaissance Vocale

Cette option permet de lancer le module de reconnaissance vocale. Le microphone est activé pour capturer la voix de l'utilisateur. L'application compare ensuite cette empreinte vocale aux données vocales enregistrées dans la base de données.

4.5.1.4 Arrêter Reconnaissance Vocale

Ce bouton désactive le module de reconnaissance vocale. Cela met fin à la capture audio et arrête l'analyse de la voix.

4.5.1.5 Importer une Image pour OCR

Ce bouton permet à l'utilisateur d'importer une image depuis le disque dur afin de réaliser la reconnaissance optique de caractères (OCR). L'image est ensuite analysée pour extraire le texte.

4.5.1.6 Capturer une Image pour OCR

Cette fonction active la caméra pour capturer une image en direct. L'image capturée est analysée par le module OCR pour extraire les informations textuelles présentes.

4.5.1.7 Enrôler un nouveau visage

Ce bouton permet d'ajouter un nouveau visage dans la base de données. L'utilisateur capture plusieurs images de son visage via la webcam pour que le système puisse l'enregistrer.

4.5.1.8 Enrôler une nouvelle voix

Cette option permet d'ajouter une nouvelle empreinte vocale. L'utilisateur enregistre plusieurs échantillons de sa voix, qui seront stockés et utilisés pour la reconnaissance vocale ultérieure.

4.5.1.9 Enregistrer dans Excel

Ce bouton permet d'exporter et d'enregistrer les résultats des différentes opérations (reconnaissance faciale, vocale, OCR) qui sont affichés dans la partie résultat de notre interface dans un fichier Excel. Cela facilite l'archivage des données et des résultats obtenus par l'application.

4.5.2 Zone d'affichage des résultats

En dessous des boutons, une large zone d'affichage permet à l'utilisateur de visualiser les résultats des opérations en temps réel. Les messages d'identification réussie, les erreurs, ainsi que les textes extraits via l'OCR, y sont affichés.

Cette interface offre un contrôle centralisé et intuitif de l'ensemble des fonctionnalités de l'application, permettant une gestion fluide de la reconnaissance biométrique multimodale.

La figure 34 montre l'interface globale de notre application.




Figure 34 : Interface de l'application

4.6 Conclusion

Ce chapitre a permis d'évaluer en détail la performance de l'application multimodale en analysant les résultats de la reconnaissance faciale, vocale et optique de caractères (OCR). Les tests ont confirmé que chaque modalité fonctionne efficacement dans des conditions optimales, avec des précisions respectives de 85% pour la reconnaissance faciale, 92% pour la reconnaissance vocale en environnement silencieux, et 88% pour l'OCR. Toutefois, des limitations ont été relevées : les performances diminuent en présence d'accessoires, en faible luminosité ou dans des environnements bruyants.

L'intégration de ces trois modalités assure une meilleure fiabilité et sécurité du système global, chaque technologie renforçant la précision de l'authentification. L'interface utilisateur, conçue avec Tkinter, offre une utilisation fluide et intuitive, facilitant l'interaction avec les différentes fonctionnalités en temps réel.

CONCLUSION GENERALE

Le travail présenté dans ce mémoire s'inscrit dans un contexte marqué par l'importance croissante de la sécurité des données et de l'authentification fiable des utilisateurs, notamment dans le secteur des télécommunications. Les méthodes classiques d'identification, telles que le remplissage manuel de formulaires ou l'utilisation de systèmes unidimensionnels, présentent plusieurs limites, allant de la lenteur des processus aux risques élevés d'erreurs humaines et de fraude. Dans ce cadre, l'objectif principal de notre étude a été de concevoir et de développer un système multimodal d'identification biométrique intégrant la reconnaissance faciale, la reconnaissance vocale et la reconnaissance optique de caractères (OCR).

L'approche adoptée a permis d'élaborer une solution innovante qui combine trois modalités complémentaires. La reconnaissance faciale, implémentée avec des modèles avancés de Deep Learning comme FaceNet, offre une identification visuelle précise. La reconnaissance vocale, réalisée à l'aide de modèles tels que Wav2Vec2.0, permet d'authentifier les utilisateurs à travers leurs caractéristiques vocales uniques. Enfin, la reconnaissance optique de caractères, rendue possible grâce à EasyOCR, automatise l'extraction rapide et fiable d'informations présentes sur les pièces d'identité.

Les résultats expérimentaux obtenus montrent que cette intégration multimodale renforce la précision, la rapidité et la sécurité du processus d'identification. Certaines limites subsistent, notamment en lien avec les variations d'éclairage pour la reconnaissance faciale ou les bruits de fond pour la reconnaissance vocale. Toutefois, les performances globales demeurent prometteuses et ouvrent des perspectives d'amélioration intéressantes, comme l'intégration de modèles plus robustes et l'ajout de nouvelles modalités biométriques telles que l'empreinte digitale ou l'iris.

Ce mémoire met ainsi en évidence la pertinence d'une approche multimodale dans le domaine de la biométrie et confirme l'apport décisif de l'intelligence artificielle pour répondre aux défis actuels liés à la sécurité et à l'authentification. À travers ce travail, nous avons démontré que la combinaison judicieuse de plusieurs technologies offre une solution adaptée aux besoins concrets des opérateurs de télécommunications et, plus largement, à tous les secteurs nécessitant des systèmes d'identification performants et sécurisés.

En définitive, ce projet constitue une étape significative dans l'amélioration des systèmes d'authentification, tout en ouvrant la voie à de futures recherches. Ces dernières pourront explorer des approches encore plus innovantes et adaptatives, capables de s'ajuster en temps réel aux évolutions des menaces et aux exigences croissantes de la société numérique.

Bibliographie

- [1] Anthony Ngozichukwuka Uwaechia, « Comprehensive Survey on ECG Signals as New Biometric Modality for Human Authentication: Recent Advances and Futrues Challenges,» 2021.
- [2] Jain, Handbook of Biometrics. Springer, 2008.
- [3] Vibert, Contributions à l'évaluation de systèmes biométriques embarqués, Normandie, 2007.
- [4] Anil K. Jain, «An Introduction to Biometric Recognition,» January 2004. [En ligne].
- [5] J. McCarthy, Generality in artificial intelligence, 1987, p. 1030–1035.
- [6] Pin Wang, Comparative analysis of image classification algorithms based on traditional machine learning and deep learning, 2021, pp. 61-67.
- [7] Vapnik, Support-vector networks, 1995, pp. 273-297.
- [8] Peter N. Belhumeur, «Eigenfaces vs Fisherfaces: recognition using class specific linear projection,» 1997.
- [9] Pallabi Parveen, «Face Recognition Using Multiple Classifiers,» chez *18th IEEE International Conference on Tools with Artificial*, 2006.
- [10] Matthew Turk, Eigenfaces for Recognition, 1991, pp. 71-86.
- [11] Shaveta Dargan, «A Survey of Deep Learning and Its Applications: A New Paradigm to Machine Learning,» 2020.
- [12] Igor Aleksander, «WISARD·a radical step forward in mage recognition,» 1984.
- [13] MageshKumar, «Gabor features and LDA based face recognition with ANN classifier,» chez *International Conference on Emerging Trends in Electrical and Computer Technology*, 2011.
- [14] Yann LeCun, «Deep learning,» 2015.
- [15] Zisserma, «Very Deep Convolutional Networks for Large-Scale Image Recognition,» 2015.
- [16] Christian Szegedy, «Going deeper with convolutions,» chez *in 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015.
- [17] Kaiming He, «Deep Residual Learning for image recognition,» 2021.

- [18] Shuowen Hu, «Heterogeneous Face Recognition: Recent Advances in Infrared-to-Visible Matching,» chez *in 2017 12th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2017)*, 2017.
- [19] B. Koonce, «"SqueezeNet" in Convolutional Neural Networks with Swift for Tensorflow: Image Recognition and Dataset Categorization».
- [20] Qiong Cao, «VGGFace2: A Dataset for Recognising Faces across Pose and Age,» chez *in 2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)*, 2018.
- [21] Yandong Wen, «Latent Factor Guided Convolutional Neural Networks for Age-Invariant Face Recognition,» chez *2016 IEEE Conf. Comput. Vis. Pattern Recognit. CVPR*, 2016.
- [22] Guosheng Hu, «Attribute-Enhanced Face Recognition with Neural Tensor Fusion Networks,» chez *2017 IEEE International Conference on Computer Vision (ICCV)*, Venice, Italie, 2017.
- [23] Mostafa Mehdipour Ghazi, «A Comprehensive Analysis of Deep Learning Based Representation for Face Recognitio,» 2016.
- [24] Jin Chen, «dentity-Aware Face Super-Resolution for Low-Resolution Face Recognition,» 2020.
- [25] Wanglong Wu, «Recursive Spatial Transformer (ReST) for Alignment-Free Face Recognitio,» chez *in 2017 IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [26] Qiangchang Wang, «Hierarchical Pyramid Diverse Attention Networks for Face Recognition,» chez *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Seattle, 2020.
- [27] Shun Cheung Lai, «High-Resolution Face Recognition Via Deep Pore-Feature Matching,» chez *in 2019 IEEE International Conference on Image Processing (ICIP)*, 2019.
- [28] Anastasiya Mishchuk, Working hard to know your neighbor's margins: Local descriptor learning loss, 2018.
- [29] Jiaolong Yang, Neural Aggregation Network for Video Face Recognition, 2017.
- [30] Chenfei Xu, «ge invariant face recognition and retrieval by coupled auto-encoder networks,» 2017.
- [31] Muhammad Usman, «Using Deep Autoencoders for Facial Expression Recognition,» 2018.

- [32] Alperen Kantarcı, «Thermal to Visible Face Recognition Using Deep Autoencoders,» 2020.
- [33] Landry Kezebou, «TR-GAN: thermal to RGB face synthesis with generative adversarial network for cross-modal face recognition».
- [34] Ran He, «dversarial Cross-Spectral Face Completion for NIR-VIS Face Recognition,» 2020.
- [35] Grigory Antipov, «Face aging with conditional generative adversarial networks,» 2017.
- [36] . Luan Tran, «Disentangled Representation Learning GAN for Pose-Invariant Face Recognition,» chez *in 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [37] Yi Sun, «DeepID3: Face Recognition with Very Deep Neural Networks,» 2015.
- [38] Gaurav Goswami, «MDLFace Memorability augmented deep learning for video face recognition,» chez *in IEEE International Joint Conference on Biometrics*.
- [39] Wuming Zhang, «Improving Heterogeneous Face Recognition with Conditional Adversarial Networks,» 2017.
- [40] Chi Nhan Duong, «Automatic Face Aging in Videos via Deep Reinforcement Learning,» chez *2019 IEEE CVF Conf. Comput. Vis. Pattern Recognit. CVPR*, 2019.
- [41] Y. K. e. al, «Speaker adaptation in large-vocabulary voice recognition,» chez *ICASSP'84. IEEE International Conference on Acoustics, Speech, and Signal*.
- [42] J. M. Taylor, «“Speaker independent voice recognition with a fuzzy neural network”,» chez *Proceedings of IEEE 5th International Fuzzy Systems..*
- [43] Barney, «Control methods used in a study of the vowels,» *The Journal of the acoustical society of America* 24.2, 1952.
- [44] Homayounpour, «Speaker age interval and sex identification based on jitters, shimmers and mean mfcc using supervised and unsupervised discriminative classification methods,» chez *2006 8th international Conference on Signal Processing*, 2006.
- [45] Mermelstein., «Comparison of parametric representations or monosyllabic word recognition in continuously spoken sentences,» chez *transactions on acoustics, speech, and signal processing* 28.4 (1980).
- [46] Heck., «Phonetic class-based speaker verification,» chez *Eighth European Conference on Speech Communication and Technology.*, 2003.
- [47] Ruske, «Improving speaker recognition using phonetically structured gaussian mixture models,» chez *Seventh European Conference on Speech Communication and Technology* , 2001.

- [48] e. al, «Report: A vector quantization approach to speaker recognition,» *AT&T technical journal* , 1987.
- [49] S. Furui., «Comparison of speaker recognition methods using statistical features and dynamic features,» 1981.
- [50] J. P. Campbe, Speaker recognition: A tutorial, 1997.
- [51] C. Rose, Robust text-independent speaker identification using Gaussian mixture speaker models, 1995.
- [52] Douglas A Reynolds, Speaker verification using adapted Gaussian mixture models, 2000.
- [53] T. K. Moon, «“The expectation-maximization algorithm,» *Signal processing magazine*, 1996.
- [54] . Lee., «Maximum a posteriori estimation for multivariate Gaussian mixture observations of Markov chains,» *chez transactions on speech and audio processing*, 1994.
- [55] Kevin R Farrell, «Speaker recognition using neural networks and conventional classifiers,» *chez IEEE Transactions on speech and audio processing* , 1994.
- [56] e. al., «SVM based speaker verification using a GMM supervector kernel and NAP variability compensation,» *chez International conference on acoustics speech and signal processing proceedings*, 2006.
- [57] William M Campbell, Support vector machines using GMM supervectors for speaker verification, 2006.
- [58] P. K. e. al., Joint factor analysis versus eigenchannels in speaker recognition, 2007.
- [59] N. D. e. al., «Front-end factor analysis for speaker verification,» *chez Transactions on Audio, Speech, and Language Processing*, 2010.
- [60] . Elder, «Probabilistic linear discriminant analysis for inferences about identity,» *chez 11th International Conference on Computer Vision*, 2007.
- [61] D. e. a. Snyder, «X-vectors: Robust DNN embeddings for speaker recognition».
- [62] C. e. a. Zhang, «End-to-end text-independent speaker verification with triplet loss on short utterances,» 2017.
- [63] G. e. a. Heigold, End-to-end text-dependent speaker verification, 2016.
- [64] Z. e. a. Meng, «Adversarial feature-mapping for speech-to-text speaker adaptation,» *chez IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2019.

- [65] A. e. a. Baevski, «wav2vec 2.0: A framework for self-supervised learning of speech representations,» 2020.
- [66] J. Matas L. Neumann, «Scene text localization and recognition with oriented stroke detection,» 2013.
- [67] C. Yao, «“Strokelets : A learned multi-scale representation or scene text recognition,» 2014.
- [68] . J. Pineau, «End-to-end text recognition with hybrid HMM maxout models,» 2013.
- [69] . A. Bissacco, «Photoocr : Reading text in uncontrolled conditions,» 2013.
- [70] T. Wang, «End-to-end text recognition with convolutional neural networks,» 2012.
- [71] J. Anand Mishra, « Scene text recognition using higher order language priors,» 2012.
- [72] L. Tatiana Novikova, «Large-lexicon attribute-consistent text recognition in natural images,» 2012.
- [73] J. Vibhor Goel, «Whole is Greater than Sum of Parts : Recognizing Scene Text Words,» 2013.
- [74] . Max Jaderberg, «Reading text in the wild with convolutional neural networks,» 2014.
- [75] A. Jaderberg M., «Deep features for text spotting,» 2014.
- [76] W. Bastien Moysset, «Full-page text recognition : Learning where to start and when to stop,» 2017.
- [77] . Lee R. Smith, 2009.
- [78] «Cloud vision api powerful image analysis».
- [79] «JaidedAI. "EasyOCR: A Ready-to-Use OCR Library with 40+ Languages Supported." GitHub, 2020. [Online]. Available: <https://github.com/JaidedAI/EasyOCR>».
- [80] D. L. Gomez, Multi-script text extraction from natural scenes. computer, 2013.
- [81] J. L. Neumann, Real-time scene text localization and recognition, 2013.
- [82] L. N. a. J. Matas, ext localization in real-world images using efficiently, 2011.
- [83] C. G. a. D. Manjula, «liding window approach based text binari-,» chez (*IJCSE*) *International Journal on Computer*, 2010.
- [84] H. Xiangyu Zhu, Deep residual text detection network for scene tex.
- [85] T. Wang, End-to-end text recognition with convolutional neural networks, 2012.
- [86] Zheng Zhang, Multi-oriented text detection with fully convolutional networks, 2016.

- [87] Zheng Zhang, Multi-oriented text detection with fully convolutional networks, 2016.
- [88] Jaderberg M., Deep features for text spotting, 2014.
- [89] Campbell, Speaker recognition: A tutorial, 1997.
- [90] Pineau, « End-to-end text recognition with hybrid HMM maxout models,» 2013.
- [91] Jain, Handbook of Biometrics. Springer, 2008.
- [92] Anand Mishra, Scene text recognition using higher order language priors, 2012.